

BAB I

PENDAHULUAN

1.1 Latar Belakang

Pemodelan topik (*topic modeling*) merupakan pendekatan penting dalam analisis teks untuk menemukan tema tersembunyi dalam kumpulan dokumen besar secara otomatis (Blei et al., 2003a). Dalam konteks teks-teks keagamaan, seperti terjemahan Al-Qur'an, analisis ini menjadi tantangan tersendiri karena sifat bahasanya yang padat makna, kontekstual, dan mengandung makna teologis yang dalam (Habash, 2006). Terjemahan Al-Qur'an dalam bahasa Indonesia memiliki kekhasan struktur linguistik yang tidak hanya literal, tetapi juga interpretatif, sehingga pemodelan topik pada korpus ini membutuhkan pendekatan yang lebih kontekstual dan adaptif terhadap makna dalam teks.

Hingga saat ini, sebagian besar penelitian pemodelan topik pada teks keagamaan masih menggunakan pendekatan klasik seperti *Latent Dirichlet Allocation* (LDA) atau *Non-Negative Matrix Factorization* (NMF). yang mengandalkan representasi bag-of-words dan tidak secara eksplisit mempertimbangkan konteks kata dalam kalimat atau paragraf secara menyeluruh. Akibatnya, model-model tersebut cenderung menghasilkan topik yang kurang mampu mencerminkan keterkaitan semantik yang mendalam dalam teks keagamaan seperti Al-Qur'an.

Seiring perkembangan teknologi pemrosesan bahasa alami (NLP), model berbasis *transformer* seperti BERT (*Bidirectional Encoder Representations from Transformers*) membawa kemajuan signifikan dalam memahami konteks kata dalam kalimat. Model ini dilatih secara besar-besaran menggunakan miliaran kata, sehingga mampu menangkap nuansa makna dan hubungan antar-kata dalam berbagai konteks. *Correlated Topic Modeling* (CTM) dan BERTopic merupakan metode pemodelan topik modern yang memanfaatkan kekuatan representasi kontekstual dari BERT untuk menghasilkan topik yang lebih koheren dan bermakna. CTM sendiri mengembangkan pendekatan klasik dengan memodelkan korelasi antar topik menggunakan distribusi logistic normal, sehingga mampu

mengidentifikasi hubungan kompleks antar tema yang muncul dalam dokumen. (Blei & Lafferty, 2007a)

BERTopic menggabungkan representasi embedding dari BERT dengan teknik pengelompokan seperti HDBSCAN dan reduksi dimensi UMAP untuk menghasilkan topik-topik yang fleksibel dan dapat diinterpretasikan secara visual (Brawijaya et al., 2017). Sementara itu, CTM menyempurnakan pendekatan klasik dengan mengintegrasikan vektor dokumen dari BERT dan representasi *bag-of-words* dalam kerangka probabilistik dengan *variational autoencoder*, sehingga tetap mempertahankan interpretabilitas topik sekaligus menangkap korelasi antar topik secara lebih nyata. Kedua metode ini masih jarang digunakan dalam analisis teks religius, khususnya dalam bahasa Indonesia, yang membuka peluang penelitian dengan kontribusi bernilai tinggi.

Beberapa penelitian awal telah menerapkan BERTopic dan CTM pada berbagai jenis korpus, seperti ulasan produk, berita, dan dokumen akademik, dengan hasil yang menjanjikan. Misalnya, (Blei & Lafferty, n.d., 2007) menunjukkan bahwa CTM mampu menghasilkan nilai koherensi topik yang lebih tinggi dibanding metode lainnya seperti LDA. Di sisi lain, BERTopic mendapatkan perhatian karena kemampuannya mengidentifikasi topik secara dinamis dan mendalam, serta menyajikannya dalam bentuk visual interaktif. Namun, penerapan kedua metode ini pada korpus teks religius terutama teks terjemahan Al-Qur'an dalam bahasa Indonesia belum banyak digunakan.

Salah satu penelitian pada terjemah Al-Qur'an yaitu diantaranya "Pengelompokan Terjemah Al-Quran Departemen Agama menggunakan Metode Fuzzy C-Means", penelitian ini menggunakan algoritma *fuzzy c-means* (FCM) dan *vector space model* (VSM) untuk mengelompokkan terjemahan ayat berdasarkan kemiripan dan fokus pada *clustering* dengan *preprocessing* teks, pembobotan *tf-idf*, dan evaluasi kualitas klaster dengan *silhouette coefficient*. Hasil algoritma FCM menghasilkan nilai *clustering* terbaik dengan parameter tertentu dan algoritma ini secara umum mampu menemukan kelompok ayat yang serupa makna. Namun, karakteristik dimensi fitur tinggi dan kemiripan antar terjemah yang sedikit membuat kinerja FCM kurang optimal (Havid Albar Purnomo & Abdurrachman Bachtiar, 2021)

Penelitian lainnya pada terjemah Al-Qur'an yaitu "Perbandingan Performa Klasifikasi Terjemahan Al-Quran Menggunakan Metode *Random Forest* dan *Long Short Term Memory* (LSTM)", penelitian ini berfokus pada klasifikasi terjemahan ayat Al-Quran ke dalam kategori tema menggunakan metode *supervised learning* *Random Forest* (RF) dan *deep learning* LSTM. Penelitian ini menggunakan dataset terjemahan dengan 6 topik dan menyajikan perbandingan kinerja klasifikasi dari dua metode tersebut. LSTM menunjukkan keunggulan pada kategori dakwah dengan nilai F1-Score lebih tinggi dibanding RF, terutama setelah dilakukan *preprocessing* dan tuning parameter secara optimal. Klasifikasi multi-label teks Al-Quran menjadi pendekatan yang penting untuk mempermudah pemahaman isi Al-Quran secara tematik (Aftari et al., 2024).

Adapun penelitian ini selain dari metode yang lebih kontekstual dengan metode CTM dan Bertopic juga terletak pada kebutuhan untuk memahami kandungan makna dalam teks Al-Qur'an secara lebih terstruktur dan otomatis, sehingga dapat dimanfaatkan dalam berbagai keperluan seperti pembelajaran tematik, pengembangan sistem pencarian ayat berbasis tema, atau analisis linguistik keislaman. Pemodelan topik yang baik pada teks terjemahan Al-Qur'an dapat membantu masyarakat maupun akademisi dalam memahami dan mengeksplorasi tema-tema utama dalam Al-Qur'an secara efisien dan sistematis.

Dengan latar belakang tersebut, penelitian ini berupaya memberikan kontribusi dalam pengembangan pendekatan NLP kontekstual terhadap teks keagamaan berbahasa Indonesia, dengan menguji efektivitas BERTopic dan CTM pada teks terjemahan Al-Qur'an. Keunikan pendekatan ini terletak pada penggunaan dua metode berbasis BERT yang masih relatif baru dalam domain NLP religius, menjadikannya sebagai salah satu bentuk kebaruan (*novelty*) dalam penelitian teks keislaman digital masa kini.

1.2 Permasalahan Penelitian

1.2.1 Identifikasi Masalah

Berdasarkan latar belakang masalah di atas, identifikasi masalah dalam penelitian ini adalah sebagai berikut:

1. Teks terjemahan Al-Qur'an memiliki kompleksitas linguistik yang tinggi, sehingga menyulitkan model dalam menangkap makna semantik secara akurat.
2. Metode CTM dan BERTopic memiliki keterbatasan yang berbeda, baik dari sisi performa, komputasi, maupun interpretabilitas hasil topik.
3. Belum ada perbandingan yang jelas mengenai kelebihan dan kekurangan metode CTM dan BERTopic dalam pemodelan topik teks terjemahan Al-Qur'an.

1.2.2 Ruang Lingkup Masalah

Berdasarkan beberapa pokok permasalahan yang telah diuraikan pada identifikasi masalah di atas, maka penelitian dibatasi pada:

1. Penelitian ini hanya membahas pemodelan topik pada teks terjemahan Al-Qur'an berbahasa Indonesia, tidak pada teks asli bahasa Arab.
2. Fokus analisis terbatas pada dua metode pemodelan topik, yaitu *Correlated Topic Modeling* (CTM) dan BERTopic.
3. Evaluasi dilakukan berdasarkan kualitas topik yang dihasilkan dan akurasi model menggunakan metrik koherensi topik seperti C_V dan UMass.

1.2.3 Rumusan Masalah

Berdasarkan identifikasi masalah di atas maka dapat dirumuskan masalah yaitu:

1. Bagaimana membangun model *Correlated Topic Modeling* (CTM) dan BERTopic dalam pembentukan topik pada teks terjemahan Al-Qur'an berbahasa Indonesia?
2. Bagaimana mengukur kualitas dan akurasi topik yang dihasilkan oleh *Correlated Topic Modeling* (CTM) dan BERTopic berdasarkan metrik koherensi?
3. Bagaimana menginterpretasikan dan mengelompokan tema topik yang dihasilkan dari kedua metode dalam konteks terjemah Al-Qur'an?

4. Apa tema utama yang terbentuk dari hasil topik metode *Correlated Topic Modeling* (CTM) dan BERTopic pada terjemahan Al-Qur'an berbahasa Indonesia?

1.3 Tujuan dan Manfaat Penelitian

1.3.1 Tujuan Penelitian

Adapun tujuan penulis melakukan penelitian ini adalah sebagai berikut:

1. Menganalisis efektivitas metode *Correlated Topic Modeling* (CTM) dan BERTopic dalam pemodelan topik pada teks terjemahan Al-Qur'an berbahasa Indonesia.
2. Mengidentifikasi kemampuan kedua metode dalam menangkap konteks dan tema utama yang terkandung dalam teks terjemahan Al-Qur'an.
3. Merumuskan metode evaluasi yang tepat untuk menilai kualitas topik yang dihasilkan dalam konteks kajian Al-Qur'an.

1.3.2 Manfaat Penelitian

Adapun manfaat yang diharapkan dalam penelitian ini sebagai berikut:

1. Memberikan kontribusi ilmiah dalam pengembangan metode pemodelan topik berbasis konteks pada teks terjemahan Al-Qur'an.
2. Mempermudah peneliti dan praktisi dalam memahami struktur tematik dan konteks isi Al-Qur'an secara sistematis.
3. Menjadi referensi bagi pengembangan aplikasi berbasis teks Al-Qur'an yang memerlukan fitur ekstraksi topik dan analisis tematik.
4. Mendukung peningkatan kualitas kajian tafsir dan studi Al-Qur'an melalui pendekatan teknologi informasi yang lebih modern dan akurat.

1.4 Sistematika Penulisan

Sistematika penulisan menjelaskan tentang berapa penjelasan singkat isi dari masing-masing bab dalam proposal tesis ini sebagai berikut:

BAB I PENDAHULUAN

Bab ini mengemukakan latar belakang masalah yang diteliti, identifikasi masalah, rumusan masalah, tujuan penelitian, batasan masalah, manfaat penelitian, metode penelitian dan sistematika penulisan.

BAB II LANDASAN TEORI DAN KERANGKA PEMIKIRAN

Bab ini mencakup beberapa sub bab antara lain : tinjauan pustaka, landasan teori seperti *Natural language Precessing* (NLP), *preprocesing text*, pemodelan topik dan kerangka pemikiran.

BAB III METODE PENELITIAN

Bab ini mencakup beberapa sub bab antara lain: analisis kebutuhan, sumber data, metode evaluasi, perancangan penelitian, dan teknik analisis.

BAB IV HASIL DAN PEMBAHASAN

Bab ini menjelaskan gambaran umum penelitian, variasi dan hasil *preprocessing* teks, analisis topik model CTM, analisis topik model BERTopic, penggabungan hasil topik model CTM dan BERTopic, hasil penelitian dan pembahasan yang telah dilaksanakan.

BAB V KESIMPULAN DAN SARAN

Bab ini menjabarkan kesimpulan yang didapat dari hasil penelitian dan saran-saran untuk pengembangan penelitian berikutnya.