

**ANALISIS PEMODELAN TOPIK PADA TEKS TERJEMAHAN
AL-QUR'AN BERBAHASA INDONESIA DENGAN METODE
*CORRELATED TOPIC MODELING (CTM) DAN BERTOPIC***

TESIS



OLEH:

**ASEP RIDWAN HIDAYAT
231012050036**

**PROGRAM STUDI TEKNIK INFORMATIKA S-2
PROGRAM PASCASARJANA
UNIVERSITAS PAMULANG
TANGERANG SELATAN
2026**

**ANALISIS PEMODELAN TOPIK PADA TEKS TERJEMAHAN
AL-QUR'AN BERBAHASA INDONESIA DENGAN METODE
CORRELATED TOPIC MODELING (CTM) DAN BERTOPIC**

TESIS

Diajukan Untuk Memenuhi Gelar Magister Komputer
Pada Program Studi Teknik Informatika S-2 Universitas Pamulang



OLEH:

**ASEP RIDWAN HIDAYAT
231012050036**

**PROGRAM STUDI TEKNIK INFORMATIKA S-2
PROGRAM PASCASARJANA
UNIVERSITAS PAMULANG
TANGERANG SELATAN
2026**

LEMBAR PERSETUJUAN TESIS

ANALISIS PEMODELAN TOPIK PADA TEKS TERJEMAHAN AL-QUR'AN BERBAHASA INDONESIA DENGAN *METODE CORRELATED TOPIC MODELING* (CTM) DAN BERTOPIC

Telah disetujui untuk disidangkan pada Program Studi Teknik Informatika S-2
Universitas Pamulang
Pada tanggal, 18 Juni 2026

Oleh:
ASEP RIDWAN HIDAYAT
231012050036

Tesis ini telah disetujui untuk diajukan ke Tim Penilai/Penguji oleh:

Pembimbing I

Pembimbing II

Dr. Sajarwo Anggai, S.ST., M.T.
NIDN. 0421108703

Dr. Arya Adhyaksa Waskita, S.Si., M.Si
NIDN. 0424047906

Mengetahui:

Kaprodi Teknik Informatika S-2

Dr. Sajarwo Anggai, S.ST., M.T.
NIDN. 0421108703

LEMBAR PENGESAHAN TESIS

ANALISIS PEMODELAN TOPIK PADA TEKS TERJEMAHAN AL- QUR'AN BERBAHASA INDONESIA DENGAN *METODE CORRELATED TOPIC MODELING* (CTM) DAN BERTOPIC

Telah dipertahankan di hadapan Dewan Penguji Program Pascasarjana
Universitas Pamulang
Pada tanggal, 25 Juli 2026

Oleh:
Asep Ridwan Hidayat
231012050036

Penguji I

Penguji II

Dr. Eng. Ahmad Musyafa, S.Kom, M.Kom.
NIDN. 0425018609

Dr. Ferhat Aziz, M.Sc.
NIDK. 8962120021

Pembimbing I

Pembimbing II

Dr. Sajarwo Anggai, S.ST., M.T.
NIDN. 0421108703

Dr. Arya Adhyaksa Waskita, S.Si., M.Si
NIDN. 0424047906

Disahkan:
Direktur Program Pascasarjana
Universitas Pamulang

Dr. Saiful Anwar, S.E., S.Pd., M.Pd.
NIDN . 0426048503

PERNYATAAN KEASLIAN TESIS

Nama : ASEP RIDWAN HIDAYAT
NIM : 231012050036
Program Studi : Teknik Informatika S-2
Judul Tesis : ANALISIS PEMODELAN TOPIK PADA TEKS TERJEMAHAN
AL-QUR'AN BERBAHASA INDONESIA DENGAN METODE
CORRELATED TOPIC MODELING (CTM) DAN BERTOPIC

Dengan ini saya menyatakan bahwa dalam tesis ini tidak terdapat karya yang pernah diajukan untuk memperoleh gelar kesarjanaan di suatu Perguruan Tinggi, dan sepanjang pengetahuan saya juga tidak terdapat karya atau pendapat yang pernah ditulis atau di terbitkan oleh orang lain, kecuali yang secara tertulis diacu dalam naskah tesis ini dan disebutkan dalam daftar pustaka.

Tangerang Selatan, 01 Agustus 2026

(Asep Ridwan Hidayat)

KATA PENGANTAR

Puji syukur Alhamdulillah kehadiran Allah SWT yang telah melimpahkan segala rahmat dan karunia-Nya, sehingga penulis dapat menyelesaikan Tesis yang merupakan salah satu persyaratan untuk menyelesaikan program studi strata satu (S2) pada program studi Teknik Informatika di Universitas Pamulang.

Penulis menyadari skripsi ini masih jauh dari sempurna. Karena itu, kritik dan saran akan senantiasa penulis terima dengan senang hati. Dengan segala keterbatasan, penulis menyadari pula bahwa Tesis ini tidak akan terwujud tanpa bantuan, bimbingan, dan dorongan dari berbagai pihak.

Dalam kesempatan ini, penulis ingin mengucapkan terima kasih kepada semua pihak yang telah membimbing dan memberikan masukan berupa kritik serta saran kepada penulis dalam penyusunan tugas akhir ini, oleh karena itu, penulis menyampaikan rasa hormat dan ungkapan terima kasih kepada:

1. Universitas Pamulang dan Program Studi Teknik Informatika S-2 yang telah melayani proses Akademik dan pembelajaran dengan baik dari mulai pendaftaran mahasiswa baru, pelaksanaan perkuliahan serta sampai penyusunantugas akhir.
 2. Dr. E. Nurzaman AM., M.M., M.Si. selaku Rektor Universitas Pamulang yang mengijinkan penulis untuk menempuh studi program S-2.
 3. Dr. Saiful Anwar, S.E., S.Pd., M.Pd. selaku Direktur Pasca sarjana Universitas Pamulang.
 4. Dr. Sajarwo Anggai, S.ST., M.T sebagai Ketua Program Studi Teknik Informatika S-2 Universitas Pamulang.
 5. Dr. Sajarwo Anggai, S.ST., M.T dan Dr. Arya Adhyaksa Waskita, S.Si., M.Si., selaku dosen pembimbing I dan Pembimbing II yang telah menyediakan waktu, tenaga dan pikiran untuk mengarahkan penulisan dan penyusunan tesis ini.
 6. Secara khusus, penulis menyampaikan rasa syukur dan terima kasih yang sebesar-besarnya kepada istri tercinta atas segala doa, kasih sayang, kesabaran, pengertian, serta dukungan yang tiada henti selama proses penyusunan tesis ini.
- Terima kasih telah menjadi sumber semangat dan kekuatan dalam setiap

langkah perjuangan akademik penulis. Kepada anak tercinta, terima kasih atas kebahagiaan, senyum, dan keceriaan yang selalu menjadi motivasi bagi penulis untuk terus berusaha memberikan yang terbaik. Penulis juga menyampaikan penghargaan dan rasa hormat kepada seluruh keluarga besar atas doa, perhatian, dukungan moral, serta kepercayaan yang senantiasa diberikan sehingga penulis mampu menyelesaikan tesis ini. Semoga Allah SWT senantiasa melimpahkan rahmat, kesehatan, keberkahan, dan kebahagiaan kepada seluruh keluarga sebagai balasan atas segala kebaikan, kasih sayang, dan pengorbanan yang telah diberikan.

7. Rekan-rekan mahasiswa Program Studi Teknik Informatika S-2 Universitas Pamulang yang telah banyak mendukung penulis dalam menyelesaikan tesis ini.
8. Semua Pihak yang terlibat dan tidak penulis sebutkan satu persatu.

Penulis berharap semoga langkah selanjutnya diridhoi oleh Allah SWT. Akhirnya sebagai penutup penulis berharap semoga laporan Tesis ini dapat memberikan manfaat bagi pembaca untuk mengembangkan ilmu pengetahuan, khususnya dibidang teknologi *Data Science*. Aamiin.

Tangerang Selatan, 01 Agustus 2026

(Asep Ridwan Hidayat)

**PERNYATAAN PERSETUJUAN PUBLIKASI TESIS UNTUK
KEPENTINGAN AKADEMIS**

Sebagai sivitas akademik Universitas Pamulang saya yang bertandatangan di bawah ini:

Nama : ASEP RIDWAN HIDAYAT

NIM : 231012050036

Program Studi : Teknik Informatika S-2

Judul Tesis : Tesis

Demi pengembangan ilmu pengetahuan, menyetujui untuk memberikan kepada Universitas Pamulang Hak Bebas Royalti Noneksklusif (*Non-exclusive Royalty-Free Right*) atas karya ilmiah saya yang berjudul:

JUDUL TESIS: ANALISIS PEMODELAN TOPIK PADA TEKS TERJEMAHAN AL-QUR'AN BERBAHASA INDONESIA DENGAN METODE *CORRELATED TOPIC MODELING* (CTM) DAN *BERTOPIC*

Beserta perangkat yang ada (jika diperlukan). Dengan Hak Bebas Royalti Noneksklusif ini Universitas Pamulang berhak menyimpan, mengalih media/formatkan, mengelola dalam bentuk pangkalan data (*database*), merawat dan mempublikasikan tesis saya selama tetap mencantumkan nama saya sebagai penulis/pencipta dan sebagai pemilik Hak Cipta.

Demikian pernyataan ini saya buat dengan sebenarnya.

Dibuat di Tangerang Selatan

Pada tanggal: 01 Agustus 2026

Yang menyatakan

(Asep Ridwan Hidayat)

ABSTRAK

Perkembangan metode pemrosesan bahasa alami (*Natural Language Processing*) membuka peluang baru dalam menganalisis struktur tematik pada korpus teks berskala besar, termasuk teks terjemahan Al-Qur'an berbahasa Indonesia. Penelitian ini bertujuan untuk menganalisis struktur tematik pada teks terjemahan Al-Qur'an berbahasa Indonesia menggunakan metode *Correlated Topic Model* (CTM) dan BERTopic. Tahapan penelitian meliputi preprocessing teks, evaluasi variasi preprocessing, optimasi parameter model, pemodelan topik, serta analisis hasil. Proses preprocessing dilakukan melalui *case folding*, *tokenization*, *stopword removal*, dan *stemming*. Hasil evaluasi menunjukkan bahwa metode *preprocessed advanced* memberikan keseimbangan terbaik dengan reduksi kosakata sebesar 83,75% dan preservasi makna sebesar 73,20%. Pada pemodelan CTM, optimasi jumlah topik menunjukkan bahwa nilai optimal berada pada $K=14$ berdasarkan kombinasi metrik *log-likelihood*, *topic diversity*, dan *composite score*. Model CTM mampu menghasilkan topik yang representatif dengan korelasi antar topik yang rendah, meskipun nilai koherensi internal masih berada pada tingkat sedang. Pada model BERTopic, parameter optimal diperoleh pada $\text{min_topic_size} = 25$ dengan nilai koherensi 0.5735 ($C_v > 0,5$) yang cukup baik. Nilai NPMI = 0.0530 yang bernilai positif menunjukkan bahwa terdapat asosiasi statistik yang bermakna antar kata dalam topik dan nilai UMass = -5.3257 merupakan nilai terbaik (paling mendekati nol) dibandingkan konfigurasi lainnya menunjukkan bahwa model memiliki konsistensi probabilistik yang baik terhadap distribusi dokumen. Hasil penggabungan topik antara CTM dan BERTopic menggunakan pendekatan *Jaccard similarity* menunjukkan adanya keterkaitan antar topik meskipun dengan tingkat kemiripan yang relatif rendah hingga sedang (0,08–0,25) sehingga diperoleh struktur tematik utama yang mencakup beberapa kategori besar seperti aqidah, eskatologi, syariah, muamalah, fenomena alam, sejarah, ilmu pengetahuan, dan aspek psikologis.

Kata kunci: Topic Modeling, *Correlated Topic Model* (CTM), BERTopic, *Natural Language Processing*, Terjemah Al-Qur'an Berbahasa Indonesia

ABSTRACT

The development of Natural Language Processing (NLP) methods has opened new opportunities for analyzing thematic structures in large-scale text corpora, including the Indonesian translation of the Qur'an. This study aims to analyze the thematic structure of the Indonesian translation of the Qur'an using the Correlated Topic Model (CTM) and BERTopic methods. The research stages include text preprocessing, evaluation of preprocessing variations, model parameter optimization, topic modeling, and result analysis. The preprocessing stage was carried out through case folding, tokenization, stopwords removal, and stemming. The evaluation results show that the advanced preprocessing method provided the best balance, with a vocabulary reduction of 83.75% and meaning preservation of 73.20%. In CTM modeling, topic number optimization showed that the optimal value was found at $K=14$, based on a combination of log-likelihood, topic diversity, and composite score metrics. The CTM model was able to produce representative topics with low inter-topic correlation, although the internal coherence value remained at a moderate level. In the BERTopic model, the optimal parameter was obtained at $\text{min_topic_size} = 25$, with a coherence value of 0.5735 ($C_v > 0.5$), which is fairly good. The NPMI value of 0.0530, being positive, indicates a meaningful statistical association between words within topics, while the UMass value of -5.3257—the best value (closest to zero) compared to other configurations—indicates that the model has good probabilistic consistency with respect to the document distribution. The results of merging topics between CTM and BERTopic using the Jaccard similarity approach revealed relationships between topics, although with a relatively low to moderate similarity level (0.08–0.25), resulting in a main thematic structure encompassing several broad categories such as aqidah (creed), eschatology, sharia, muamalah (social transactions), natural phenomena, history, science, and psychological aspects.

Keywords: *Topic Modeling, Correlated Topic Model (CTM), BERTopic, Natural Language Processing, Indonesian Translation of the Quran*

DAFTAR ISI

LEMBAR PERSETUJUAN TESIS.....	i
LEMBAR PENGESAHAN TESIS	ii
PERNYATAAN KEASLIAN TESIS	iii
KATA PENGANTAR.....	iv
PERNYATAAN PERSETUJUAN PUBLIKASI TESIS UNTUK KEPENTINGAN AKADEMIS.....	vi
ABSTRAK	vii
<i>ABSTRACT</i>	viii
DAFTAR ISI.....	ix
DAFTAR TABEL	xii
DAFTAR GAMBAR.....	xiii
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang	1
1.2 Permasalahan Penelitian	3
1.2.1 Identifikasi Masalah	3
1.2.2 Ruang Lingkup Masalah	4
1.2.3 Rumusan Masalah	4
1.3 Tujuan dan Manfaat Penelitian	5
1.3.1 Tujuan Penelitian.....	5
1.3.2 Manfaat Penelitian.....	5
1.4 Sistematika Penulisan	5
BAB II LANDASAN TEORI DAN KERANGKA PEMIKIRAN	7
2.1 Tinjauan Pustaka	7
2.2 Landasan Teori.....	25
2.2.1 Natural Language Processing (NLP).....	25
2.2.2 <i>Data Mining</i>	26
2.2.3 <i>Text Mining</i>	26
2.2.4 <i>Preprocessing Text</i>	27
2.3 Pemodelan Topik	28
2.3.1 BERT.....	29
2.3.2 <i>Correlated Topic Models (CTM)</i>	33

2.4 Evaluasi Model	36
2.5 Kerangka Pemikiran.....	37
BAB III METODELOGI.....	40
3.1 Analisis Kebutuhan	40
3.2 Sumber Data.....	40
3.3 Perancangan Penelitian	40
3.4 Teknik Analisis	43
3.4.1 Metode Analisis.....	43
3.4.2 <i>Tools</i> dan <i>Library</i> yang Digunakan.....	43
3.4.3 Tahapan Implementasi	44
3.5 Metode Evaluasi.....	44
3.5.1 Evaluasi Kuantitatif.....	44
3.5.2 Evaluasi Kualitatif.....	49
3.5.3 Penggabungan Akhir Model CTM dan BERTopic	50
BAB IV HASIL DAN PEMBAHASAN	52
4.1 Gambaran Umum Hasil Penelitian	52
4.2 Variasi dan Hasil Preprocessing Teks.....	52
4.2.1 <i>Preprocessing</i> Teks	52
4.2.2 Variasi Metode <i>Preprocessing</i>	56
4.2.3 Analisis Reduksi Token, Reduksi Kosakata, Preservasi Makna pada Variasi Preprocessing	58
4.2.4 Pemilihan Preprocessing Utama	59
4.3 Analisis Topik Model CTM.....	59
4.3.1 Optimasi Jumlah Topik	60
4.3.2 <i>Training</i> dan Analisa Hasil Pemodelan CTM.....	67
4.4 Analisis Topik Model BERTopic	73
4.4.1 Penentuan Uji Parameter Jumlah Minimal Dokumen.....	74
4.4.2 Analisis Metriks <i>Coherence</i>	75
4.4.3 Hasil pemodelan BERTopic.....	76
4.5 Penggabungan hasil topik model CTM dan BERTopic.....	83
4.5.1 Interpretasi Kata Kunci Topik	84
4.5.2 Distribusi Topik terhadap Dokumen	92
4.6 Implementasi Aplikasi	93
4.6.1 Arsitektur Sistem.....	94
4.6.2 Implementasi dashboard.....	95
4.6.3 Implementasi Preprocessing Teks	96

4.6.4 Implementasi pemodelan CTM.....	96
4.6.5 Implementasi Model BERTopic.....	99
4.6.6 Impelementasi Penggabungan Hasil Topik.....	101
BAB V KESIMPULAN DAN SARAN	104
5.1 Kesimpulan	104
5.2 Saran	106
DAFTAR PUSTAKA	107
LAMPIRAN.....	112

DAFTAR TABEL

Tabel 2. 1 Tinjauan Pustaka	10
Tabel 4. 1 Contoh Hasil <i>Case Folding</i>	53
Tabel 4. 2 Contoh Hasil <i>Stopword Removal</i>	53
Tabel 4. 3 Contoh Hasil <i>Tokenization</i>	54
Tabel 4. 4 Contoh <i>Punctuation Removal</i>	55
Tabel 4. 5 Contoh <i>Stemming</i> Dan <i>Lemmatization</i>	56
Tabel 4. 6 Tabel Variasi <i>Preprocessing</i> Dokumen.....	57
Tabel 4. 7 Analisa Reduksi Token, Reduksi Kosakata Dan Preservasi Makna....	58
Tabel 4. 8 Hasil Nilai Optimasi Topik	60
Tabel 4. 9 Nilai <i>Log-Likelihood</i> Pada Setiap Train Model	67
Tabel 4. 10 Hasil Topik CTM	68
Tabel 4. 11 Nilai Metrik Koherensi (C_V, Npmi,Uci, Dan Perplexity)	70
Tabel 4. 12 Contoh Distribusi Nilai Rata-Rata Probabilitas Surat Al-Fatihah	71
Tabel 4. 13 Nilai Cv, Npmi Dan Umass Pada Pengujian Min Topic Size.....	74
Tabel 4. 14 Hasil Topik Bertopik.....	79
Tabel 4. 15 Penggabungan Topik CTM dan Bertopik Dengan Nilai Similiarity..	83
Tabel 4. 16 Interpretasi Dari Hasil Topik	84

DAFTAR GAMBAR

Gambar 3. 1 Perancangan Penelitian	41
Gambar 4. 1 <i>Wordcloud Preprocessed Advance</i>	57
Gambar 4. 2 <i>Grafik Log-Likelihood Vs Number Of Topics</i>	61
Gambar 4. 3 <i>Grafik Coherence Vs Number Of Topics</i>	62
Gambar 4. 4 <i>Grafik Topic Diversity Vs Number Of Topics</i>	63
Gambar 4. 5 <i>Grafik Topic Quality Vs Number Of Topics</i>	64
Gambar 4. 6 <i>Grafik Composite Score Vs Number Of Topics</i>	65
Gambar 4. 7 <i>Grafik Normalized Score Vs Number Of Topics</i>	66
Gambar 4. 8 <i>Grafik CTM Topic Correlation Heatmap</i>	69
Gambar 4. 9 Contoh <i>Grafik Heatmap</i> Distitibusi 20 Surat Pertama.....	73
Gambar 4. 10 <i>Grafik Distribusi Topik Pada Dokumen</i>	76
Gambar 4. 11 <i>Grafik TOPIC WORD SCORES</i>	78
Gambar 4. 12 <i>Distribusi Topik Pada Surat Al-Fatihah, Al-Baqarah Dan Ali Imran</i>	93
Gambar 4. 13 <i>Arsitektur Sistem</i>	94
Gambar 4. 15 <i>Page Login Dan Dashboard System</i>	95
Gambar 4. 15 <i>Fitur Preprocessing</i>	96
Gambar 4. 16 <i>Implementasi Analisa Model Ctm Pada System</i>	97
Gambar 4. 17 <i>Implementasi Optimasi Nilai K Pada Model Ctm</i>	97
Gambar 4. 18 <i>Output Nilai Optimasi K Dan Grafik Nilai Dari Optimasi</i>	98
Gambar 4. 19 <i>Hasil Topik Model CTM</i>	99
Gambar 4. 20 <i>Implementasi Pemodelan Bertopic Pada Sistem</i>	100
Gambar 4. 21 <i>Hasil Topik Dengan Model Bertopic</i>	101
Gambar 4. 23 <i>Penggabungan Hasil Topik Model Ctm Dan Bertopic Dengan</i> <i>Jaccard Index</i>	102
Gambar 4. 24 <i>CTM Correlation Matrix</i>	103
Gambar 4. 25 <i>Topic Word Score</i>	103

BAB I

PENDAHULUAN

1.1 Latar Belakang

Pemodelan topik (*topic modeling*) merupakan pendekatan penting dalam analisis teks untuk menemukan tema tersembunyi dalam kumpulan dokumen besar secara otomatis (Blei et al., 2003a). Dalam konteks teks-teks keagamaan, seperti terjemahan Al-Qur'an, analisis ini menjadi tantangan tersendiri karena sifat bahasanya yang padat makna, kontekstual, dan mengandung makna teologis yang dalam (Habash, 2006). Terjemahan Al-Qur'an dalam bahasa Indonesia memiliki kekhasan struktur linguistik yang tidak hanya literal, tetapi juga interpretatif, sehingga pemodelan topik pada korpus ini membutuhkan pendekatan yang lebih kontekstual dan adaptif terhadap makna dalam teks.

Hingga saat ini, sebagian besar penelitian pemodelan topik pada teks keagamaan masih menggunakan pendekatan klasik seperti *Latent Dirichlet Allocation* (LDA) atau *Non-Negative Matrix Factorization* (NMF). yang mengandalkan representasi bag-of-words dan tidak secara eksplisit mempertimbangkan konteks kata dalam kalimat atau paragraf secara menyeluruh. Akibatnya, model-model tersebut cenderung menghasilkan topik yang kurang mampu mencerminkan keterkaitan semantik yang mendalam dalam teks keagamaan seperti Al-Qur'an.

Seiring perkembangan teknologi pemrosesan bahasa alami (NLP), model berbasis *transformer* seperti BERT (*Bidirectional Encoder Representations from Transformers*) membawa kemajuan signifikan dalam memahami konteks kata dalam kalimat. Model ini dilatih secara besar-besaran menggunakan miliaran kata, sehingga mampu menangkap nuansa makna dan hubungan antar-kata dalam berbagai konteks. *Correlated Topic Modeling* (CTM) dan BERTopic merupakan metode pemodelan topik modern yang memanfaatkan kekuatan representasi kontekstual dari BERT untuk menghasilkan topik yang lebih koheren dan bermakna. CTM sendiri mengembangkan pendekatan klasik dengan memodelkan korelasi antar topik menggunakan distribusi logistic normal, sehingga mampu

mengidentifikasi hubungan kompleks antar tema yang muncul dalam dokumen. (Blei & Lafferty, 2007a)

BERTopic menggabungkan representasi embedding dari BERT dengan teknik pengelompokan seperti HDBSCAN dan reduksi dimensi UMAP untuk menghasilkan topik-topik yang fleksibel dan dapat diinterpretasikan secara visual (Brawijaya et al., 2017). Sementara itu, CTM menyempurnakan pendekatan klasik dengan mengintegrasikan vektor dokumen dari BERT dan representasi *bag-of-words* dalam kerangka probabilistik dengan *variational autoencoder*, sehingga tetap mempertahankan interpretabilitas topik sekaligus menangkap korelasi antar topik secara lebih nyata. Kedua metode ini masih jarang digunakan dalam analisis teks religius, khususnya dalam bahasa Indonesia, yang membuka peluang penelitian dengan kontribusi bernilai tinggi.

Beberapa penelitian awal telah menerapkan BERTopic dan CTM pada berbagai jenis korpus, seperti ulasan produk, berita, dan dokumen akademik, dengan hasil yang menjanjikan. Misalnya, (Blei & Lafferty, n.d., 2007) menunjukkan bahwa CTM mampu menghasilkan nilai koherensi topik yang lebih tinggi dibanding metode lainnya seperti LDA. Di sisi lain, BERTopic mendapatkan perhatian karena kemampuannya mengidentifikasi topik secara dinamis dan mendalam, serta menyajikannya dalam bentuk visual interaktif. Namun, penerapan kedua metode ini pada korpus teks religius terutama teks terjemahan Al-Qur'an dalam bahasa Indonesia belum banyak digunakan.

Salah satu penelitian pada terjemah Al-Qur'an yaitu diantaranya "Pengelompokan Terjemah Al-Quran Departemen Agama menggunakan Metode Fuzzy C-Means", penelitian ini menggunakan algoritma *fuzzy c-means* (FCM) dan *vector space model* (VSM) untuk mengelompokkan terjemahan ayat berdasarkan kemiripan dan fokus pada *clustering* dengan *preprocessing* teks, pembobotan *tf-idf*, dan evaluasi kualitas klaster dengan *silhouette coefficient*. Hasil algoritma FCM menghasilkan nilai *clustering* terbaik dengan parameter tertentu dan algoritma ini secara umum mampu menemukan kelompok ayat yang serupa makna. Namun, karakteristik dimensi fitur tinggi dan kemiripan antar terjemah yang sedikit membuat kinerja FCM kurang optimal (Havid Albar Purnomo & Abdurrachman Bachtiar, 2021)

Penelitian lainnya pada terjemah Al-Qur'an yaitu "Perbandingan Performa Klasifikasi Terjemahan Al-Quran Menggunakan Metode *Random Forest* dan *Long Short Term Memory* (LSTM)", penelitian ini berfokus pada klasifikasi terjemahan ayat Al-Quran ke dalam kategori tema menggunakan metode *supervised learning* *Random Forest* (RF) dan *deep learning* LSTM. Penelitian ini menggunakan dataset terjemahan dengan 6 topik dan menyajikan perbandingan kinerja klasifikasi dari dua metode tersebut. LSTM menunjukkan keunggulan pada kategori dakwah dengan nilai F1-Score lebih tinggi dibanding RF, terutama setelah dilakukan *preprocessing* dan tuning parameter secara optimal. Klasifikasi multi-label teks Al-Quran menjadi pendekatan yang penting untuk mempermudah pemahaman isi Al-Quran secara tematik (Aftari et al., 2024).

Adapun penelitian ini selain dari metode yang lebih kontekstual dengan metode CTM dan Bertopic juga terletak pada kebutuhan untuk memahami kandungan makna dalam teks Al-Qur'an secara lebih terstruktur dan otomatis, sehingga dapat dimanfaatkan dalam berbagai keperluan seperti pembelajaran tematik, pengembangan sistem pencarian ayat berbasis tema, atau analisis linguistik keislaman. Pemodelan topik yang baik pada teks terjemahan Al-Qur'an dapat membantu masyarakat maupun akademisi dalam memahami dan mengeksplorasi tema-tema utama dalam Al-Qur'an secara efisien dan sistematis.

Dengan latar belakang tersebut, penelitian ini berupaya memberikan kontribusi dalam pengembangan pendekatan NLP kontekstual terhadap teks keagamaan berbahasa Indonesia, dengan menguji efektivitas BERTopic dan CTM pada teks terjemahan Al-Qur'an. Keunikan pendekatan ini terletak pada penggunaan dua metode berbasis BERT yang masih relatif baru dalam domain NLP religius, menjadikannya sebagai salah satu bentuk kebaruan (*novelty*) dalam penelitian teks keislaman digital masa kini.

1.2 Permasalahan Penelitian

1.2.1 Identifikasi Masalah

Berdasarkan latar belakang masalah di atas, identifikasi masalah dalam penelitian ini adalah sebagai berikut:

1. Teks terjemahan Al-Qur'an memiliki kompleksitas linguistik yang tinggi, sehingga menyulitkan model dalam menangkap makna semantik secara akurat.
2. Metode CTM dan BERTopic memiliki keterbatasan yang berbeda, baik dari sisi performa, komputasi, maupun interpretabilitas hasil topik.
3. Belum ada perbandingan yang jelas mengenai kelebihan dan kekurangan metode CTM dan BERTopic dalam pemodelan topik teks terjemahan Al-Qur'an.

1.2.2 Ruang Lingkup Masalah

Berdasarkan beberapa pokok permasalahan yang telah diuraikan pada identifikasi masalah di atas, maka penelitian dibatasi pada:

1. Penelitian ini hanya membahas pemodelan topik pada teks terjemahan Al-Qur'an berbahasa Indonesia, tidak pada teks asli bahasa Arab.
2. Fokus analisis terbatas pada dua metode pemodelan topik, yaitu *Correlated Topic Modeling* (CTM) dan BERTopic.
3. Evaluasi dilakukan berdasarkan kualitas topik yang dihasilkan dan akurasi model menggunakan metrik koherensi topik seperti C_V dan UMass.

1.2.3 Rumusan Masalah

Berdasarkan identifikasi masalah di atas maka dapat dirumuskan masalah yaitu:

1. Bagaimana membangun model *Correlated Topic Modeling* (CTM) dan BERTopic dalam pembentukan topik pada teks terjemahan Al-Qur'an berbahasa Indonesia?
2. Bagaimana mengukur kualitas dan akurasi topik yang dihasilkan oleh *Correlated Topic Modeling* (CTM) dan BERTopic berdasarkan metrik koherensi?
3. Bagaimana menginterpretasikan dan mengelompokan tema topik yang dihasilkan dari kedua metode dalam konteks terjemah Al-Qur'an?

4. Apa tema utama yang terbentuk dari hasil topik metode *Correlated Topic Modeling* (CTM) dan BERTopic pada terjemahan Al-Qur'an berbahasa Indonesia?

1.3 Tujuan dan Manfaat Penelitian

1.3.1 Tujuan Penelitian

Adapun tujuan penulis melakukan penelitian ini adalah sebagai berikut:

1. Menganalisis efektivitas metode *Correlated Topic Modeling* (CTM) dan BERTopic dalam pemodelan topik pada teks terjemahan Al-Qur'an berbahasa Indonesia.
2. Mengidentifikasi kemampuan kedua metode dalam menangkap konteks dan tema utama yang terkandung dalam teks terjemahan Al-Qur'an.
3. Merumuskan metode evaluasi yang tepat untuk menilai kualitas topik yang dihasilkan dalam konteks kajian Al-Qur'an.

1.3.2 Manfaat Penelitian

Adapun manfaat yang diharapkan dalam penelitian ini sebagai berikut:

1. Memberikan kontribusi ilmiah dalam pengembangan metode pemodelan topik berbasis konteks pada teks terjemahan Al-Qur'an.
2. Mempermudah peneliti dan praktisi dalam memahami struktur tematik dan konteks isi Al-Qur'an secara sistematis.
3. Menjadi referensi bagi pengembangan aplikasi berbasis teks Al-Qur'an yang memerlukan fitur ekstraksi topik dan analisis tematik.
4. Mendukung peningkatan kualitas kajian tafsir dan studi Al-Qur'an melalui pendekatan teknologi informasi yang lebih modern dan akurat.

1.4 Sistematika Penulisan

Sistematika penulisan menjelaskan tentang berapa penjelasan singkat isi dari masing-masing bab dalam proposal tesis ini sebagai berikut:

BAB I PENDAHULUAN

Bab ini mengemukakan latar belakang masalah yang diteliti, identifikasi masalah, rumusan masalah, tujuan penelitian, batasan masalah, manfaat penelitian, metode penelitian dan sistematika penulisan.

BAB II LANDASAN TEORI DAN KERANGKA PEMIKIRAN

Bab ini mencakup beberapa sub bab antara lain : tinjauan pustaka, landasan teori seperti *Natural language Precessing* (NLP), *preprocesing text*, pemodelan topik dan kerangka pemikiran.

BAB III METODE PENELITIAN

Bab ini mencakup beberapa sub bab antara lain: analisis kebutuhan, sumber data, metode evaluasi, perancangan penelitian, dan teknik analisis.

BAB IV HASIL DAN PEMBAHASAN

Bab ini menjelaskan gambaran umum penelitian, variasi dan hasil *preprocessing* teks, analisis topik model CTM, analisis topik model BERTopic, penggabungan hasil topik model CTM dan BERTopic, hasil penelitian dan pembahasan yang telah dilaksanakan.

BAB V KESIMPULAN DAN SARAN

Bab ini menjabarkan kesimpulan yang didapat dari hasil penelitian dan saran-saran untuk pengembangan penelitian berikutnya.

BAB II

LANDASAN TEORI DAN KERANGKA PEMIKIRAN

2.1 Tinjauan Pustaka

Penelitian tentang topik model telah berkembang pesat seiring dengan kemajuan teknologi pemrosesan bahasa alami, terutama dengan kehadiran algoritma topik model seperti BERT, LDA dan *Corelated Topic Model* (CTM). Berikut beberapa penelitian terdahulu yang dapat dijadikan sebagai referensi pada penelitian ini.

Beberapa Penelitian sebelumnya seperti mengenai " *Text Mining Approach for Topic Modeling of Corpus Al Qur'an in Indonesian Translation* " Penelitian ini bertujuan mengaplikasikan pemodelan topik pada terjemahan Al-Qur'an berbahasa Indonesia untuk mengidentifikasi tema-tema utama yang berkaitan dengan kehidupan manusia. Metode pemodelan topik menggunakan pendekatan text mining dengan mempertimbangkan variabel moderator Makki dan Madani. Dengan analisis frekuensi kata untuk mengidentifikasi topik-topik utama seperti surga dan neraka, dunia dan akhirat, ilmu, amal, jihad, siang, malam, hidup, dan mati. Hasil penelitian dari semua pemodelan topik yang diuji berdasarkan jumlah kata, Surah Makki memberikan kontribusi lebih dari 50% dibandingkan dengan Surah Madani. Oleh karena itu, hasil penelitian ini dapat menjadi penguatan dari sudut pandang ilmu pengetahuan bahwa ayat-ayat Makki memang menekankan iman sebagai fondasi Islam. Hal ini dapat dilihat dari angka frekuensi yang menunjukkan kata-kata "hidup" (161), "neraka" (157), "surga" (105), "dunia" (127), "amal" yang sangat terkait dengan iman manusia selama hidup mereka di dunia dibahas lebih banyak dalam ayat-ayat Makki dibandingkan dengan Madani.(Rolliawati, 2024)

Penelitian lainnya mengenai "*Fine-Tuning Topic Modelling: A Coherence-Focused Analysis of Correlated Topic Models*". Penelitian ini meneliti pengaruh penyetelan hiperparameter terhadap kemampuan model untuk mengekstrak tema-tema yang bermakna dari korpus teks tak terstruktur. Hiperparameter kunci yang diperiksa meliputi laju pembelajaran (0,1, 0,01,

0,001), jumlah topik (3, 5, 7, 10), dan jumlah kata teratas (10, 20, 30, 40, 50, 80, 100). Dataset terdiri dari 100 artikel, dan hasilnya divisualisasikan menggunakan plot garis dan peta panas untuk menyoroti tren kinerja. Skor koherensi tertinggi, yaitu 0,803, dicapai dengan tiga topik dan 10 kata kunci. Penelitian ini menggarisbawahi pentingnya optimasi parameter dalam meningkatkan efektivitas CTM untuk aplikasi pemodelan topik. (Syahrial & Afidh, 2024)

Penelitian lainnya yaitu ” *Indonesian Hoax News Classification with Multilingual Transformer Model and BERTopic*” dengan tujuan penelitian mengklasifikasikan berita hoaks berbahasa Indonesia menggunakan model transformer multibahasa dan BERTopic. Metode pada penelitian ini menggabungkan model transformer multibahasa (XLM-R dan mBERT) dengan BERTopic untuk distribusi topik. Proses penelitian menganalisis berita hoaks berbahasa Indonesia untuk mengidentifikasi dan mengklasifikasikan topik-topik utama. Hasil dari penelitian ini berfokus pada klasifikasi berita hoaks Indonesia menggunakan model transformer multibahasa yang telah dilatih sebelumnya (XLM-R dan mBERT) yang dipadukan dengan model BERTopic sebagai model distribusi topik. Hasil menunjukkan bahwa metode yang diusulkan mengungguli model dasar dalam mengklasifikasikan berita palsu dalam bahasa sumber daya rendah (Indonesia) dengan hasil akurasi, presisi, recall, dan F1 masing-masing sebesar 0.9051, 0.9515, 0.8233, dan 0.8828. (Hutama & Suhartono, 2022)

Penelitian lainnya yaitu ” *Correlated Topic Modeling for Big Data with MapReduce*” penelitian ini Dalam jurnal ini membahas *Correlated Topic Modeling* (CTM) dengan algoritma EM variasional untuk Big Data diusulkan untuk mengekstrak topik-topik yang mewakili korpus. Pendekatan peneliti masih dalam tahap pengembangan dan bertujuan untuk meningkatkan kualitas topik laten, mengungkap topik-topik yang saling terkait dalam korpus, dan meningkatkan keandalan dan skalabilitas CTM dengan menggunakan EM variasional melalui kerangka kerja MapReduce. Ke depannya, penelitian ini berfokus pada peningkatan kinerja algoritma EM variasional. (Khine Oo & Aye Khine, 2018)

Penelitian lainnya mengenai "Pemodelan Topik Menggunakan Bertopic Dengan Keybert Untuk Ekstraksi Kata Kunci Sebagai *Topic Representation Tuning*", Salah satu metode yang digunakan untuk mendapatkan informasi dari cuitan twitter dengan lebih efisien adalah pemodelan topik. Pemodelan topik adalah sebuah metode untuk menemukan topik dari berbagai teks. Penelitian ini bertujuan untuk melakukan pemodelan topik pada tweet berbahasa Indonesia dengan menggunakan BERTopic dengan KeyBERT untuk ekstraksi kata kunci di setiap topik. KeyBERT akan menghasilkan kata kunci pada setiap kelompok topik dan akan digunakan oleh BERTopic untuk memperkaya hasil dari pemodelan topik. Dataset yang digunakan terdiri dari 10.000 tweets berbahasa Indonesia yang diambil dari akun Twitter @detikcom. Data dibagi menjadi 2 bagian, 8.000 tweets digunakan untuk data training dan 2.000 tweets digunakan untuk testing. Berdasarkan hasil pemodelan topik dengan BERTopic, diperoleh 50 total topik. Evaluasi Pemodelan Topik dilakukan menggunakan *coherence score*, diperoleh rata-rata 0.765 pada data training dan 0.675 pada data testing.

Herwinsyah dengan penelitiannya berjudul "Pemodelan Topik dalam Al-Qur'an Menggunakan Library Bertopic pada Model Bahasa Bert" menghasilkan penelitian Hasil penelitian adalah pemodelan topik menghasilkan 8 topik utama secara terperinci sebagai berikut; Topic 0 Al Quran dengan prosentase sebesar 6%, Topic 1 Aku (Allah) sebesar 6,5%, Topic 2 Langit 3,8%, Topic 3 Rasul 8%, Topic 4 Malaikat 12,5%, Topic 5 Wanita 5%, Topic 6 Neraka dengan prosentase 13%, serta Topic 7 Dibangkitkan sebesar 5,5%. Kata-kata tersebut dianggap sangat penting dalam mewakili topik-topik yang dihasilkan dan juga termasuk dalam kategori spiritual, moral, dan hukum.(Herwinsyah, 2023)

Peneliti lainnya berjudul "*Dynamic Topic Modelling Menggunakan BERTOPIC Dalam Pemilihan Presiden Tahun 2019*". Pada penelitian ini Peneliti mencoba menganalisis topik apa saja yang dihasilkan dari *tweet* yang diunggah oleh masyarakat menjelang Pemilu 2019 dan disertai dengan evolusi topiknya dari waktu ke waktu. Metode pemodelan topik yang akan digunakan kali ini adalah *BERTopic*. Metode pemodelan topik ini di dasari *sentence embedding* dengan salah satu jenis arsitektur *neural network* yaitu *Siamese network* sehingga metode ini dapat mengelompokkan kata sesuai konteksnya dalam suatu kalimat.

Metode *BERTopic* ini juga dilengkapi dengan fitur *Dynamic Topic Modelling* yaitu metode pemodelan topik yang dilanjutkan dengan mengevolusi setiap topiknya dari waktu ke waktu. Dengan data *tweet* yang ada, metode *BERTopic* mampu menghasilkan topik-topik yang ada dengan baik, hal ini dapat dibuktikan dengan hasil evaluasi dari nilai koheren yang dihasilkan yaitu 0.71. Topik yang dihasilkan juga relevan dan dapat dibuat narasinya.(Raihan, n.d.,2024)

Dari beberapa penelitian terdahulu yang dijadikan acuan pustaka, berikut ini diberikan review paper seperti pada tabel tabel 2.1 yang menyajikan ringkasan dari beberapa penelitian relevan atau penelitian sebelumnya.

Tabel 2. 1 Tinjauan Pustaka

No	Penulis	Tahun	Judul Penelitian	Model	Ulasan dan Hasil Pengujian
1	(Murugaraj et al., 2025)	2025	<i>Mining the Past: A Comparative Study of Classical and Neural Topic Models on Historical Newspaper Archives</i>	<i>BerTopic</i> , LDA, NMF, Top2Vec	BERTopic dengan embedding kontekstual menghasilkan kualitas topik yang lebih tinggi dan stabil dibandingkan LDA, NMF, dan Top2Vec.
2	Maria Sanchez, Paulo Reis	2022	<i>Comparative Analysis of LDA, LSA, and BerTopic for Text Mining</i>	LDA, LSA, <i>BerTopic</i>	BerTopic menunjukkan performa yang lebih tinggi dalam pemodelan topik untuk data pendek
3	(Bartolomeo, 2024)		<i>Exploring the Power of Topic Modeling Techniques in Analyzing Customer Reviews: A Comparative Analysis</i>		Penemuan peneliti menunjukkan bahwa BERTopic secara konsisten menghasilkan topik yang diekstraksi lebih bermakna dan mencapai hasil yang baik.

No	Penulis	Tahun	Judul Penelitian	Model	Ulasan dan Hasil Pengujian
3	Ling Zhang, Wei Huang	2020	<i>An Analysis of Legal Documents Using LDA, LSA, and BerTopic</i>	<i>LDA, LSA, BerTopic</i>	LDA dan BerTopic lebih cocok untuk dokumen legal dibandingkan dengan LSA
4	(Mustapha Hankar, 2025)	2025	<i>A comprehensive overview of topic modeling: Techniques, applications, and trends</i>	<i>CTM</i>	Review menyeluruh berbagai teknik topic modeling termasuk CTM, dengan aplikasi pada klasifikasi teks, analisis sentimen, dan pengambilan informasi.
5	K MSajjadul Islam, Ravi Teja Karri, Srujan Vegesna, Jiawei Wu, Praveen Madiraju	2025	<i>Documenting the Half-Century Evolution of Islamic Education Research: A Correlated Topic Modeling (CTM) Study of the Literature from 1970 to 2023</i>		Studi pada penelitian ini menunjukkan adanya 19 topik utama yang dikelompokkan ke dalam empat klaster: Konsep dan Metodologi Dasar, Isu Sosial, Pengajaran dan Pembelajaran, serta Sistem dan Pengaturan Pendidikan.
6	(Awaludin, 2025)	2025	<i>Pre-training is a Hot Topic: Correlated Document Embeddings Improve Topic Coherence</i>	<i>CTM,</i>	Penulis menemukan bahwa pendekatan peneliti menghasilkan topik yang lebih bermakna dan koheren daripada model topik kumpulan kata tradisional dan model neural

No	Penulis	Tahun	Judul Penelitian	Model	Ulasan dan Hasil Pengujian
					terkini. Pada hasil menunjukkan bahwa peningkatan model bahasa di masa mendatang akan menghasilkan model topik yang lebih baik
7	(Cheng, 2024)	2024	<i>A Corporate Financial Statement Fraud Model Based on Extracting Correlated Topic Features</i>	CTM	studi ini mengusulkan model topik berkorelasi tertimbang untuk membangun sistem deteksi kecurangan keuangan, memberikan solusi yang efektif dan dapat diterapkan untuk mendeteksi kecurangan laporan keuangan, dan sistem dapat mendeteksi kecurangan keuangan pada sejumlah besar dokumen tekstual. Studi ini mengevaluasi nomor topik terbaik berdasarkan metrik koherensi untuk mengekstrak fitur ringkas dengan menggunakan CTM tertimbang yang diusulkan. Hasilnya menunjukkan bahwa kombinasi metode

No	Penulis	Tahun	Judul Penelitian	Model	Ulasan dan Hasil Pengujian
					NPMI+CTM yang diusulkan dengan hutan acak memiliki kinerja terbaik.
8	Khine Oo & Aye Khine	2024	<i>Topic Extraction Of Crawled Documents Collection Using Correlated Topic Model In Mapreduce Framework</i>	CTM	Paper ini mengusulkan implementasi <i>Correlated Topic Model</i> (CTM) dengan algoritma <i>Variational Expectation Maximization</i> (EM) dalam kerangka kerja <i>MapReduce</i> pada platform <i>Hadoop</i> untuk mengatasi masalah skalabilitas dalam pemodelan topik pada koleksi dokumen besar yang dikumpulkan secara <i>crawling</i> . Implementasi ini diuji pada dataset dokumen penuh dari PLOS ONE, dengan evaluasi berdasarkan koherensi topik menggunakan metrik UCI dan UMass. Hasil menunjukkan bahwa <i>MapReduce</i> CTM memiliki performa koherensi topik yang sebanding dengan LDA, dengan

No	Penulis	Tahun	Judul Penelitian	Model	Ulasan dan Hasil Pengujian
					keunggulan sedikit pada skor UCI pada jumlah topik tertentu, meskipun waktu pelatihan <i>MapReduce</i> CTM lebih lama karena kompleksitas korelasi topik
9	Edward A. Fox, Chair, Xuan Wang, Yinlin Chen	2024	<i>Topic Modeling for Heterogeneous Digital Libraries: Tailored Approaches Using Large Language Models</i>	<i>BERTopic</i>	Peneliti menerapkan dan mengoptimalkan teknik pemodelan beberapa topik untuk mengungkap tema laten, termasuk LDA, <i>ProdLDA</i> , <i>NeuralLDA</i> , Model Topik Kontekstual, dan <i>BERTopic</i> . Penelitian ini juga mengintegrasikan Model Bahasa Besar (LLM), seperti GPT-4, menggunakan rekayasa prompt untuk menambah model topik tradisional, menyempurnakan dan menafsirkan outputnya tanpa menggantinya. Kerangka kerja ini diuji pada korpus besar metadata ETD, termasuk melalui pengujian awal pada subset kecil. Metrik kuantitatif dan

No	Penulis	Tahun	Judul Penelitian	Model	Ulasan dan Hasil Pengujian
					studi pengguna digunakan untuk mengevaluasi kinerja, dengan fokus pada kejelasan, akurasi, dan relevansi topik yang dihasilkan. Hasilnya menunjukkan peningkatan yang signifikan dalam koherensi topik dan <i>interpretabilitas</i>, dengan peserta studi pengguna menyoroti nilai representasi yang ditingkatkan. Temuan ini menggarisbawahi potensi menggabungkan prapemrosesan yang disesuaikan, pemodelan topik tingkat lanjut, dan penyempurnaan yang digerakkan oleh LLM untuk mewakili tema dengan lebih baik dalam koleksi kompleks seperti ETD, memberikan dasar untuk tugas hilir seperti pencarian, penelusuran, dan rekomendasi.
10	Majed Albarrak and Gabriele	2024	<i>U-BERTopic: An urgency-aware BERT-Topic</i>	<i>BERTopic</i>	Peneliti dalam jurnalnya menggunakan U-

No	Penulis	Tahun	Judul Penelitian	Model	Ulasan dan Hasil Pengujian
	Pergola, Arshad Jhumka		<i>modeling approach for detecting cyberSecurity issues via social media</i>		BERTopic, pendekatan pemodelan topik BERT untuk menyadari urgensi untuk mendeteksi masalah keamanan siber melalui media sosial, dengan mengintegrasikan analisis sentimen dengan pemodelan topik kontekstual seperti BERTopic. Peneliti membandingkan U-BERTopic dengan tiga teknik pemodelan topik lainnya menggunakan empat metrik evaluasi yang berbeda untuk pemodelan topik dan klasifikasi keamanan siber dengan menjalankan kumpulan data Twitter terkait keamanan siber tahun 2018. Hasil peneliti menunjukkan bahwa untuk pemodelan topik dan dalam pengaturan tertentu (misalnya, jumlah topik), U- BERTopic sering kali mengungguli semua teknik

No	Penulis	Tahun	Judul Penelitian	Model	Ulasan dan Hasil Pengujian
					pemodelan topik lainnya dan (ii) untuk klasifikasi serangan, U-BERTopic berkinerja lebih baik untuk beberapa serangan seperti identifikasi kerentanan dalam beberapa pengaturan.
11	Haya Alngari, Nahlah Algethami	2024	<i>Exploring the Effects of Pre-Processing Techniques on Topic Modeling of an Arabic News Article Data Set</i>	BERTopic, LDA, NMF	Penelitian ini menyelidiki dampak teknik pra-pemrosesan terhadap efektivitas algoritma pemodelan topik untuk teks Arab, dengan fokus pada perbandingan antara BERTopic, <i>Latent Dirichlet Allocation</i> (LDA), dan <i>Non-Negative Matrix Factorization</i> (NMF). Dengan menggunakan <i>Single-label Arabic News Article Data Set</i> (SANAD), yang mencakup 195.174 artikel berita Arab. Teknik pra-pemrosesan disempurnakan untuk meningkatkan kualitas data sebelum menerapkan

No	Penulis	Tahun	Judul Penelitian	Model	Ulasan dan Hasil Pengujian
					BERTopic, LDA, dan NMF, dan kinerjanya dinilai menggunakan metrik seperti koherensi topik dan keragaman. Koherensi diukur menggunakan <i>Normalized Pointwise Mutual Information</i> (NPMI). Hasilnya menunjukkan bahwa <i>stemmer Tashaphyne</i> secara signifikan meningkatkan kinerja LDA dan NMF. BERTopic, dioptimalkan dengan pra-pemrosesan dan bi-gram, mengungguli LDA dan NMF baik dalam koherensi maupun keragaman.
12	Zheng Fang, Yulan He, Rob Procter	2023	<i>CWTM: Leveraging Correlated Word Embeddings from BERT for Neural Topic Modeling</i>	Bert	Penelitian ini bertujuan mengembangkan model topik <i>neural</i> baru yang mengintegrasikan <i>embedding</i> kata kontekstual dari BERT, dengan metode <i>Correlated Word Topic Model</i> (CWTM) yang memanfaatkan <i>embedding</i> kata kontekstual dari

No	Penulis	Tahun	Judul Penelitian	Model	Ulasan dan Hasil Pengujian
					BERT tanpa menggunakan representasi <i>bag-of-words</i>. kesimpulan dari penelitian CWTM menghasilkan topik yang lebih koheren dan bermakna dibandingkan model topik sebelumnya, serta mampu menangani kata-kata yang tidak dikenal dalam dokumen baru
13	Maarten Grootendorst	2022	<i>BERTopic: Neural topic modeling with a class-based TF-IDF procedure</i>	BERTopic	Peneliti pada jurnal menggunakan model BERTopic yang memperluas proses ini dengan mengekstraksi representasi topik yang koheren melalui pengembangan variasi TF-IDF berbasis kelas. Lebih khusus lagi, BERTopic menghasilkan penyematan dokumen dengan model bahasa berbasis transformator yang telah dilatih sebelumnya, mengelompokkan penyematan ini, dan akhirnya, menghasilkan representasi topik

No	Penulis	Tahun	Judul Penelitian	Model	Ulasan dan Hasil Pengujian
					dengan prosedur TF-IDF berbasis kelas. BERTopic menghasilkan topik yang koheren dan tetap kompetitif di berbagai tolok ukur yang melibatkan model klasik dan yang mengikuti model yang lebih baru.
14	Bagas Raditya Nur Listyawan, Nanang Yudi Setiawan, Mochamad Chandra Saputra	2024	Topic Modelling Pada Aktivitas Pengembangan Perangkat Lunak Menggunakan BERTopic	Bertopic	BERTopic layak untuk pengelompokan topik aktivitas pengembangan perangkat lunak, dengan nilai <i>topic coherence</i> 0,625 dan <i>topic diversity</i> 0,828. Ada kekurangan pada <i>overlap</i> dan deteksi topik tertentu
15	Naishuai Zhang, Jimin Wang		<i>Topic Analysis of Digital Preservation Based on BERTopic</i>	BERTopic	BERTopic efektif menganalisis tren dan topik utama digital preservation, menemukan 24 topik utama, dan menyoroti tren penelitian terbaru.
16	Dini Aryani	2024	Pemodelan Topik Pemilu 2024 Menggunakan Metode BERTopic	BERTopic	BERTopic berhasil mengelompokkan isu-isu utama Pemilu 2024 dari data media sosial, dengan visualisasi topik yang jelas.

No	Penulis	Tahun	Judul Penelitian	Model	Ulasan dan Hasil Pengujian
17	Rama Pratama	2024	Pemodelan Topik Menggunakan BERTopic dengan KeyBERT untuk Ekstraksi Kata Kunci	BERTopic	Integrasi BERTopic dan KeyBERT meningkatkan representasi topik dan ekstraksi kata kunci pada data Twitter
18	Valentinus Roby Hananto	2023	<i>Implementation of Dynamic Topic Modeling to Discover Topic Evolution on Customer Reviews</i>	BERTopic	BERTopic efektif untuk <i>Dynamic Topic Modeling</i> , memantau evolusi topik dari waktu ke waktu pada ulasan pelanggan.
19	Metti Detricia Pratiwi', Ken Ditha Tania	2024	<i>Knowledge Discovery Through Topic Modeling on GoPartner User Reviews</i>	BERTopic	penelitian ini melakukan <i>knowledge discovery</i> melalui topik modeling pada review aplikasi <i>GoPartner</i> dengan menggunakan BERTopic, LDA, dan NMF, masing-masing metode tersebut memiliki pendekatan yang berbeda. Berdasarkan hasil penelitian dan kualitas topik yang dihasilkan, BERTopic dan LDA memiliki kualitas yang lebih baik dalam menganalisis review pengguna <i>GoPartner</i> .

No	Penulis	Tahun	Judul Penelitian	Model	Ulasan dan Hasil Pengujian
20	I Komang Tryana Mertayasaa, I Dewa Made Bayu Atmaja Darmawana	2022	Pemodelan Topik Pada Ulasan Hotel Menggunakan Metode BERTopic Dengan Prosedur c-TF-IDF	BERTopic	Pemodelan topik menggunakan metode BERTopic menghasilkan 78 topik dengan nilai koherensi topik sebesar 0,07287 dan keragaman topik sebesar 0,496154. Semakin sedikit jumlah topik yang dihasilkan, nilai koherensi topik dan keberagaman topik akan menurun.
21	Olusola Babalola, Bolanle Ojokoh, Olutayo Boyinbode	2024	<i>Comprehensive Evaluation of LDA, NMF, and BERTopic's Performance on News Headlines</i>	BERTopic	BERTopic dievaluasi pada judul berita, menunjukkan performa baik pada data pendek
22	Keiko Tanaka, Yuki Yamamoto	2023	<i>Analyzing Customer Reviews Using LDA, LSA, and BerTopic</i>	LDA, LSA, BerTopic	BerTopic menunjukkan keunggulan dalam kategori topik layanan pelanggan.
23	Springer, Cham	2024	<i>Comparison of LDA, NMF and BERTopic Topic Modeling Techniques on Amazon Product Review Dataset: A Case Study</i>	LDA, NMF, BerTopic	Dengan algoritma pemodelan topik, keluhan pengguna dapat dikelompokkan dan dibaca dalam kelompok. Dalam penelitian ini, <i>Latent Dirichlet allocation</i> (LDA), NMF (<i>Non-Negative Matrix Factorization</i>) dan algoritma BERTopic yang

No	Penulis	Tahun	Judul Penelitian	Model	Ulasan dan Hasil Pengujian
					diuji pada kumpulan data ulasan produk Amazon dibandingkan. Menurut hasil yang diperoleh, semua 3 algoritma berhasil dan berguna. Algoritma BERTopic menghasilkan hasil yang lebih bermakna daripada algoritma lain sesuai dengan metrik perhitungan konsistensi.
24	Herwinsyah	2023	Pemodelan Topik dalam Al-Qur'an Menggunakan Library Bertopic pada Model Bahasa Bert	<i>BerTopic</i>	Hasil penelitian adalah pemodelan topik menghasilkan 8 topik utama secara terperinci sebagai berikut; Topic 0 Al-Quran dengan prosentase sebesar 6%, Topic 1 Aku (Allah) sebesar 6,5%, Topic 2 Langit 3,8%, Topic 3 Rasul 8%, Topic 4 Malaikat 12,5%, Topic 5 Wanita 5%, Topic 6 Neraka dengan prosentase 13%, serta Topic 7 Dibangkitkan sebesar 5,5%. Kata-kata tersebut dianggap sangat penting dalam

No	Penulis	Tahun	Judul Penelitian	Model	Ulasan dan Hasil Pengujian
					mewakili topik-topik yang dihasilkan dan juga termasuk dalam kategori spiritual, moral, dan hukum.
25	Asma Cheddak, Tarek Ait Baha, Youssef Es-Saady, Mohamed El Hajji, Mohamed Baslam	2024	<i>BERTopic for Enhanced Idea Management and Topic Generation in Brainstorming Support Systems</i>	BERTopic	BERTopic meningkatkan manajemen ide dan generasi topik dalam sistem <i>brainstorming</i>
26	M Raihan	2024	<i>Dynamic Topic Modelling Menggunakan BERTOPIC Dalam Pemilihan Presiden Tahun 2019</i>	Bertopic	Peneliti mencoba menganalisis topik apa saja yang dihasilkan dari <i>tweet</i> yang diunggah oleh masyarakat menjelang Pemilu 2019. Dengan data <i>tweet</i> yang ada, metode <i>BERTopic</i> mampu menghasilkan topik-topik yang ada dengan baik, hal ini dapat dibuktikan dengan hasil evaluasi dari nilai koheren yang dihasilkan yaitu 0.71. Topik yang dihasilkan juga relevan dan dapat dibuat narasinya.
27	Dwi Ahmad	2023	Analisis Komparasi Pemodelan Topik	LDA Bertopik	Korpus pada penelitian yang digunakan adalah

No	Penulis	Tahun	Judul Penelitian	Model	Ulasan dan Hasil Pengujian
			Metode <i>Latent Dirichlet Allocation</i> (LDA) Dan Bertopic pada Berita Berbahasa Indonesia		7.836 artikel berita dari situs Tempo pada bulan Desember 2022 yang kemudian diolah dengan prapemrosesan yang berbeda-beda. Prapemrosesan menghasilkan 6 jenis korpus untuk tiap metode. Jadi pada metrik koherensi pertimbangan metode terbaik adalah BERTopic, pada metrik waktu pertimbangan metode terbaik adalah LDA.

2.2 Landasan Teori

Dalam landasan teori ini dituliskan teori-teori yang mendukung penelitian.

2.2.1 Natural Language Processing (NLP)

NLP adalah cabang ilmu komputer dan linguistik komputasional yang berfokus pada interaksi antara komputer dengan bahasa manusia secara alami. NLP bertujuan mengembangkan teknik dan algoritma untuk menangani, memahami, dan menghasilkan bahasa alami agar komputer dapat meniru cara manusia berkomunikasi (Prof & Tarumingkeng, 2024).

NLP mencakup modul-modul seperti pengenalan entitas bernama (*Named Entity Recognition*), analisis sentimen, *parsing* sintaksis, serta pembangkitan teks otomatis. Kemajuan terbaru dengan model-model berbasis transformer, seperti BERT dan GPT, telah meningkatkan kemampuan

pemahaman konteks yang kompleks dan kemampuan generasi bahasa alami (Dwiyoga Widianoro Mustafid Ridwan Sanjaya, 2024).

2.2.2 Data Mining

Data Mining adalah proses menemukan pola, hubungan, dan informasi berguna tersembunyi dari kumpulan data besar dan kompleks. Proses ini mencakup pengumpulan data, ekstraksi, analisis, dan penggunaan metode statistik, pembelajaran mesin, serta kecerdasan buatan untuk memahami data dan mendukung pengambilan keputusan. Data mining dapat digunakan untuk mengidentifikasi tren, melakukan klasifikasi, klustering, regresi, dan prediksi dalam berbagai bidang seperti bisnis, kedokteran, keuangan, dan ilmu sosial (Kiwasi Wororomi et al., 2024)

Data mining terdiri dari serangkaian tahapan, yaitu: pemilihan data, praproses, transformasi, penambangan pola, evaluasi, dan presentasi. Teknik utama dalam data mining meliputi klasifikasi (*classification*), pengelompokan (*clustering*), aturan asosiasi (*association rules*), regresi, dan deteksi anomali. (Kiwasi Wororomi et al., 2024).

2.2.3 Text Mining

Seiring berjalannya waktu dokumen berupa teks akan bertambah banyak. Banyaknya dokumen teks berasal dari berbagai sumber seperti dari paper, jurnal, berita, opini, email, dan lain-lain. Teknik yang berkembang untuk menggali dokumen teks salah satunya adalah *text mining*. Cara kerja *text mining* yaitu memproses pengambilan intisari dari sebuah dokumen teks sehingga didapatkan hasil yang berguna untuk tujuan tertentu. Hal ini sesuai dengan pengertian *text mining* menurut para ahli yaitu Ronen Feldman dan James Sanger (Sanger, 2007).

Text mining dapat didefinisikan secara luas sebagai suatu proses menggali informasi dimana seorang user berinteraksi dengan sekumpulan dokumen menggunakan tools analisis yang merupakan komponen-komponen dalam data mining yang salah satunya adalah kategorisasi. Dalam melakukan *text mining*, berikut adalah langkah- langkah yang harus di perhatikan (Ahmad, 2014).

1. Mengambil informasi dari data yang ada.
2. Mengidentifikasi informasi yang telah diperoleh.
3. Melakukan pemrosesan terhadap informasi yang diberikan oleh sebuah data teks.
4. Menganalisis pola yang didapatkan.
5. Mengelompokkannya sesuai dengan kategori.
6. Ekstrak informasi berharga dan menyimpannya kedalam database.

Text Mining berperan penting dalam Sentimen Analisis, Pemodelan Topik, dan lain- lain. Secara umum, terdapat beberapa proses yang perlu dijalankan dalam melakukan *Text Mining* contohnya untuk melakukan *Dynamic topic modelling*, yaitu sebagai berikut:

1. Pengambilan data dari penelitian terdahulu
2. Pemrosesan data atau *Preprocessing Data*.
3. Pemodelan data yang akan di proses secara berkala.
4. Visualisasi data dari hasil pemodelan yang telah dilakukan.

2.2.4 *Preprocessing Text*

Setelah pengumpulan data, langkah selanjutnya adalah melakukan *preprocessing*. Pada tahap ini akan dilakukan *preprocessing* pada dokumen-dokumen hasil dari scrapping yang akan dilakukan proses pemodelan topik. Hal ini bertujuan untuk mengurangi singkatan atau bentuk tidak beraturan pada dokumen yang nantinya akan mempersulit dalam proses analisa teks (T. Aksoy, 2020).

Tahapan *preprocessing* terdiri dari beberapa langkah yaitu diantaranya *case folding*, menambahkan titik pada akhir kalimat, menghapus simbol, tokenisasi, melakukan *stopwords*, dan *lemmatisasi*.

1. *Case Folding*

Case Folding merupakan salah satu bentuk *preprocessing text* yang sederhana dan sangat efektif meskipun sering diabaikan dalam penggunaannya (Salsabila, 2022). Tujuan utama dari *case folding* yaitu menyamaratakan penggunaan huruf kapital dengan mengubah semua

huruf menjadi lowercase semua. Selain itu, karakter selain huruf dihilangkan dan dianggap sebagai delimiter. Ada beberapa cara yang dapat digunakan dalam melakukan *case folding*. Pertama, mengubah text menjadi *lowercase*. Kedua, menghapus angka, simbol dan tanda baca. Dan yang terakhir menghapus *whitespace* atau karakter kosong (Tineges, 2021).

2. Tokenisasi

Tokenisasi adalah tahap untuk memisahkan teks yang berupa paragraf atau kalimat menjadi token-token berdasarkan tiap kata yang menyusunnya atau dengan kata lain, tokenisasi merupakan suatu proses pemisahan kata-kata dari suatu dokumen (Tineges, 2021).

3. Penghapusan *Stopwords*

Setelah melakukan proses tokenisasi, perlu adanya pembuangan atau *stopwords*. *Stopwords* biasanya terdiri dari kata konjungsi ataupun kata keterangan (Luo, 2021). Penghapusan *stopwords* juga bergantung terhadap kebutuhan penelitian yang dilakukan. Pada penelitian ini akan dilakukan proses dengan menambahkan *stopwords* ataupun tidak untuk mengamati hasil model yang diperoleh.

4. *Lemmatisasi*

Lemmatisasi merupakan proses transformasi untuk menemukan normalisasi pada sebuah kata. Proses ini merubah suatu kata menjadi kata dasarnya, sehingga dapat mengelompokkan kata-kata yang memiliki makna yang sama. Hal ini dilakukan agar data yang dihasilkan tidak terlalu besar dan tentunya dapat mengurangi noise yang ada pada data.

2.3 Pemodelan Topik

Pemodelan topik merupakan algoritma untuk menemukan tema utama yang berasal dari koleksi dokumen yang besar dan tidak terstruktur. Menurut David M. Blei (D. M. Blei, 2021), setiap dokumen dalam korpus mengandung

proporsi topik tersendiri dari topik-topik yang dibahas sesuai kata-kata yang terkandung didalamnya. Konsep *topic modelling* menurutnya terdiri dari entitas-entitas yaitu “kata”, “dokumen”, dan “*corpus*”. Kata dianggap sebagai unit dasar dari data diskrit dalam dokumen, di definisikan sebagai item dari kosa kata yang diberi indeks n untuk setiap kata unik pada dokumen. Sedangkan “dokumen” adalah susunan n kata-kata dan sebuah *corpus* adalah kumpulan dari N dokumen. Sementara topik adalah beberapa kata yang dapat menggambarkan sekumpulan dokumen yang dapat merepresentasikannya. Secara sederhana, setiap dokumen dalam korpus mempunyai topik-topik yang dibahas berdasarkan kata-kata yang terkandung di dalamnya (Rubayyi Alghamdi, 2015). *Topic modelling* di anggap sebagai teknik *Unsupervised Learning* karena tidak melakukan pelabelan pada data yang dilatih. *Unsupervised Learning* adalah penggunaan algoritma kecerdasan buatan atau *Artificial Intelligence* untuk mengidentifikasi pola dalam kumpulan data yang berisik titik data yang tidak diklasifikasikan atau diberi label. Contoh implementasi dari *Unsupervised Learning* salah satunya yaitu *clustering* yang mana merupakan bagian dari Topic Modelling (Snyder & Com, 2015).

Tujuan dari *topic modelling* adalah untuk mengungkap variabel laten yang membentuk makna dokumen dan korpus dengan membuat topik atau kumpulan kata dalam dokumen yang diamati (Alghamdi & Alfalqi, 2015). Metode yang umum digunakan untuk melakukan pendekatan topic modelling adalah *Latent Dirichlet Allocation*, *Latent Semantic Analysis* dan *Corelated Topic Model* (Snyder & Com, 2015).

2.3.1 BERT

Peneliti ahli dari Google AI mengembangkan model bahasa terlatih pada tahun 2018. Penemuan ini diberi nama BERT atau *Bidirectional Encoder Representasion From Transformer* (J. D. Google, 2018). Secara sederhana, teknik ini memanfaatkan *transformer*, sebuah mekanisme yang mempelajari hubungan kontekstual antara kata atau sub- kata dalam sebuah teks (A. Vaswani, 2023). Transformer menyertakan dua mekanisme terpisah yaitu:

2.3.1.1 *Encoder dan Decoder*

Encoder merupakan salah satu bagian dari arsitektur *Transformer* yang terdiri dari tumpukan 6 atau lebih lapisan identik. Setiap lapisan memiliki 2 sublapisan, yaitu lapisan *self-attention* dan *feed-forward neural network* (Geva et al., n.d.). Fungsi dari *self-attention* layer yaitu *encoder* membantu setiap node untuk fokus pada kata yang terlihat, serta mendapatkan konteks semantik dari kata tersebut. Lapisan *Self-attention* memungkinkan setiap posisi *encoder* menangani semua posisi lapisan sebelumnya dan posisi saat ini.

Decoder juga terdiri dari tumpukan 6 atau lebih lapisan identik. *Decoder* berguna untuk menghasilkan urutan output yang dapat diprediksi. Setiap lapisan terdiri dari dua sublapisan, yaitu *self-attention layer* dan *feed-forward neural network* (Geva et al., n.d.), tetapi diantara dua lapisan ini terdapat lapisan *attention layer* yang membantu node saat ini mendapatkan *key content* yang membutuhkan perhatian dengan cara melakukan *multi-head attention* dari output di *encoder* (Christopher D. Manning. 2009).

Dalam prosedur *BERTopic* yang akan digunakan dalam penelitian kali ini, kita akan menggunakan salah satu varian dari BERT yaitu, *Sentence – BERT* atau SBERT. (Reimers & Gurevych, 2019) . SBERT merupakan modifikasi dari jaringan *pretrained* BERT yang menggunakan struktur jaringan *siamese* sehingga dapat memperoleh *sentence embedding* yang bermakna secara semantik dan dapat dibandingkan menggunakan *cosine-similarity*.

2.3.1.2 *Dimensionality Reduction*

Salah satu hal yang terpenting pada *BERTopic* adalah mengurangi dimensi data yang dihasilkan saat melakukan proses “*Embedding*”. Biasanya data yang dihasilkan dari proses *embedding* setidaknya memiliki 384 dimensi, dan banyak dari algoritma “*Clustering*” kesulitan untuk memproses data yang memiliki dimensi terlalu tinggi (Reimers & Gurevych, 2019). Maka dari itu solusinya adalah dengan mengurangi data dengan “*Dimensionality Reduction*”, yaitu merubah data vektor yang memiliki dimensi tinggi menjadi dimensi yang lebih rendah sehingga data tersebut bisa diproses oleh algoritma *clustering* (Van Der Maaten et al., n.d.).

UMAP (*Uniform Manifold Approximation and Projection*) adalah teknik terbaru pembelajaran *manifold* untuk reduksi dimensi (McInnes et al., 2020). UMAP dibangun dari kerangka teoritis yang didasarkan pada geometri dan topologi aljabar Riemannian. Hasilnya adalah algoritma terukur praktis yang berlaku untuk data dunia nyata. Algoritma UMAP bersaing dengan t-SNE untuk kualitas visualisasi, dan bisa dibilang mempertahankan lebih banyak struktur global dengan kinerja waktu berjalan yang unggul. Selain itu, UMAP tidak memiliki keterbatasan komputasi dimensi embedding, membuatnya layak sebagai tujuan umum teknik pengurangan dimensi untuk machine learning.

2.3.1.3 *Clustering*

Clustering atau klasterisasi adalah metode pengelompokan data ke dalam beberapa *cluster* atau kelompok sehingga data dalam satu *cluster* memiliki tingkat kemiripan yang maksimum dan data antar *cluster* memiliki kemiripan yang minimum (Kumar, 2019). Dalam “*Topic Modelling*” *clustering* berguna untuk menglompokkan kata yang sebelumnya telah melewati tahap preprocessing sehingga terbentuk kelompok topik yang ada dalam suatu dokumen.

Metode *clustering* yang digunakan dalam penelitian ini adalah HDBSCAN (*Hierarchical Density Based Spatial Clustering of Application with Noise*) yang merupakan metode pengelompokan bertingkat atau hierarkis yang berbasis kepadatan yang telah ditingkatkan secara teoritis dan praktikal, memberikan hirarki pengelompokan dimana cabang yang disederhanakan dari kelompok yang signifikan dapat dibangun (Campello et al., n.d.). Untuk mendapatkan partisi “*flat*” yang hanya terdiri dari *cluster* paling signifikan (mungkin sesuai dengan ambang kepadatan yang berbeda), kami mengusulkan ukuran stabilitas *cluster* baru, memformalkan masalah memaksimalkan stabilitas keseluruhan *cluster* yang dipilih, dan merumuskan algoritma yang menghitung solusi optimal untuk masalah ini.

2.3.1.4 Class Based TF-IDF

Prosedur klasik TF - IDF menggabungkan dua statistik yaitu, “*Term Frequency*” dan “*Inverse Document Frequency*” (Joachims, n.d.). sehingga terbentuk rumus berikut:

$$W_{t,d} = tf_{t,d} \cdot \log\left(\frac{N}{df_t}\right) \quad (1)$$

Di mana:

$tf_{t,d}$ = Frekuensi kata t pada dokumen d

df_t = Jumlah dokumen yang mengandung kata t

N = Jumlah dokumen di sebuah korpus N

Di mana “*Term Frequency*” memodelkan frekuensi kata t dalam dokumen d dan “*Inverse Document Frequency*” mengukur berapa banyak informasi suatu istilah atau kata tersedia untuk dokumen dan dihitung dengan mengambil logaritma dari jumlah dokumen di sebuah korpus N dibagi dengan jumlah dokumen yang mengandung t .

Kemudian prosedur ini di generalisasikan ke dalam *cluster* dokumen. Pertama, semua dokumen dalam sebuah *cluster* diperlakukan sebagai satu dokumen hanya dengan menggabungkan dokumen. Kemudian, TF-IDF disesuaikan untuk representasi ini dengan menerjemahkan dokumen ke *cluster*, sehingga terbentuk rumus berikut:

$$W_{t,c} = tf_{t,c} \cdot \left(1 + \frac{A}{tf_t}\right) \quad (2)$$

Di mana:

$tf_{t,c}$ = Frekuensi kata t pada cluster c

tf_t = Frekuensi kata t pada semua cluster

A = Jumlah rata – rata kata per kelas A

Di mana “*Term Frequency*” memodelkan frekuensi kata t di kelas c atau dalam contoh ini. Disini, kelas c adalah kumpulan dokumen yang digabungkan menjadi satu dokumen dalam *cluster*. Kemudian, “*Inverse Document Frequency*” diganti dengan “*Inverse Class Frequency*” untuk mengukur berapa banyak informasi yang disediakan sebuah kata untuk suatu kelas. Itu dihitung dengan mengambil logaritma dari jumlah rata-rata kata per kelas A dibagi dengan frekuensi kata t di semua kelas. Untuk hanya menampilkan nilai positif, kami menambahkan satu ke pembagian dalam logaritma.

Dengan demikian, prosedur TF-IDF berbasis kelas ini memodelkan pentingnya kata-kata dalam kelompok, bukan dokumen individu. Hal ini memungkinkan kita untuk menghasilkan distribusi topik-kata untuk setiap kelompok dokumen. Terakhir, dengan menggabungkan perwakilan c -TF-IDF secara iteratif dari topik yang paling tidak umum dengan topik yang paling umum. Dengan demikian, kita dapat mengurangi jumlah topik menjadi nilai yang di tentukan oleh pengguna.

2.3.2 *Correlated Topic Models (CTM)*

Correlated Topic Models (CTM) adalah model topik yang mengatasi keterbatasan model topik sebelumnya seperti *Latent Dirichlet Allocation (LDA)*, terutama dalam hal asumsi independensi antar topik. CTM menggunakan distribusi normal logistik (*logistic normal distribution*) untuk memodelkan proporsi topik di dalam dokumen, sehingga memungkinkan adanya korelasi antara topik. Berbeda dengan LDA yang menggunakan distribusi *Dirichlet* yang mengasumsikan hampir independensi antar topik, CTM mengizinkan struktur kovariansi antar topik sehingga model ini lebih realistis dalam menangani koleksi dokumen yang memiliki topik-topik saling berkaitan. (Blei & Lafferty, 2007)

CTM dikembangkan sebagai perluasan LDA dengan mengganti prior distribusi Dirichlet pada proporsi topik θ dengan distribusi logistik-normal. Didefinisikan dengan mengambil vektor $\eta \sim N(\mu, \Sigma)$ dari distribusi Normal multivariat, kemudian ditransformasikan ke dalam simplex melalui fungsi *softmax*.

$$\theta_i = \frac{\exp(\eta_i)}{\sum_{j=1}^K \exp(\eta_j)} \quad (3)$$

Transformasi ini menghasilkan vektor probabilitas θ dengan total 1, di mana Σ memungkinkan adanya korelasi antar-topik. (Blei & Lafferty, 2007c)

Proses *Generate CTM*

1. Ambil $\eta d \sim N(\mu, \Sigma)$
2. Hitung $\theta d = \text{softmax}(\eta d)$
3. Untuk setiap k atau n , untuk memilih topik $z d, n \sim \text{Multinomial}(\theta d)$, untuk memilih kata $w d, n \sim \text{Multinomial}(\beta z d, n)$.


2.3.2.1 Inferensi Variasional dalam CTM

Berbeda dengan LDA, inferensi posterior pada CTM tidak dapat dilakukan secara langsung karena distribusi logistik-normal tidak konjugat dengan Multinomial. Oleh karena itu, digunakan metode *variational inference* dengan pendekatan *mean-field*.

Distribusi *variational* diasumsikan faktorisasi:

$$q(\eta, z) = \prod_i N(\eta_i \mid \lambda_i, \nu_i^2) \prod_n \text{Categorical}(z_n \mid \phi_n). \quad (4)$$

Untuk mengaproksimasi $\log \sum_i \exp(\eta_i)$ digunakan ekspansi Taylor dan parameter variational tambahan ζ . Optimisasi dilakukan melalui *coordinate ascent*, mirip dengan *Expectation-Maximization* (EM). (Blei & Lafferty, 2007)



Gambar 2.1 Probabilistic Graphical Model CTM

Pada gambar 2.1 diatas merupakan representasi *grafis probabilistik* (PGM) dari *Correlated Topic Model* (CTM), menunjukkan bahwa CTM menggunakan logistic normal distribution untuk menghasilkan distribusi topik per dokumen, bukan *Dirichlet* seperti pada LDA. Hal ini memungkinkan topik-topik memiliki korelasi (misalnya topik "ekonomi" sering muncul bersama topik "politik").



Gambar 2.2 Visualisasi Logistic Normal pada Simplex

Gambar 2.2 memperlihatkan contoh distribusi logistic normal pada simplex 2-dimensi (bentuk segitiga) yang menggambarkan kemungkinan distribusi topik dalam dokumen:

1. Kiri: Logistic normal dengan kovarians diagonal dan mean tidak nol. Distribusi menyebar secara seimbang di dalam simplex.
2. Tengah: Contoh korelasi negatif antara topik 1 dan topik 2. Artinya jika dokumen banyak mengandung topik 1, maka kecil kemungkinan mengandung topik 2.
3. Kanan: Contoh korelasi positif antara topik 1 dan topik 2. Jika dokumen banyak membahas topik 1, kemungkinan besar juga membahas topik 2.

2.4 Evaluasi Model

Evaluasi sebuah model penting dilakukan karena evaluasi model merupakan salah satu cara untuk melihat seberapa baik kinerja model. Dan juga dapat menjadi perbandingan model dengan model lainnya. Ada beberapa cara yang bisa dilakukan untuk mengevaluasi sebuah model contohnya, running time dan coherence score. (Wallach et al., n.d.)

Running time akan menilai seberapa cepat model dapat memprediksi topik dari sebuah dokumen atau data set. Penilaian ini menjadi penting karena pada penerapannya kecepatan sebuah model dalam memprediksi topik adalah hal yang sangat di pertimbangkan nantinya ketika model akan diaplikasikan pada sebuah program.

Selain kecepatan, ketepatan sebuah model juga menjadi hal yang sangat dipertimbangkan. Salah satu cara untuk mengukur ketepatan atau seberapa baik performa sebuah model “*Topic Modelling*” adalah dengan mengukur “*Topic Coherence*” dari model tersebut. (Mimno et al., n.d., 2011). Konsep dari topic coherence adalah menggabungkan sejumlah ukuran ke dalam kerangka kerja untuk mengevaluasi koherensi antara topik yang disimpulkan oleh sebuah model. Topic Coherence dapat dihitung dengan melakukan perbandingan antara pasangan kata-kata di dalam suatu topik tertentu yang dapat menghasilkan ukuran standar kualitas suatu topik, semakin tinggi nilai coherence akan semakin baik modelnya. (Mimno et al., n.d.-a). Terdapat dua tipe dalam menghitung coherence score yaitu. (Röder et al., 2015a) :

1. *Extrinsic UCI Measure*

$$SCORE_{UCI}(w_i, w_j) = \log \frac{p(w_i, w_j)}{p(w_i)p(w_j)} \quad (5)$$

Di mana:

$$p(w_i) = \frac{D_{corpus}(w_i)}{D_{corpus}} \text{ dan } p(w_i, w_j) = \frac{D_{corpus}(w_i, w_j)}{D_{corpus}}$$

2. *Intrinsic Umass Measure*

$$SCORE_{UMass}(w_i, w_j) = \log \frac{D(w_i, w_j) + 1}{D(w_j)} \quad (6)$$

Di mana:


D = Jumlah total dokumen dalam korpus

$D(w_i)$ = Jumlah total dokumen yang mengandung kata w_i

$D(w_i, w_j)$ = Jumlah total dokumen yang mengandung kata w_i dan w_j

2.5 Kerangka Pemikiran

Berikut ini adalah kerangka pemikiran berdasarkan kebutuhan pemahaman yang lebih sistematis terhadap tema-tema yang terkandung dalam teks terjemahan Al-Qur'an. Upaya untuk mengekstraksi tema-tema tersebut secara otomatis menjadi penting dalam era digital saat ini, khususnya dengan pendekatan NLP. Oleh karena itu, penelitian ini memanfaatkan metode pemodelan topik modern, yaitu *Correlated Topic Model* (CTM) dan BERTopic, untuk mengidentifikasi dan menganalisis topik-topik laten dalam teks terjemah Al-Qur'an Bahasa Indonesia. Kerangka pemikiran penelitian sebagai berikut.



Gambar 2. 3 Kerangka Pemikiran

Diagram kerangka pemikiran yang disusun menggambarkan alur berpikir ilmiah mulai dari identifikasi masalah, hingga ke proses interpretasi hasil. Proses dimulai dengan pengumpulan data dari situs web resmi Al-Qur'an departement agama di <https://quran.kemenag.go.id/> dan untuk akses download referensi terjemahnya diarahkan ke <https://pustakalajnah.kemenag.go.id/> sebagai pustaka yang disediakan dari hasil penelitian naskah dan unduhan terjemah dengan

beberapa versi terbaru yang disusun dalam format .doc atau pdf. Dokumen ini kemudian melalui tahap preprocessing data diconvert menjadi format csv untuk dipisahkan menjadi kolom surat, ayat, dan teks yang berisi terjemah. kemudian preprosesing normalisasi huruf, penghilangan stopwords, dan tokenisasi, untuk menyiapkannya dalam bentuk yang layak dianalisis dengan pemrograman mesin

Tahap krusial berikutnya adalah representasi teks, yaitu cara mengubah teks menjadi bentuk numerik. Pada metode CTM, representasi dilakukan melalui gabungan antara *Bag-of-Words* (BoW)—yang menangkap frekuensi kata—dan BERT embedding—yang menangkap makna kontekstual dari kalimat (Bianchi et al., 2021). Sementara itu, pada BERTopic, representasi teks mengandalkan sentence embedding dari model transformer (seperti *Sentence-BERT*), yang kemudian digunakan dalam proses clustering untuk membentuk topik-topik berdasarkan kedekatan semantik antar kalimat.(Grootendorst, 2022).

Perbedaan mendasar antara kedua pendekatan ini terletak pada metode pemodelan topik itu sendiri. CTM membangun model topik secara probabilistik, menghasilkan distribusi topik per dokumen atau ayat, yang mencerminkan campuran tema dalam setiap ayat. Sementara itu, BERTopic membentuk topik melalui clustering, di mana setiap kelompok dokumen dikaitkan dengan topik tertentu berdasarkan kedekatan vektor representasi, lalu diekstraksi kata kuncinya dengan pendekatan class-based TF-IDF (c-TF-IDF). Pendekatan ini memungkinkan interpretasi topik yang lebih eksplisit dan mudah dibaca oleh manusia.(Grootendorst, 2022).

Pada tahap evaluasi, digunakan dua pendekatan utama: evaluasi kuantitatif, melalui metrik *topic coherence* (seperti C_V), dan evaluasi kualitatif, melalui interpretasi manusia terhadap kata-kata kunci dalam topik yang dihasilkan. Pendekatan ini digunakan untuk menilai sejauh mana model menghasilkan topik yang bermakna dan relevan terhadap konteks keislaman yang terkandung dalam Al-Qur'an.

BAB III

METODELOGI

3.1 Analisis Kebutuhan

Penelitian ini dilatarbelakangi oleh kebutuhan untuk memahami struktur tematik dalam teks terjemahan Al-Qur'an berbahasa Indonesia, yang merupakan representasi dari teks sumber yang sangat kompleks, mendalam, dan penuh dimensi makna. Penemuan topik secara otomatis melalui pemodelan topik berbasis *Neural Topic Model* (NLP) dapat menjadi alat bantu eksploratif bagi peneliti, pendidik, dan masyarakat luas dalam memahami cakupan pesan-pesan dalam Al-Qur'an.

3.2 Sumber Data

Data yang digunakan dalam penelitian ini adalah teks terjemahan Al-Qur'an dalam Bahasa Indonesia, yang diperoleh dari sumber kementerian Agama Republik Indonesia (Kemenag RI) di <https://quran.kemenag.go.id/> dan untuk akses download referensi terjemahannya diarahkan ke <https://pustakalajnah.kemenag.go.id/> dengan versi Terjemahan Al-Quran_v161122 dalam format file dokumen persurat sebanyak 114 file.


File data yang didapat kemudian dirubah format nya menjadi csv kemudian dijadikan beberapa format kolom. Yaitu kolom surat, kolom ayat dan kolom teks (terjemahan ayat dalam Bahasa Indonesia). Selanjutnya data dijadikan satu file csv dari 114 file untuk diproses penelitian.

Data Terjemahan Al-Qur'an ini dipilih karena merupakan hasil terjemahan resmi departemen Agama Indonesia, sudah melalui tahapan penerjemahan dan mewakili penterjemahan Al-Qur'an secara keseluruhan dan utuh.

3.3 Perancangan Penelitian

Perancangan penelitian ini dilakukan melalui pendekatan kuantitatif-komputasional yang bertujuan untuk mengevaluasi dan membandingkan performa dua pendekatan model topik berbasis representasi semantik, yakni *Correlated Topic Model* (CTM) dan BERTopic, terhadap dataset terjemahan Al-

Qur'an dalam Bahasa Indonesia. berikut diagram alir penelitian, langkah-langkah pada penelitian ini sebagai berikut:



Gambar 3. 1 Perancangan Penelitian

Dari diagram perancangan penelitian diatas langkah-langkah perancangan penelitian dapat dijelaskan seperti berikut:

1. Pengumpulan dan praproses dataset yang digunakan berupa teks terjemahan Al-Qur'an Bahasa Indonesia yang bersumber dari situs departemen agama republik Indonesia.
2. *Preprocessing* mencakup *cleaning*, *tokenization*, *lemmatization*, penghapusan kata-kata umum (*stopwords*) *lemmatization* dan *stemming*.
3. Pengujian *preprocessing* dengan *token reduction*, *vocabulary reduction* dan *preservation rate*.
4. Training dan Evaluasi Model, membangun dan melatih model CTM dan BERTopic secara terpisah.
5. Pengujian nilai optimasi parameter K dengan nilai *Log likelihood*, *Coherence*, *Topic Diversity*, dan *Topic Quality*.
6. untuk BERTopic digunakan embedding transformer (BERT atau *SentenceTransformer*) yang digabungkan dengan teknik clustering HDBSCAN dan reduksi dimensi UMAP.
7. Pengujian parameter topik size dengan minimal size 5, 10, 15, 20, 25 dan 30.
8. Evaluasi model berdasarkan nilai Cv, *Coherence Score* dan *Diversity Score*.
9. Training dan Evaluasi Model menggunakan optimasi k dan parameter minimal size dan melatih model CTM dan BERTopic.
10. Menggabungkan nilai hasil topik CTM dan BERTopic dengan menggunakan metode Jackard Similiarity.
11. Mengevaluasi hasil model berdasarkan *Coherence Score* dan *Diversity Score*, Visualisasi interaktif topik, Interpretabilitas dan relevansi topik terhadap konteks Al-Qur'an.
12. Penilaian mendalam atas keunggulan semantik antar model dengan pendekatan komparatif.
13. Penyajian visualisasi topik yang dapat digunakan sebagai alat bantu edukasi keislaman berbasis teknologi.

3.4 Teknik Analisis

Teknis analisis dilakukan secara bertahap dengan pendekatan berbasis bahasa Python dan pustaka NLP modern. Detail teknis dijelaskan sebagai berikut:

3.4.1 Metode Analisis

Metode analisis yang digunakan adalah dua algoritma pemodelan topik utama yaitu:

1. *Correlated Topic Model* (CTM)

Secara matematis CTM memodelkan distribusi topik dalam dokumen menggunakan model *Gaussian logit-normal* sebagai pengganti distribusi *Dirichlet* pada LDA. Ini membuat CTM menangkap korelasi antar topik melalui parameter kovarians dari distribusi *multivariat Gaussian*. Rumus inti dari model ini:

$$\theta_d \sim \text{LogisticNormal}(\mu, \Sigma) \quad (7)$$

Di mana:

θ_d = distribusi topik dokumen d

μ = mean dan Σ adalah matriks kovarians untuk korelasi topik.

2. Bertopic

BERTopic menggunakan representasi *embedding* kata/konteks berdasarkan model *transformer* (seperti BERT) dan klusterisasi berbasis densitas (misalnya HDBSCAN) untuk menghasilkan topik. Metode ini dianalisis dengan pengukuran kualitas topik seperti *coherence score* (misalnya Cv) dan interpretasi topik berdasarkan distribusi kata dalam *cluster*.

3.4.2 Tools dan Library yang Digunakan

Bahasa pemrograman yang digunakan Python 3.10 dengan menggunakan *Framework* Jupyter Notebook dan Google Colab. Library utama

yang digunakan *transformers*, *sentence-transformers*, *ctm*, *bertopic nltk*, *spacy*, *gensim*, *pandas*, *scikit-learn*. Untuk Visualisasi datanya menggunakan library *pyLDAvis*, *plotly*, *matplotlib*.

3.4.3 Tahapan Implementasi

Beberapa tahapan implelementasi yang dilakukan dari praproses data yaitu membersihkan tanda baca, angka, stopwords, dan *lemmatization*. dilanjutkan dengan Embedding menggunakan *pretrained* BERT/DistilBERT, untuk Pelatihan Model CTM menggunakan kombinasi *BoW*, *Correlated embeddings*. BERTopic menggunakan *transformer*, *UMAP* dan HDBSCAN. untuk evaluasi menggunakan *coherence*, intra/inter-topic distance, serta analisis kualitatif, Visualisasi dengan Interaktif topik via *plotly* dan *wordcloud* untuk interpretasi makna.

3.5 Metode Evaluasi

Evaluasi dalam penelitian ini dilakukan untuk mengukur kualitas dan efektivitas model topik yang dihasilkan oleh CTM dan BERTopic dalam menggambarkan struktur tematik dari teks terjemahan Al-Qur'an. Evaluasi dilakukan melalui pendekatan kuantitatif dan kualitatif, yang terdiri dari beberapa metrik berikut:

3.5.1 Evaluasi Kuantitatif

Beberapa evaluasi kualitatif yang bisa dijadikan parameter penilaian dari ouput data yang diperoleh yaitu :

3.5.1.1 Metode Evaluasi Preprocessing

Pada tahap preprocessing, dilakukan evaluasi untuk mengukur efektivitas pembersihan data teks melalui tiga metrik utama, yaitu:

1. Token *Reduction*

Mengukur persentase pengurangan jumlah token setelah preprocessing. (Röder et al., 2015b).

$$Token\ Reduction(\%) = \frac{T_{before} - T_{after}}{T_{before}} \times 100 \quad (7)$$

Di mana :

T_{before} = Jumlah Token sebelum preprocessing

T_{after} = Jumlah Token setelah preprocessing

2. Vocabulary Reduction (%)

Mengukur seberapa banyak kosakata unik yang berhasil direduksi.

$$Vocabulary\ Reduction(\%) = \frac{V_{before} - V_{after}}{V_{before}} \times 100 \quad (8)$$

Di mana :

V_{before} = Jumlah kata unik sebelum preprocessing

V_{after} = Jumlah kata unik setelah preprocessing

3. Preservation Rate (%)

Preservation Rate (Preservasi makna) diukur menggunakan *average preservation rate*, yang mengevaluasi keberlangsungan kemunculan istilah kunci teologis setelah *preprocessing* dan mengukur seberapa banyak informasi yang tetap dipertahankan. Berikut rumus dari *preservation rate*

$$Preservation\ Rate\ (\%) = \frac{T_{after}}{T_{before}} \times 100 \quad (9)$$

Di mana:

T_{before} = Jumlah Token sebelum preprocessing

T_{after} = Jumlah Token setelah preprocessing.

3.5.1.2 Evaluasi Optimasi Jumlah Topik CTM

Pada tahap optimasi jumlah topik K pada model CTM dilakukan untuk mengukur nilai K optimal sebagai parameter pada model CTM dengan beberapa nilai sebagai berikut:

1. **Log-Likelihood (LL)**

Nilai yang didapatkan untuk mengukur seberapa baik model menjelaskan data dimana Semakin tinggi nilai LL model semakin baik.(Blei et al., 2003b)

$$LL = \sum_{d=1}^D \log P(w_d|\theta_d) \quad (10)$$

Di mana:

D = total seluruh dokumen

d = indeks dokumen

w_d = kata dalam dokumen ke -d

θ_d = distribusi topik dokumen

2. **Perplexity**

Nilai yang didapatkan untuk mengukur kemampuan prediksi model.

$$Perplexity = \exp\left(-\frac{\sum_d \log P(w_d)}{\sum_d N_d}\right) \quad (11)$$

Di mana:

w_d = kumpulan kata dalam dokumen

d = dokumen

N_d = jumlah kata dalam dokumen d

3. **Topic Coherence Score**

Topic coherence mengukur seberapa masuk akal dan koheren kumpulan kata-kata dalam satu topik. Semakin tinggi nilai koherensinya, semakin topik tersebut mencerminkan makna yang nyata dalam konteks bahasa. (Röder et al., 2015b)

Beberapa varian yang digunakan:

- a. UMass menggunakan *co-occurrence* dalam dokumen yang sama. Cocok untuk model berbasis probabilistik.

Rumus yang digunakan:

$$UMass(w_i, w_j) = \log \frac{D(w_i, w_j) + \epsilon}{D(w_j)} \quad (12)$$

Di mana :

$D(w_i, w_j)$ = Jumlah total dokumen yang mengandung kata w_i dan w_j

$D(w_j)$ = Jumlah total dokumen yang mengandung kata w_j

ϵ = adalah konstanta kecil untuk menghindari pembagian dengan nol.

UMass coherence dihitung untuk pasangan kata dalam topik yang terurut. Nilai yang dihasilkan biasanya negatif, dan semakin mendekati nol, maka topik semakin koheren. (Mimno et al., n.d.-b)

- b. CV (C_v) menggunakan *cosine similarity* dengan pembobotan PPMI (*Positive Pointwise Mutual Information*), PPMI mengukur kekuatan asosiasi antara dua kata berdasarkan probabilitas kemunculan bersama dalam jendela geser pada korpus. Rumus PPMI:

$$PPMI(w_i, w_j) = \max(0, \log \frac{P(w_i, w_j)}{P(w_i)P(w_j)}) \quad (13)$$

Di mana:

$P(w_i, w_j)$ = probabilitas kemunculan bersama kata w_i dan w_j dalam korpus.

$P(w_i)$ dan $P(w_j)$ = probabilitas kemunculan masing-masing kata. (Röder et al., 2015c)

- c. NPMI (*Normalized Pointwise Mutual Information*) adalah metrik untuk mengukur asosiasi antara dua kata dalam korpus dengan menormalkan nilai PMI sehingga berada di rentang $[-1, 1]$. NPMI digunakan dalam perhitungan coherence C_V untuk mendapatkan evaluasi kualitas topik yang lebih stabil. Rumus yang digunakan:

$$NPMI(w_i, w_j) = \frac{\log \frac{P(w_i, w_j)}{P(w_i)P(w_j)}}{-\log P(w_i, w_j)} \quad (14)$$

Di mana:

$P(w_i, w_j)$ = probabilitas kemunculan bersama kata w_i dan w_j dalam korpus

$P(w_i)$ dan $P(w_j)$ = probabilitas kemunculan masing-masing kata. (Röder et al., 2015c)

4. *Topic Diversity Score*

Mengukur seberapa unik kumpulan kata yang muncul di setiap topik. Skor yang tinggi menunjukkan bahwa model menghasilkan topik-topik yang saling berbeda dan tidak terlalu tumpang tindih.

Formula umum:

$$Topic\ Diversity = \frac{Jumlah\ kata\ unik\ disemua\ topik}{Total\ kata\ yang\ diekstraksi\ dari\ semua\ topik} \quad (15)$$

5. *Silhouette Score*

Silhouette Score untuk BERTopic, digunakan untuk mengevaluasi hasil *clustering* dalam representasi *embedding* (hasil UMAP + HDBSCAN pada BERTopic). Nilai berada pada rentang -1 hingga 1.

Dengan rumus:

$$s_i = \frac{b_i - a_i}{\max(a_i, b_i)} \quad (16)$$

Di mana:

a_i = rata-rata jarak dari data poin i ke semua titik lain dalam cluster yang sama

b_i = rata-rata jarak dari data poin i ke semua titik cluster terdekat.

3.5.1.3 Evaluasi BERTopic

Perhitungan *coherence* pada BERTopic dilakukan dengan cara Ambil top-n words tiap topik, Hitung *co-occurrence* dari corpus asli, gunakan metrik C_v, NPMI, Umass, normalisasi nilai dan Final Score. (Grootendorst, 2022)

Untuk Normalisasi nilai sebagai berikut:

$$Score_{norm} = \frac{x - x_{min}}{x_{max} - x_{min}} \quad (17)$$

Untuk Final Score seperti berikut:

$$Final\ Score = \alpha.Cv + \beta.NPMI_{norm} + \gamma.Umass_{norm} \quad (18)$$

Biasanya $\alpha = 0.4$ $\beta = 0.3$ dan $\gamma = 0.3$

3.5.2 Evaluasi Kualitatif

Bebberapa Evaluasi Kualitatif yang bisa dilakukan dari model yang terbentuk diantaranya:

3.5.2.1 Human Interpretability Analysis

Evaluasi ini dilakukan dengan cara menganalisis langsung topik-topik yang dihasilkan untuk melihat apakah kumpulan kata yang disajikan benar-benar mewakili satu konsep atau tema tertentu dalam konteks Al-Qur'an. Adapun kriteria penilaiannya seperti :

- a. Kekohesifan tematik, yaitu apakah kumpulan kata dalam satu topik saling berhubungan secara makna?

- b. Kesesuaian dengan konteks Al-Qur'an, yaitu apakah topik mencerminkan tema yang dikenal dalam studi Al-Qur'an (misal: ibadah, kisah nabi, hukum, tauhid)?
- c. Kemudahan interpretasi oleh manusia: Seberapa mudah pengguna atau peneliti memahami makna topik hanya dengan melihat kumpulan kata kunci?

3.5.2.2 Visualisasi dan Interpretasi Interaktif

Menggunakan alat bantu visual seperti:

- a. Visualisasi topik (CTM Topic Correlation Heatmap, Grafik Topic Word Scores, Intertopic Distance Map) untuk melihat penyebaran dan pemisahan antar-topik.
- b. *WordCloud*, guna menangkap kata-kata dominan secara visual.

3.5.3 Penggabungan Akhir Model CTM dan BERTopic

Setelah seluruh proses pemodelan topik selesai dilakukan, tahap berikutnya adalah penggabungan hasil model CTM dan BERTopic melalui analisis kesamaan topik menggunakan metode *Jaccard Similarity*. Metode ini digunakan untuk mengukur tingkat kemiripan antar topik berdasarkan irisan kata-kata dominan yang dihasilkan oleh kedua model. Nilai kemiripan dihitung dari perbandingan jumlah kata yang sama terhadap total gabungan kata unik pada masing-masing topik. (an & Kumar, 2005)

Beirkut rumus Jaccard similiarity yang digunakan:

$$J = \frac{M_{11}}{M_{01} + M_{10} + M_{11}} \quad (19)$$

Di mana:

M_{11} = jumlah atribut bernilai 1 pada kedua objek

M_{10} = atribut 1 pada objek A tetapi 0 pada B

M_{01} = atribut 0 pada objek A tetapi 1 pada B

Tahap analisis dilakukan dengan fokus pada beberapa aspek berikut:

- a. Perhitungan tingkat kesamaan topik antara model CTM dan BERTopic menggunakan *Jaccard Similarity*
- b. Interpretasi hubungan dan keterkaitan tema yang dihasilkan oleh kedua model
- c. Analisis kemampuan masing-masing model dalam merepresentasikan struktur makna kontekstual pada terjemahan Al-Qur'an
- d. Evaluasi kemudahan interpretasi topik berdasarkan visualisasi serta konsistensi kata-kata representatif yang dihasilkan.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Gambaran Umum Hasil Penelitian

Bab ini menyajikan hasil pengolahan data dan pembahasan pemodelan topik pada teks terjemahan Al-Qur'an berbahasa Indonesia. Tahapan penelitian meliputi preprocessing teks, evaluasi variasi preprocessing, optimasi parameter jumlah topik pada *Correlated Topic Model* (CTM), optimasi parameter BERTopic, pemodelan topik menggunakan CTM dan BERTopic, serta analisis hasil kedua metode.

Secara umum, penelitian ini menggunakan dataset teks terjemahan Al-Qur'an berbahasa Indonesia yang bersumber dari Kementerian Agama Republik Indonesia, terdiri dari 114 dokumen pada tingkat surat. Seluruh tahapan pengolahan data dilakukan menggunakan bahasa pemrograman Python dengan memanfaatkan pustaka NLP modern seperti *transformers*, *sentence-transformers*, *bertopic*, *gensim*, dan *scikit-learn*. Pembahasan pada bab ini disusun secara sistematis, dimulai dari hasil evaluasi variasi preprocessing untuk menentukan metode terbaik, dilanjutkan dengan proses optimasi parameter pada masing-masing model, yaitu jumlah topik K pada CTM dan `min_topic_size` pada BERTopic, kemudian hasil pemodelan dan interpretasi topik dari kedua metode, hingga analisis penggabungan topik menggunakan pendekatan *Jaccard similarity* untuk mengidentifikasi struktur tematik utama yang terkandung dalam teks terjemahan Al-Qur'an

4.2 Variasi dan Hasil Preprocessing Teks

4.2.1 *Preprocessing* Teks

Tahap preprocessing teks dilakukan melalui tahapan berikut:

1. *Case Folding*

Seperti yang terlihat pada tabel 4.1 merupakan beberapa contoh dari *case folding* yang dilakukan pada surat Al-Fatihah:

Tabel 4. 1 Contoh Hasil *Case Folding*

Surat-Ayat	Teks Terjemahan	Hasil
1-1	Dengan nama Allah Yang Maha Pengasih lagi Maha Penyayang.	dengan nama allah yang maha pengasih lagi maha penyayang
1-2	Segala puji bagi Allah, Tuhan semesta alam	segala puji bagi allah, tuhan2 semesta alam
1-3	Yang Maha Pengasih lagi Maha Penyayang	yang maha pengasih lagi maha penyayang
1-4	Pemilik hari Pembalasan	pemilik hari pembalasan
1-5	Hanya kepada Engkaulah kami menyembah dan hanya kepada Engkaulah kami memohon pertolongan.	hanya kepada engkaulah kami menyembah dan hanya kepada engkaulah kami memohon pertolongan

2. *Stopwords Removal*

Stopword yang dilakukan yaitu *stopwords* berbahasa Indonesia dan kontekstual terjemah Al-Qur'an, *Stopword removal* menghapus kata-kata fungsional yang sering muncul tetapi tidak membawa makna tematik kuat. Contoh *Stopword* Bahasa Indonesia; yang, dan, lagi, adalah, sesungguhnya. Seperti pada tabel 4.2 berikut merupakan beberapa contoh dari Sebelum dan Sesudah *stopword Removal*.

Tabel 4. 2 Contoh Hasil *Stopword Removal*

Surat-Ayat	Teks Terjemahan	Hasil
------------	-----------------	-------

1-1	Dengan nama Allah Yang Maha Pengasih lagi Maha Penyayang.	nama allah maha pengasih maha penyayang
1-2	Segala puji bagi Allah, Tuhan semesta alam	puji allah tuhan semesta alam
1-3	Yang Maha Pengasih lagi Maha Penyayang	maha pengasih maha penyayang
1-4	Pemilik hari Pembalasan	pemilik hari pembalasan
1-5	Hanya kepada Engkaulah kami menyembah dan hanya kepada Engkaulah kami memohon pertolongan.	engkau kami menyembah engkau kami memohon pertolongan

3. *Tokenization*

Tokenization yang dilakukan yaitu proses memecah teks menjadi unit-unit dasar (token), seperti pada tabel 4.3 berikut merupakan beberapa contoh hasil dari *Tokenization*.

Tabel 4. 3 Contoh Hasil *Tokenization*

Surat-Ayat	Teks Terjemahan	Hasil
1-1	Dengan nama Allah Yang Maha Pengasih lagi Maha Penyayang.	[nama, allah, maha, pengasih, maha, penyayang]
1-2	Segala puji bagi Allah, Tuhan semesta alam	[puji, allah, tuhan, semesta, alam]
1-3	Yang Maha Pengasih lagi Maha Penyayang	[maha, pengasih, maha, penyayang]

1-4	Pemilik hari Pembalasan	[pemilik, hari, pembalasan]
1-5	Hanya kepada Engkaulah kami menyembah dan hanya kepada Engkaulah kami memohon pertolongan.	[engkau, kami, menyembah, engkau, kami, memohon, pertolongan]

4. *Punctuation Removal*

Punctuation removal berfungsi untuk menghapus, simbol *non-alfabet*, Angka dan beberapa tanda baca yang tidak berkontribusi terhadap makna tematik. Beberapa contoh dari *Punctuation Removal* seperti pada tabel 4.4 berikut.

Tabel 4. 4 Contoh *Punctuation Removal*

Surat-Ayat	Teks Terjemahan	Hasil
1-1	Dengan nama Allah Yang Maha Pengasih lagi Maha Penyayang.	nama allah maha pengasih maha penyayang
1-2	Segala puji bagi Allah, Tuhan semesta alam	puji allah tuhan semesta alam
1-3	Yang Maha Pengasih lagi Maha Penyayang	maha pengasih maha penyayang
1-4	Pemilik hari Pembalasan	pemilik hari pembalasan
1-5	Hanya kepada Engkaulah kami menyembah dan hanya kepada Engkaulah kami memohon pertolongan.	engkau kami menyembah engkau kami memohon pertolongan

5. *Stemming* dan *Lemmatization*

Stemming memotong kata ke bentuk, dan *Lemmatization* mengubah kata ke bentuk kamus (lebih akurat). *stemming* pada *preprocessing* menggunakan library Sastrawi. Beberapa contoh dari hasil *stemming* dan *Lemmatization* seperti pada tabel 4.5 berikut.

Tabel 4. 5 Contoh *Stemming* dan *Lemmatization*

Surat-Ayat	Teks Terjemahan	Hasil
1-1	Dengan nama Allah Yang Maha Pengasih lagi Maha Penyayang.	nama allah maha asih maha sayang
1-2	Segala puji bagi Allah, Tuhan semesta alam	puji allah tuhan semesta alam
1-3	Yang Maha Pengasih lagi Maha Penyayang	maha asih maha sayang
1-4	Pemilik hari Pembalasan	milik hari balas
1-5	Hanya kepada Engkaulah kami menyembah dan hanya kepada Engkaulah kami memohon pertolongan.	engkau kami sembah engkau kami mohon tolong

4.2.2 Variasi Metode *Preprocessing*

Pada penelitian ini diterapkan beberapa variasi metode *preprocessing* untuk mengevaluasi pengaruh masing-masing tahapan terhadap kualitas representasi teks sebelum dilakukan pemodelan topik secara *unsupervised*. Variasi *preprocessing* disusun berdasarkan kombinasi penggunaan *stopword removal* dan *stemming* Bahasa Indonesia (Sastrawi).

Variasi *preprocessing* yang digunakan dalam penelitian ini seperti pada tabel 4.6 berikut.

Tabel 4. 6 Tabel Variasi Preprocessing Dokumen

Variasi Preprocessing	Deskripsi
<i>preprocessed basic</i>	<i>case folding, Tokenization, punctuation removal, cleaning tanpa stopwords removal dan stemming</i>
<i>Preprocessed no steam</i>	<i>case folding, Tokenization, punctuation removal, cleaning stopwords removal tanpa stemming</i>
<i>Preprocessed advanced</i>	<i>case folding, Tokenization, punctuation removal, cleaning stopwords removal dan stemming</i>

Dari pendekatan variasi preprocessing didapatkan beberapa hasil pengolahan data untuk *preprocessed basic* total token 126.734 dengan rata-rata 22 token per dokumen, untuk *preprocessed no steam* total token 60.168 dengan rata-rata 10.4 token per dokumen, dan *preprocessed advance* total token 60.258 dengan rata-rata 10.4 token per dokumen. Salah satu contoh *wordcloud* *preprocessed advance* seperti pada pada gambar 4.1.



Gambar 4. 1 *Wordcloud Preprocessed Advance*

Evaluasi kualitas preprocessing dilakukan menggunakan tiga metrik utama, yaitu *token reduction*, *vocabulary reduction*, dan *average preservation rate*. Ketiga metrik ini digunakan secara luas dalam penelitian NLP untuk menilai efisiensi representasi teks serta preservasi makna sebelum pemodelan topik.

4.2.3 Analisis Reduksi Token, Reduksi Kosakata, Preservasi Makna pada Variasi Preprocessing

Sebelum ditentukan dokumen yang akan dilakukan untuk pengolahan data topik, dilakukan analisa dari variansi preprocessing dengan menghitung nilai reduksi token, reduksi kosakata dan preservasi makna. Dengan tujuan agar kualitas topik yang terbentuk lebih akurat dan minimalisasi noise pada setiap dokumen yang terbentuk. Seperti pada tabel 4.7 adalah nilai reduksi token, reduksi kosakata dan preservasi makna.

Tabel 4. 7 Analisa Reduksi Token, Reduksi Kosakata dan Preservasi Makna

Variasi Preprocessing	Reduksi Token (%)	Reduksi Kosakata (%)	Preservasi Makna (%)
<i>Preprocessed basic</i>	6,81	58.43	68,61
<i>Preprocessed no steam</i>	55.7	59.31	74.45
<i>Preprocessed advanced</i>	55.6	83.75	73.20

6. Analisis Reduksi token (*Token Reduction*)

Berdasarkan hasil dari pengolahan reduksi token pada tabel 4.7 terlihat bahwa variasi berbasis *Preprocessed no steam* dan *Preprocessed advanced* menghasilkan reduksi token yang signifikan yaitu sekitar 55%, dibandingkan *Preprocessed basic* yang hanya mereduksi sekitar 6,8% token. Hal ini menunjukkan bahwa pada *preprocessed no steam* dan *preprocessed advanced* berperan dominan dalam menghilangkan kata *non informatif* yang tidak berkontribusi langsung terhadap pembentukan topik.

7. Analisis Reduksi Kosakata (*Vocabulary Reduction*)

Hasil pada Tabel 4.7 menunjukkan pada variasi *preprocessed advanced* yaitu 83,75. Hal ini mengindikasikan bahwa proses *stemming* berhasil menyatukan variasi kata ke dalam bentuk dasar, sehingga ukuran kosakata menjadi lebih terkendali.

8. Analisis Preservasi Makna (*Preservation Rate*)

Pada Tabel 4.7 Nilai preservasi makna di atas 70% menunjukkan bahwa *preprocessing* tidak bersifat destruktif terhadap konsep utama Al-Qur'an, dan masih mempertahankan kepadatan informasi semantik yang memadai untuk pemodelan topik.

4.2.4 Pemilihan Preprocessing Utama

Berdasarkan ketiga metrik evaluasi, *preprocessed advanced* dipilih sebagai preprocessing utama dalam penelitian ini. Variasi ini memberikan keseimbangan terbaik antara reduksi token tinggi (55,6%) untuk menekan noise, reduksi kosakata sangat signifikan (83,75%) untuk meningkatkan stabilitas topik, Preservasi makna memadai (73,20%) untuk menjaga interpretabilitas tema.

Dengan demikian, preprocessing ini dinilai paling sesuai untuk digunakan pada pemodelan topik berbasis CTM dan BERTopic yang sensitif terhadap kualitas representasi teks dan distribusi kosakata.

4.3 Analisis Topik Model CTM

Setelah dilakukan *preprocessing* data, sebelum dilakukan train terhadap model maka dilakukan pengujian parameter untuk nilai K pada model CTM, tujuan dari uji parameter adalah mengambil nilai K yang optimal pada model.

Optimasi jumlah topik K dilakukan untuk menentukan konfigurasi model CTM yang mampu merepresentasikan struktur tematik teks Al-Qur'an secara optimal. Pemilihan nilai K yang tidak tepat dapat menyebabkan topik terlalu umum (*underfitting*) atau terlalu terfragmentasi (*overfitting*). Oleh karena itu, optimasi dilakukan dengan mengevaluasi beberapa metrik kuantitatif yang

umum digunakan dalam pemodelan topik, yaitu *log-likelihood*, *coherence score*, *topic diversity*, dan *Quality*.

4.3.1 Optimasi Jumlah Topik


Proses optimasi dilakukan dengan menguji rentang jumlah topik $K = 8$ hingga $K = 19$, menggunakan 114 dokumen tingkat surat dengan total 75.490 token. Hasil perhitungan nilai optimasi topik dengan jumlah topik, nilai *Log-Likelihood* (LL), *Coherence*, *Diversity* dan *Quality* bisa dilihat pada tabel 4.8 berikut.

Tabel 4. 8 Hasil Nilai Optimasi Topik

No	Jumlah Topik (K)	<i>Log-Likelihood</i> (LL)	<i>Coherence Score</i>	<i>Diversity</i>	<i>Quality</i>
1	8	-6.556	1	0.925	0.95
2	9	-7.0233	1	0.9111	0.9444
3	10	-6.7489	1	0.96	0.94
4	11	-6.9106	1	0.9455	0.9545
5	12	-7.0999	1	0.9167	0.9417
6	13	-7.1274	1	0.9385	0.9385
7	14	-6.8294	1	0.9714	0.9429
8	15	-7.1615	1	0.9933	0.9267
9	16	-7.0843	1	0.975	0.9375
10	17	-7.1856	1	0.9529	0.9529
11	18	-7.8642	1	0.9333	0.9556
12	19	-7.7731	1	0.9526	0.9421

4.3.1.1 Analisis *Log-Likelihood* terhadap Jumlah Topik

Dari tabel 4.8 jika dianalisis dan divisualisasikan dengan menggunakan grafik nilai *Log-likelihood* dapat terlihat pada gambar 4.2.




Gambar 4. 2 Grafik Log-Likelihood vs Number of Topics

Gambar grafik 4.2 adalah grafik nilai *Log-Likelihood* yang menunjukkan kemampuan model dalam merepresentasikan data, di mana nilai yang lebih tinggi mengindikasikan model yang lebih baik. (Blei et al., 2003b)

Berdasarkan nilai yang didapat seperti pada gambar grafik 4.2 nilai terbaik diperoleh pada $K=8$ (-6.556), diikuti oleh $K=10$ (-6.7489) dan $K=14$ (-6.8294). Hal ini menunjukkan bahwa pada jumlah topik yang relatif kecil, model mampu menangkap distribusi kata dengan lebih optimal. Namun, seiring bertambahnya jumlah topik ($K > 14$), nilai Log-Likelihood cenderung menurun secara signifikan, seperti pada $K=18$ (-7.8642). Penurunan ini mengindikasikan bahwa model mulai mengalami over-segmentation, yaitu pembagian topik yang terlalu banyak sehingga distribusi probabilitas menjadi kurang stabil. Dengan demikian, dari sisi Log-Likelihood, jumlah topik optimal berada pada rentang 8–14 topik, dengan titik kompromi yang cukup baik pada $K=14$.

4.3.1.2 Analisis *Coherence Score* terhadap Jumlah Topik

Gambar 4.3 berikut adalah visualisasi dari nilai yang didapat pada tabel 4.8 untuk nilai *coherence score* seperti berikut.




Gambar 4. 3 *Grafik Coherence vs Number of Topics*

Hasil pengujian menunjukkan bahwa nilai coherence score bernilai konstan sebesar 1 untuk seluruh nilai K dari 8 hingga 18. Kondisi ini mengindikasikan bahwa model CTM yang digunakan menghasilkan topik dengan konsistensi internal yang sangat tinggi, dan perubahan jumlah topik tidak memberikan perbedaan signifikan terhadap nilai coherence.

Fenomena *coherence* yang stabil ini dapat terjadi pada korpus dengan struktur semantik yang kuat dan homogen, dimana keterkaitan antar konsep teologis relatif konsisten. Oleh karena itu, pada penelitian ini *coherence score* tidak dijadikan faktor pembeda utama, melainkan dikombinasikan dengan metrik lain yang lebih sensitif terhadap variasi K. (Röder et al., 2015b)

4.3.1.3 Analisis *Topic Diversity* terhadap Jumlah Topik

Dari tabel 4.8 jika dianalisis dan divisualisasikan dengan menggunakan grafik untuk nilai *Topic Diversity* terhadap jumlah parameter nilai K seperti berikut.




Gambar 4. 4 Grafik Topic Diversity vs Number of Topics

Grafik Topic Diversity mengukur sejauh mana kata-kata antar topik berbeda satu sama lain. Nilai diversity tertinggi diperoleh pada $K=15$ (0.9933), diikuti oleh $K=16$ (0.975) dan $K=14$ (0.9714). Hal ini menunjukkan bahwa semakin banyak jumlah topik, semakin beragam kata-kata yang digunakan dalam setiap topik. Namun demikian, diversity yang terlalu tinggi tidak selalu ideal, karena dapat menyebabkan topik menjadi terlalu terfragmentasi dan kehilangan makna yang koheren. Pada K yang lebih kecil seperti $K=8$ (0.925), diversity lebih rendah namun masih dalam kategori baik, yang menunjukkan adanya keseimbangan antara perbedaan topik dan konsistensi makna. Dengan demikian, $K=14$ dapat dianggap sebagai titik optimal karena memberikan diversity tinggi tanpa berlebihan.

4.3.1.4 Analisis Topic Quality

Dari tabel 4.8 jika dianalisa dan divisualisasikan dengan menggunakan grafik untuk nilai *Topic Quality* terhadap jumlah parameter nilai K seperti berikut.




Gambar 4. 5 Grafik *Topic Quality vs Number of Topics*

Pada gambar Grafik 4.5 merupakan *Topic Quality vs Number of Topics* merupakan kombinasi antara *coherence* dan *diversity*, hal ini yang mencerminkan kualitas keseluruhan topik. Nilai tertinggi diperoleh pada K=18 (0.9556) dan K=11 (0.9545), diikuti oleh K=17 (0.9529). Meskipun K=18 memiliki kualitas tertinggi, nilai Log-Likelihood pada K ini sangat rendah, sehingga secara keseluruhan model kurang stabil. Sebaliknya, K=11 dan K=14 menunjukkan keseimbangan antara kualitas topik dan stabilitas model. Nilai quality pada K=14 (0.9429) masih tergolong tinggi dan lebih konsisten dengan metrik lainnya. Hal ini menunjukkan bahwa jumlah topik tersebut mampu menghasilkan topik yang cukup berkualitas tanpa mengorbankan performa model secara keseluruhan.

4.3.1.5 Analisis *Composite Score*

Composite score digunakan untuk menggabungkan beberapa metrik evaluasi ke dalam satu skor terstandardisasi seperti pada gambar 4.6.




Gambar 4. 6 Grafik Composite Score vs Number of Topics

Berdasarkan Gambar 4.6 nilai tertinggi diperoleh pada $K=14$ (0.64), diikuti oleh $K=10$ (0.62) dan $K=8$ (0.615). Hal ini menunjukkan bahwa $K=14$ merupakan jumlah topik yang paling optimal karena mampu memberikan keseimbangan terbaik antara *Log-Likelihood*, *diversity*, dan *quality*. Sementara itu, meskipun $K=15$ dan $K=16$ memiliki *diversity* tinggi, nilai *composite*-nya lebih rendah karena penurunan pada metrik lain. Dengan demikian, pemilihan $K=14$ didukung secara kuat oleh pendekatan multi-metrik.

4.3.1.6 Pengambilan K Optimal

Dari beberapa uji optimasi nilai K , dibuatkan grafik *normalized score* terdiri dari gabungan grafik lainnya seperti bisa dilihat pada gambar grafik 4.7 berikut.



Gambar 4. 7 Grafik Normalized Score vs Number of topics

Gambar 4.7 merupakan grafik normalisasi menunjukkan perbandingan semua metrik dalam satu skala. Terlihat bahwa pada $K=14$, hampir seluruh metrik berada pada posisi yang relatif tinggi dan seimbang dibandingkan jumlah topik lainnya. Tidak ada metrik yang terlalu dominan maupun terlalu rendah, yang menunjukkan bahwa model berada pada kondisi optimal. Sebaliknya, pada K tinggi seperti $K=18$ dan $K=19$, terlihat ketidakseimbangan antar metrik, terutama penurunan drastis pada *Log-Likelihood*. Hal ini memperkuat bahwa pemilihan jumlah topik tidak dapat hanya berdasarkan satu metrik saja, melainkan harus mempertimbangkan keseimbangan keseluruhan performa model.

Berdasarkan seluruh hasil evaluasi, dapat disimpulkan bahwa jumlah topik optimal dalam penelitian ini adalah $K=14$, karena memberikan keseimbangan terbaik antara kualitas topik, keberagaman, dan stabilitas model.

4.3.2 *Training* dan Analisa Hasil Pemodelan CTM

4.3.2.1 *Training Model CTM*

Proses *training* pada model CTM dilakukan secara iteratif dengan nilai parameter $K=14$ yang didapatkan dari uji optimasi. Proses iteratif model dilakukan hingga mencapai konvergensi artinya model sudah mencapai titik akhir. Indikator utama yang diamati adalah perubahan nilai *log-likelihood* pada setiap interval iterasi.

Tabel 4. 9 nilai *Log-Likelihood* pada setiap train model

Iterasi	Log-Likelihood
0	-7.7665
100	-6.7815
200	-6.8747
300	-7.2442
400	-7.3224

Berdasarkan Tabel 4.9 terlihat bahwa nilai *log-likelihood* mengalami perubahan sepanjang proses iterasi pelatihan model CTM. Pada iterasi awal (iterasi ke-0), nilai berada pada angka -7.7665, yang menunjukkan bahwa model masih dalam kondisi awal dan belum mampu memodelkan distribusi data dengan baik. Selanjutnya, pada iterasi ke-100 terjadi peningkatan signifikan menjadi -6.7815, yang mengindikasikan bahwa model mulai belajar pola distribusi topik dalam data dan menghasilkan probabilitas yang lebih baik..

Namun, setelah iterasi ke-100, nilai *log-likelihood* mengalami sedikit penurunan pada iterasi ke-200 menjadi -6.8747, dan terus menurun hingga iterasi ke-300 (-7.2442) dan iterasi ke-400 (-7.3224). Penurunan ini menunjukkan adanya fluktuasi dalam proses optimasi, yang umum terjadi pada model berbasis sampling seperti CTM. Meskipun demikian, perubahan tersebut tidak terlalu signifikan dibandingkan dengan peningkatan awal, sehingga dapat

diinterpretasikan bahwa model telah mencapai kondisi konvergensi (menuju satu titik pemusatan) pada iterasi ke-100.

4.3.2.2 Analisis Hasil Topik CTM

Hasil pemodelan yaitu 14 topik, sesuai dengan jumlah topik optimal yang telah ditentukan pada tahap optimasi, berikut Daftar Topik CTM dan Kata Kunci Utama.

Tabel 4. 10 Hasil Topik CTM

Topik	Kata-kata Utama
0	ayat, ingat, dosa, baca, dengar
1	benar, janji, setan, ajar, ambil
2	rasul, sembah, dusta, datang, bukti
3	kaum, tanda, hidup, mati, waktu
4	kufur, hati, takut, balas, rasa
5	maha, bumi, langit, tahu, segala
6	turun, tempat, kitab, buruk, malaikat
7	azab, bawa, timpa, datang, gembira
8	hari, jalan, sendiri, kiamat, malam
9	masuk, dua, dalam, surga, neraka
10	kepada, beri, tunjuk, anugerah, rezeki
11	buat, jangan, anak, laki, perempuan
12	tuhan, dapat, siapa, kata, tahu
13	ada, bagi, baik, iman, jadi


Analisis terhadap kata-kata utama hasil topik pada tabel 4.10 menunjukkan bahwa topik-topik yang dihasilkan memiliki koherensi semantik yang jelas dan mencerminkan tema-tema utama Al-Qur'an, diantaranya:

1. Kenabian dan Wahyu pada Topik 1, 2, 6, dan 7
2. Ketuhanan dan Kekuasaan Allah pada Topik 3, 5, 12 dan 13
3. Hari akhir dan pembalasan pada Topik 4, 8 dan 9

4. Sosial, Hukum dan Keluarga pada topik 11
5. Ilmu pengetahuan dan Petunjuk pada topik 0 dan 10

4.3.2.3 Analisa Korelasi antar topik model CTM

Untuk mengetahui keterkaitan antara topik model CTM yang terbentuk bisa dilihat dengan grafik matrik CTM *Topic Correlation Heatmap* seperti pada gambar 4.8 berikut:



Gambar 4. 8 Grafik CTM Topic Correlation Heatmap

Gambar *heatmap* korelasi topik pada model *Correlated Topic Model* (CTM) menunjukkan tingkat hubungan antar topik yang dihasilkan dari proses pemodelan terhadap korpus teks.

Berdasarkan grafik CTM pada gambar 4.8, sebagian besar nilai korelasi berada pada rentang yang relatif rendah, yaitu sekitar -0,15 hingga 0,12. Hal ini

menunjukkan bahwa nilai korelasi yang tidak begitu kuat satu sama lain. Kondisi ini mengindikasikan bahwa model CTM mampu memisahkan topik-topik secara cukup baik, sehingga setiap topik merepresentasikan tema yang berbeda dalam korpus teks tanpa adanya tumpang tindih yang signifikan.

Meskipun demikian, terdapat beberapa pasangan topik yang memiliki korelasi positif, meskipun dalam skala kecil, seperti antara topik 1 dan topik 2 dengan nilai sekitar 0,12, serta topik 7 dan topik 10 dengan nilai sekitar 0,08. Korelasi positif ini menunjukkan adanya kedekatan konteks atau kemiripan semantik antar topik tersebut. Adapun korelasi negatif, seperti antara topik 8 dan topik 11 (-0,29), serta topik 10 dan topik 11 (-0,29) dapat diinterpretasikan sebagai indikator adanya perbedaan tema yang cukup signifikan antar topik.

Secara keseluruhan, hasil korelasi ini menunjukkan bahwa model CTM menghasilkan struktur topik yang terdistribusi dengan baik, ditandai dengan dominasi nilai korelasi yang rendah antar topik. Hal ini menjadi indikator bahwa model memiliki kemampuan yang baik dalam membedakan tema-tema dalam data.

4.3.2.4 Analisa Metriks Koherensi CTM

Dari pemodelan CTM didapat nilai metriks koherensi seperti pada tabel 4.11 berikut:

Tabel 4. 11 Nilai Metrik Koherensi (C_v , NPMI, UCI, dan Perplexity)

C_v	NPMI	UMass	UCI	Perplexity
0.517	-0.022	-5.066	-2.137	1720.28

Pada tabel 4.11 Nilai C_v sebesar 0,5170 mengindikasikan bahwa koherensi topik berada pada kategori sedang, artinya kata-kata dalam setiap topik sudah cukup saling berkaitan secara semantik dan masih dapat diinterpretasikan dengan baik, meskipun belum optimal. Namun, nilai NPMI sebesar -0,0226 yang mendekati nol tetapi masih negatif menunjukkan bahwa keterkaitan antar kata dalam topik relatif lemah, karena idealnya nilai NPMI

berada pada rentang positif untuk menunjukkan asosiasi kata yang kuat. Hal ini diperkuat oleh nilai UMass sebesar -5,0661 dan UCI sebesar -2,1370, yang keduanya bernilai negatif dan mengindikasikan bahwa dari perspektif probabilistik berbasis corpus, hubungan antar kata dalam topik masih kurang kuat atau kurang konsisten muncul bersama dalam dokumen yang sama.

Nilai *Perplexity* sebesar 1720,28 menunjukkan bahwa model CTM yang digunakan masih belum optimal dalam menangkap struktur distribusi kata pada dataset. Secara nilai perplexity mengindikasikan bahwa model belum mampu secara optimal menangkap pola probabilistik dalam data, sehingga prediksi terhadap kata-kata dalam dokumen masih kurang akurat.

Secara keseluruhan, hasil metrik koherensi menunjukkan CTM sudah mampu menangkap hubungan antar topik, tetapi kualitas koherensi internal topik masih berada pada tingkat sedang hingga rendah. Dengan kata lain, model cenderung baik dalam memodelkan relasi antar topik, namun belum optimal dalam menghasilkan topik yang benar-benar solid secara semantik.

4.3.2.5 Analisis Distribusi Topik CTM


Selain analisis topik secara global, dilakukan pemetaan topik dominan pada setiap dokumen tingkat surat. Tabel 4.12 berikut menyajikan contoh hasil distribusi topik pada surat ke-1 yaitu Al-Fatihah.

Tabel 4. 12 Contoh distribusi nilai rata-rata probabilitas surat Al-fatihah

Sura	Ayat	Topik						
		0	1	2	3	4	5	6
1	1	0.02	0.02	0.02	0.02	0.02	0.39	0.02
	2	0.02	0.02	0.02	0.02	0.02	0.76	0.02
	3	0.02	0.02	0.02	0.02	0.25	0.25	0.02
	4	0.01	0.01	0.55	0.01	0.01	0.01	0.01
	5	0.02	0.25	0.02	0.02	0.02	0.02	0.02
	6	0.02	0.02	0.02	0.02	0.17	0.02	0.02

Sura	Ayat	Topik						
		7	8	9	10	11	12	13
1	1	0.39	0.02	0.02	0.02	0.02	0.02	0.02
	2	0.02	0.02	0.02	0.02	0.02	0.02	0.02
	3	0.02	0.25	0.02	0.02	0.02	0.02	0.02
	4	0.01	0.01	0.01	0.01	0.01	0.15	0.15
	5	0.02	0.48	0.02	0.02	0.02	0.02	0.02
	6	0.02	0.17	0.02	0.33	0.02	0.17	0.02

Tabel 4.12 diatas menunjukkan rata-rata probabilitas distribusi topik pada setiap ayat dalam Surah 1 yang dihasilkan oleh CTM. Setiap ayat memiliki kombinasi beberapa topik dengan nilai probabilitas tertentu, di mana nilai tertinggi menunjukkan topik dominan dalam ayat tersebut. Berdasarkan data, terlihat bahwa ayat 1 dan 2 sangat didominasi oleh topik 5, khususnya ayat 2 dengan nilai sangat tinggi (0,7593) artinya ayat 1 dan 2 menunjukan makna tema ketauhidan. ayat 3 dan 5 menunjukkan distribusi multi-topik, di mana beberapa topik memiliki nilai yang relatif seimbang (misalnya topik 4, 5, dan 8 pada ayat 3).



Gambar 4. 9 Contoh Grafik *heatmap* distitibusi 20 surat pertama

Gambar 4.9 merupakan grafik *heatmap* menunjukkan contoh distribusi rata-rata proporsi topik dari model CTM pada 20 surat pertama, Secara umum, distribusi topik terlihat tidak merata, yang mengindikasikan bahwa setiap surat memiliki kecenderungan kuat terhadap topik tertentu. Beberapa topik seperti Topik 12 dan 13 tampak memiliki nilai yang relatif tinggi dan konsisten di banyak surat (misalnya mencapai kisaran 0.15–0.26), sehingga dapat diasumsikan sebagai topik dominan global dalam korpus 20 surat pertama.

4.4 Analisis Topik Model BERTopic

Pada pemodelan BERTopic dilakukan terlebih dahulu dengan menentukan parameter jumlah minimal dokumen (*min topic size*), penentuan *min topic size* selain untuk mengontrol ukuran minimum sebuah topik tetapi juga untuk mengurangi topik terlalu kecil (*Overfragmentation*), mengurangi nilai *outlier* pada topik dan untuk memperoleh struktur topik yang stabil, koheren, dan representatif terhadap distribusi dokumen.

4.4.1 Penentuan Uji Parameter Jumlah Minimal Dokumen

Pengujian dilakukan terhadap beberapa nilai jumlah topik untuk menentukan konfigurasi terbaik berdasarkan jumlah topik dan metrik koherensi. Pada tabel 4.13 merupakan hasil dari pengujian topik.

Tabel 4. 13 Nilai CV, NPMI dan UMass pada pengujian *Min Topic Size*

No	min topic size	number topics	C_v	NPMI	UMass	NPMI norm	UMass norm	Final Score
1	5	203	0.6048	0.0619	-7.5949	1	0	0.6
2	10	104	0.5908	0.0576	-6.6529	0.8983	0.4142	0.7047
3	15	75	0.5769	0.0367	-6.4287	0.4043	0.5128	0.4477
4	20	60	0.555	0.0196	-6.5236	0	0.471	0.1884
5	25	50	0.5735	0.053	-5.3257	0.7896	0.9977	0.8728
6	30	36	0.5687	0.0476	-5.3205	0.6619	1	0.7972

Berdasarkan hasil evaluasi parameter *min_topic_size*, terlihat bahwa perubahan nilai parameter ini memberikan pengaruh signifikan terhadap jumlah topik yang dihasilkan (*number topics*) serta kualitas topik yang diukur menggunakan metrik *coherence* (C_v, NPMI, UMass). Secara umum, semakin kecil nilai *min_topic_size*, jumlah topik yang terbentuk cenderung semakin banyak, seperti terlihat pada nilai 5 yang menghasilkan 203 topik. Namun, meskipun nilai C_v dan NPMI relatif tinggi pada konfigurasi ini, nilai UMass yang sangat rendah (-7.5949) menunjukkan bahwa topik yang dihasilkan kurang koheren secara statistik dalam konteks probabilistik dokumen.

ketika nilai *min_topic_size* ditingkatkan, jumlah topik menjadi lebih sedikit dan lebih general. Pada nilai 25, model menghasilkan 39 topik dengan keseimbangan terbaik antara metrik evaluasi. Hal ini ditunjukkan oleh nilai C_v sebesar 0.5735 yang tetap kompetitif, NPMI sebesar 0.0530 yang cukup tinggi, serta nilai UMass yang paling mendekati nol (-5.3257), yang mengindikasikan

peningkatan kualitas koherensi topik. Selain itu, normalisasi metrik menghasilkan nilai $NPMI_norm$ (0.7896) dan $UMass_norm$ (0.9977) yang tinggi, sehingga menghasilkan *FinalScore* tertinggi yaitu 0.8728.

Dengan demikian, dapat disimpulkan bahwa nilai $min_topic_size = 25$ merupakan parameter optimal dalam eksperimen ini karena mampu menghasilkan keseimbangan terbaik antara jumlah topik yang representatif dan kualitas topik yang koheren.

4.4.2 Analisis Metriks *Coherence*

Pada Tabel 4.13 konfigurasi $min_topic_size = 25$, model menghasilkan nilai C_v sebesar 0.5735, $NPMI$ sebesar 0.0530, dan $UMass$ sebesar -5.3257.

Nilai $C_v = 0.5735$ menunjukkan bahwa topik yang dihasilkan memiliki tingkat koherensi yang cukup baik. nilai C_v di atas 0.5 umumnya dianggap menunjukkan bahwa kata-kata dalam suatu topik memiliki keterkaitan semantik yang cukup kuat dan mudah diinterpretasikan. Hal ini mengindikasikan bahwa model mampu menangkap hubungan konseptual antar kata dalam topik secara representatif, sehingga topik yang dihasilkan tidak bersifat acak atau sulit dipahami.

Nilai $NPMI = 0.0530$ yang bernilai positif menunjukkan bahwa terdapat asosiasi statistik yang bermakna antar kata dalam topik. Dalam konteks *Normalized Pointwise Mutual Information*, nilai yang mendekati nol namun tetap positif mengindikasikan bahwa kata-kata dalam topik cenderung muncul bersama lebih sering dibandingkan kemunculan acak, tetapi belum menunjukkan keterkaitan yang sangat kuat. Hal ini dapat dipahami mengingat teks Al-Qur'an memiliki variasi tema yang luas dan penggunaan bahasa yang kontekstual, sehingga distribusi kata tidak selalu berulang secara eksplisit.


Nilai $UMass = -5.3257$, yang merupakan nilai terbaik (paling mendekati nol) dibandingkan konfigurasi lainnya, menunjukkan bahwa model memiliki konsistensi probabilistik yang baik terhadap distribusi dokumen. Metrik $UMass$ berbasis pada frekuensi kemunculan bersama dalam korpus, sehingga nilai yang lebih tinggi (kurang negatif) mengindikasikan bahwa kata-kata dalam topik

sering muncul bersama dalam dokumen yang sama. Hal ini memperkuat bahwa topik yang dihasilkan tidak hanya koheren secara semantik, tetapi juga didukung oleh struktur statistik data.

Dengan demikian, model yang terbentuk pada $min_topic_size = 25$ dapat digambarkan sebagai model yang menghasilkan topik-topik yang cukup spesifik namun tetap stabil digunakan untuk analisis tematik pada teks terjemahan Al-Qur'an. Topik-topik yang dihasilkan cenderung merepresentasikan kelompok konsep yang bermakna, tidak terlalu terpecah, serta memiliki dasar statistik yang kuat dalam korpus.

4.4.3 Hasil pemodelan BERTopic

Setelah dilakukan pengolahan dokumen dengan pengujian parameter topic size 25 diperoleh 47 topik , dan berikut diperoleh grafik distribusi topik sebagai berikut:



Gambar 4. 10 Grafik Distribusi Topik pada dokumen

Gambar 4.10 merupakan grafik distribusi terlihat bahwa Topik -1 (maha, benar, kepada,beri) memiliki jumlah dokumen terbesar (2039), Hal ini menunjukkan bahwa sekitar sepertiga dokumen tidak tergabung dalam topik tertentu dan diklasifikasikan sebagai outlier. jika dianalisa ada beberapa penyebab. (Grootendorst, 2022)

1. Karakteristik Teks dokumen yang Multitematik

Setiap dokumen ayat dalam dokumen seringkali mengandung lebih dari satu tema (*multi-topic*), Menggabungkan konsep teologis, hukum, dan naratif dalam satu kalimat. Hal ini yang mengakibatkan Representasi embedding menjadi tidak spesifik ke satu cluster, Dokumen sulit dikelompokkan secara tegas ke satu topik.


2. Panjang Dokumen yang pendek

Beberapa dokumen yang digunakan memiliki karakteristik sangat pendek menjadikan Informasi kontekstual terbatas. ini menyebabkan Embedding menjadi kurang kaya informasi, Kemiripan antar dokumen menjadi rendah, *Clustering* menjadi kurang stabil. (Grootendorst, 2022)

3. Sensitifitas Algoritma *Clustering* HDBSCAN

BERTopic menggunakan clustering berbasis densitas (HDBSCAN), yang memiliki sifat hanya membentuk *cluster* jika terdapat kepadatan data yang cukup, dokumen yang berada di area *sparse* (renggang) akan dianggap sebagai noise. Dengan demikian jika distribusi embedding tersebar, maka banyak dokumen akan dikategorikan sebagai outlier (-1).

Meskipun telah dilakukan optimasi `min_topic_size`, tetapi Parameter ini hanya mengontrol ukuran minimal *cluster*, Tidak menghilangkan karakteristik data yang memang tidak padat. Dan hal ini menunjukan model tidak memaksakan *cluster* (menghindari *overfitting*) dan menjaga kualitas topik tetap koheran. Berikut gambar 4.11 merupakan grafik frekuensi kemunculan topik dalam dokumen.



Gambar 4. 11 Grafik *Topic Word Scores*

Gambar 4.11 merupakan grafik *Topic Word Scores* secara khusus fungsi menampilkan topik berdasarkan tingkat dominansi atau frekuensi kemunculannya dalam dokumen (jumlah *count*). Grafik *Topic Word Scores* menunjukkan distribusi kata-kata representatif pada masing-masing topik yang dihasilkan oleh model BERTopic. Setiap topik ditandai oleh beberapa kata kunci dengan bobot tertentu, dimana kata dengan nilai skor tertinggi merepresentasikan inti makna dari topik tersebut.

Hasil visualisasi menunjukkan bahwa setiap topik memiliki konsistensi semantik yang baik, ditandai dengan keterkaitan yang kuat antar kata dalam satu klaster. Sebagai contoh, topik yang berkaitan dengan penciptaan alam didominasi oleh kata seperti *bumi* dan *langit*, sedangkan topik keimanan ditandai dengan kata *iman* dan *agama*. Selain itu, terlihat bahwa sebagian besar topik memiliki satu atau dua kata dengan skor dominan, yang berfungsi sebagai pusat representasi topik, sementara kata lainnya berperan sebagai pendukung konteks. Secara keseluruhan, pola topik yang terbentuk mencerminkan struktur tematik

utama dalam Al-Qur'an, seperti ketuhanan, kenabian, keimanan, serta kehidupan akhirat. Hal ini menunjukkan bahwa model BERTopic mampu menangkap hubungan semantik dalam teks secara efektif dan menghasilkan topik yang interpretatif serta relevan secara konseptual.

Adapun rincian hasil dari pemodelan BERTopic untuk topik 1 dan seterusnya dapat dilihat pada tabel 4.14 berikut:

Tabel 4. 14 Hasil Topik BERTopic

Topik	
0	['bumi', 'langit', 'langit bumi', 'cipta', 'ada', 'maha', 'milik', 'cipta langit', 'segala', 'ada langit']
1	['iman', 'wahai iman', 'wahai', 'agama', 'benar', 'iman kepada', 'kufur', 'kepada', 'iman jangan', 'ada']
2	['hidup', 'mati', 'akhirat', 'dunia', 'hidup dunia', 'hidup mati', 'mati hidup', 'dunia akhirat', 'nyawa', 'bumi']
3	['jahat', 'laku', 'manusia', 'cipta', 'hina', 'durhaka', 'benar', 'jahanam', 'duga', 'siapa']
4	['nabi', 'jihad', 'muslim', 'arab', 'islam', 'agama', 'ibrahim', 'iman', 'masjid', 'bahasa']
5	['ayat', 'ayat ayat', 'kitab', 'baca', 'dusta ayat', 'turun', 'jelas', 'olok', 'dusta', 'hikmah']
6	['rasul', 'bukti', 'rasul rasul', 'bukti bukti', 'orang rasul', 'datang', 'rasul datang', 'kepada', 'bawa', 'benar']
7	['tuhan', 'maha', 'tuhan tuhan', 'nama tuhan', 'tuhan maha', 'nama', 'agung', 'benar', 'tuhan benar', 'tuhan sudah']
8	['perempuan', 'istri', 'laki', 'istri istri', 'anak', 'saudara', 'laki laki', 'halal', 'perempuan perempuan', 'bagi']
9	['kafir', 'kaum kafir', 'iman', 'azab', 'kafir azab', 'ada', 'dapat', 'beri', 'benar', 'jangan']
10	['api', 'air', 'minum', 'panas', 'gelas', 'batu', 'air panas', 'mabuk', 'mata', 'mata air']

11	['malam', 'siang', 'matahari', 'bulan', 'waktu', 'tanda', 'malam siang', 'pagi', 'petang', 'bintang']
12	['ingat', 'beri ingat', 'nenek', 'moyang', 'nenek moyang', 'orang beri', 'beri', 'dahulu', 'mimpi', 'ingat ingat']
13	['anugerah', 'karunia', 'syukur', 'rahmat', 'nikmat', 'beri', 'kaya', 'kikir', 'besar', 'senang']
14	['dosa', 'dosa dosa', 'pikul', 'ampun', 'pikul dosa', 'dosa besar', 'buat dosa', 'buat', 'salah', 'ada']
15	['hari', 'celaka hari', 'hari dusta', 'dusta', 'celaka', 'dusta celaka', 'hari putus', 'hari manusia', 'main', 'balas hari']
16	['tolong', 'golong', 'masuk', 'golong besar', 'datang', 'panggil', 'segera', 'tolong tolong', 'masuk golong', 'golong tangguh']
17	['malaikat', 'malaikat malaikat', 'sujud', 'turun malaikat', 'turun', 'malaikat sujud', 'nama', 'tuhan', 'datang malaikat', 'lihat malaikat']
18	['jangan', 'bukankah', 'jangan sekali', 'gesa', 'sekali kali', 'tidak', 'kali', 'sekali', 'daya', 'tipu']
19	['hamba', 'hamba hamba', 'hamba pilih', 'rezeki', 'maha', 'pilih', 'zalim hamba', 'sahaya', 'hamba sahaya', 'hendak hamba']
20	['kebun', 'buah', 'pohon', 'buah buah', 'kurma', 'kebun kebun', 'tumbuh', 'pohon kurma', 'taman', 'biji']
21	['ri', 'main', 'takwa', 'tanya urus', 'wahai utus', 'penting wahai', 'ganjar takwa', 'urus penting', 'qqah', 'tulis']
22	['neraka', 'api neraka', 'huni neraka', 'api', 'huni', 'tempat', 'buruk', 'kekal dalam', 'kekal', 'neraka kekal']
23	['takut', 'rasa takut', 'rasa', 'sedih', 'takut timpa', 'hati', 'tuhan takut', 'takut tuhan', 'takut hari', 'tuhan']
24	['setan', 'setan setan', 'teman', 'dua', 'setan jadi', 'setan musuh', 'musuh', 'iblis', 'buat', 'janji']

25	['anak', 'keluarga', 'miskin', 'barang', 'yatim', 'anak yatim', 'anak anak', 'kerabat', 'susu', 'barang barang']
26	['kiamat', 'hari kiamat', 'hari', 'datang', 'kiamat datang', 'jadi kiamat', 'hari jadi', 'putus hari', 'tiba', 'selisih']
27	['jalan', 'jauh', 'jalan lurus', 'lurus', 'sesat', 'lubang', 'sanggup', 'ejek', 'tempat', 'sesat jauh']
28	['sekutu', 'sekutu sekutu', 'tentara', 'musuh', 'bala tentara', 'bala', 'perang', 'bimbing', 'sama', 'tenggelam']
29	['rusa', 'buat rusa', 'sapi', 'keburu', 'ternak', 'buat', 'hewan', 'hewan ternak', 'tujuh', 'ekor']
30	['saksi', 'saksi atas', 'atas', 'saksi saksi', 'dua saksi', 'dua', 'maha saksi', 'beri saksi', 'cukup saksi', 'sumpah']
31	['langit', 'awan', 'angin', 'hujan', 'tumpuk', 'terus', 'langit belah', 'terbang', 'barat', 'turun']
32	['ikan', 'kapal', 'laut', 'ikan kepada', 'tanda', 'kepada', 'masing', 'layar', 'tanda tanda', 'syukur']
33	['salat', 'doa', 'laksana salat', 'laksana', 'doa tuhan', 'zakat', 'tuhan', 'iman', 'rezeki anugerah', 'infak bagi']
34	['lihat', 'lihat lihat', 'kelak lihat', 'lihat kelak', 'jahim', 'tengah', 'perhati', 'kelak', 'tengok', 'tengah jahim']
35	['nikmat tuhan', 'tuhan mana', 'mana dusta', 'dusta nikmat', 'mana', 'nikmat', 'dusta', 'tuhan', 'tawakal', 'gila nikmat']
36	['janji', 'janji benar', 'kapan janji', 'kapan', 'benar janji', 'penuh janji', 'benar', 'ingkar janji', 'tepat janji', 'tepat']
37	['sihir', 'mukjizat', 'kena sihir', 'fir aun', 'aun', 'fir', 'kena', 'sihir pandai', 'kepada sihir', 'musa']
38	['burung', 'mukmin', 'burung burung', 'masing', 'sarang', 'semut', 'bagi mukmin', 'gembira mukmin', 'kubur', 'tanda']
39	['kerja', 'usaha', 'bagi usaha', 'pertanggungjawaban', 'minta pertanggungjawaban', 'tahu kerja', 'atas kerja', 'baik kerja', 'kerja lut', 'pertanggungjawaban atas']

40	['gunung', 'gunung gunung', 'pancang', 'bumi gunung', 'rumah', 'bumi', 'amanat', 'jalan', 'hancur', 'jalan jalan']
41	['sungai', 'sungai sungai', 'surga', 'alir bawah', 'alir', 'bawah', 'bawah sungai', 'surga alir', 'sungai kekal', 'kekal dalam']
42	['amal', 'amal saleh', 'iman amal', 'saleh', 'iman', 'surga', 'adapun iman', 'adapun', 'tobat', 'saleh ampun']
43	['azab', 'timpa', 'timpa azab', 'tiba', 'hari pedih', 'hak urus', 'pedih', 'tambah kepada', 'benar', 'azab selalu']
44	['balas', 'sempurna', 'beri balas', 'baik', 'baik demikian', 'balas buat', 'demikian beri', 'cipta sempurna', 'sempurna sesuai', 'buat baik']
45	['anugerah', 'tuhan', 'karunia', 'rahmat', 'anugerah kepada', 'dapat bukti', 'dapat', 'tuhan anugerah', 'nyata tuhan', 'tuhan beri']
46	['surga', 'huni', 'ada surga', 'penuh nikmat', 'surga penuh', 'huni surga', 'nikmat', 'surga dekat', 'surga nikmat', 'masuk surga']
47	['dengar', 'tuli', 'dapat dengar', 'suara', 'buta', 'telinga', 'bisik', 'tuli dengar', 'dapat', 'tutup']
48	['azab', 'azab pedih', 'pedih', 'umat', 'kufur', 'nabi', 'anugerah kepada', 'akhirat', 'bagi', 'qub']
49	['sembah', 'kaum sembah', 'sembah sembah', 'kaum', 'ayah kaum', 'bapak kaum', 'hud wahai', 'sembah pernah', 'tekun sembah', 'tekun']

Pada tabel Tabel 4.14 jika dianalisis terhadap kata-kata dominan pada tabel menunjukkan bahwa topik-topik yang dihasilkan memiliki koherensi semantik yang jelas dan mencerminkan tema-tema seperti ketuhanan, kenabian, keimanan, akhlak, eskatologi (hari kiamat, surga, dan neraka), ilmu pengetahuan (*science*), sosial, dan hukum.

4.5 Penggabungan hasil topik model CTM dan BERTopic

Berdasarkan hasil pemodelan topik menggunakan metode CTM pada tabel 4.10 dan BERTopic pada tabel 4.14, dilakukan proses pencocokan topik menggunakan pendekatan *Jaccard similarity* berbasis kata kunci dengan nilai *similarity*. Hasilnya pada tabel 4.15 berikut:

Tabel 4. 15 Penggabungan Topik CTM dan BERTopik dengan nilai Similarity

Topik CTM	Topik BERT	Similarity	Kata Kunci CTM	Kata Kunci BERTopic
1	8	0.25	rezeki, baik, ampun, siapa, bagi, hamba, saudara	bagi, saudara, perempuan, Perempuan, ..
3	18	0.25	gunung, kekal, sungai, jahanam, masuk, wajah, ...	kekal, huni neraka, kekal dalam, api, buruk, d...
4	0	0.25	tahu, langit, mudah, hati, takwa, rasul, hari,...	langit, cipta, maha, segala, ada bumi, ada lan...
9	3	0.1905	sama, wahai, maha, kata, mati, kerja, hanya, k...	kufur, sama, hati, wahai, agama, iman kepada, ...
0	38	0.1364	duduk, binasa, gembira, aun, bawa, masing, fir...	mukjizat, fir aun, sihir, aun, kena, kena sihi...
6	9	0.1364	takut, manusia, tuhan, kafir, tidak, turun, an...	kikir, karunia, syukur, anugerah, pinjam, kaya...
2	4	0.087	timpa, kufur, amal, ayat, azab, malam, akhirat...	nyawa, akhirat, mati, bunuh, mati hidup, hidup...

5	13	0.087	umpama, mulia, cipta, pasang, api, lihat, mata...	mabuk, bakar, air panas, didih, gelas, minum, ...
7	1	0.087	kitab, jalan, kufur, ajar, bagi, minta, terang...	arab, nabi, bagi, agama, benar, muslim, islam,...
8	2	0.087	sendiri, dua, niscaya, orang, diri, tunjuk, ma...	jalan, jauh, masuk, lurus, golong, paling, jal...

Berdasarkan hasil pencocokan topik menggunakan *Jaccard Similarity* dan greedy 1:1, diperoleh pasangan topik antara model CTM dan BERTopic dengan nilai kemiripan yang bervariasi. Secara umum nilai *similarity* tertinggi 0.2500, Nilai *similarity* terendah 0.0870, dengan rata-rata berada pada rentang 0.08 – 0.25.

CTM Topik 1 dengan BERTopic 8 bisa digabungkan dengan nilai *similarity* 0.25 berarti Topik CTM 1 dan BERTopic 8 memiliki kesamaan kata seperti “bagi” dan “saudara” yang menunjukkan tema distribusi atau hubungan sosial dalam konteks ajaran Islam. begitupun dengan topik CTM Topik 3 dengan BERTopic 18, CTM Topik 4 dengan BERTopic 0, dan lainnya seperti pada tabel 4.15.

4.5.1 Interpretasi Kata Kunci Topik

Berdasarkan hasil penggabungan pemodelan topik CTM dan BERTopic, diperoleh struktur tema besar yang terdiri dari sembilan kategori utama, yaitu aqidah, akhlak, eskatologi, syariah, muamalah, fenomena alam (kauniyah), ilmu pengetahuan, kisah umat terdahulu (history), aspek emosional dan kondisi bathin manusia (psikologi). Adapun rincian dari kategori utama seperti pada tabel 4.16 berikut:

Tabel 4. 16 Interpretasi dari hasil topik

Topik	Tema Inti	Kategori Besar
-------	-----------	----------------

0	['bumi', 'langit', 'langit bumi', 'cipta', 'ada', 'maha', 'milik', 'cipta langit', 'segala', 'ada langit']	Penciptaan langit & bumi	Science dan Ilmu Pengetahuan
1	['iman', 'wahai iman', 'wahai', 'agama', 'benar', 'iman kepada', 'kufur', 'kepada', 'iman jangan', 'ada']	Kebenaran & ketuhanan	Aqidah (teologi)
2	['hidup', 'mati', 'akhirat', 'dunia', 'hidup dunia', 'hidup mati', 'mati hidup', 'dunia akhirat', 'nyawa', 'bumi']	Dunia & akhirat	Eskatologi
3	['jahat', 'laku', 'manusia', 'cipta', 'hina', 'durhaka', 'benar', 'jahanam', 'duga', 'siapa']	Moral manusia (baik-buruk)	Akhlaq
4	['nabi', 'jihad', 'muslim', 'arab', 'islam', 'agama', 'ibrahim', 'iman', 'masjid', 'bahasa']	Kenabian & Islam (religi)	Aqidah (teologi)
5	['ayat', 'ayat ayat', 'kitab', 'baca', 'dusta ayat', 'turun', 'jelas', 'olok', 'dusta', 'hikmah']	Wahyu & Al-Qur'an	Aqidah (teologi)
6	['rasul', 'bukti', 'rasul rasul', 'bukti bukti', 'orang rasul', 'datang', 'rasul datang', 'kepada', 'bawa', 'benar']	Rasul & bukti	Aqidah
7	['tuhan', 'maha', 'tuhan tuhan', 'nama tuhan', 'tuhan maha',	kebesaran Tuhan	Aqidah

	'nama', 'agung', 'benar', 'tuhan benar', 'tuhan sudah']		
8	['perempuan', 'istri', 'laki', 'istri istri', 'anak', 'saudara', 'laki laki', 'halal', 'perempuan perempuan', 'bagi']	Gender dan Keluarga	Syariah
9	['kafir', 'kaum kafir', 'iman', 'azab', 'kafir azab', 'ada', 'dapat', 'beri', 'benar', 'jangan']	Kekafiran dan Azab	Eskatologi
10	['api', 'air', 'minum', 'panas', 'gelas', 'batu', 'air panas', 'mabuk', 'mata', 'mata air']	Unsur alam dan muamalah manusia	Mumalah
11	['malam', 'siang', 'matahari', 'bulan', 'waktu', 'tanda', 'malam siang', 'pagi', 'petang', 'bintang']	Fenomena waktu & kosmos	Alam (Kauniyah)
12	['ingat', 'beri ingat', 'nenek', 'moyang', 'nenek moyang', 'orang beri', 'beri', 'dahulu', 'mimpi', 'ingat ingat']	Tradisi nenek moyang	History
13	['anugerah', 'karunia', 'syukur', 'rahmat', 'nikmat', 'beri', 'kaya', 'kikir', 'besar', 'senang']	Nikmat & syukur	Akhlak
14	['dosa', 'dosa dosa', 'pikul', 'ampun', 'pikul dosa', 'dosa besar', 'buat dosa', 'buat', 'salah', 'ada']	Dosa & taubat	Syariah
15	['hari', 'celaka hari', 'hari dusta', 'dusta', 'celaka', 'dusta']	Hari pembalasan	Eskatologi

	celaka', 'hari putus', 'hari manusia', 'main', 'balas hari']		
16	['tolong', 'golong', 'masuk', 'golong besar', 'datang', 'panggil', 'segera', 'tolong tolong', 'masuk golong', 'golong tangguh']	Golongan manusia	Eskatologi
17	['malaikat', 'malaikat malaikat', 'sujud', 'turun malaikat', 'turun', 'malaikat sujud', 'nama', 'tuhan', 'datang malaikat', 'lihat malaikat']	Malaikat, Ketaatan	Aqidah
18	['jangan', 'bukankah', 'jangan sekali', 'gesa', 'sekali kali', 'tidak', 'kali', 'sekali', 'daya', 'tipu']	Larangan (normatif)	Muamalah (Sosial, Ekonomi)
19	['hamba', 'hamba hamba', 'hamba pilih', 'rezeki', 'maha', 'pilih', 'zalim hamba', 'sahaya', 'hamba sahaya', 'hendak hamba']	Hamba (penghambaan)	Aqidah
20	['kebun', 'buah', 'pohon', 'buah buah', 'kurma', 'kebun kebun', 'tumbuh', 'pohon kurma', 'taman', 'biji']	Kebun, buah & tumbuhan	Alam (Kauniyah)
21	['main', 'takwa', 'tanya urusan', 'wahai utus', 'penting wahai', 'ganjar takwa', 'urusan penting', 'qqah', 'tulis']	Ketakwaan	Akhlak
22	['neraka', 'api neraka', 'huni neraka', 'api', 'huni', 'tempat',	Neraka	Eskatologi

	'buruk', 'kekal dalam', 'kekal', 'neraka kekal']		
23	['takut', 'rasa takut', 'rasa', 'sedih', 'takut timpa', 'hati', 'tuhan takut', 'takut tuhan', 'takut hari', 'tuhan']	Rasa takut (khauf)	Psikologi
24	['setan', 'setan setan', 'teman', 'dua', 'setan jadi', 'setan musuh', 'musuh', 'iblis', 'buat', 'janji']	Setan & iblis	Aqidah
25	['anak', 'keluarga', 'miskin', 'barang', 'yatim', 'anak yatim', 'anak anak', 'kerabat', 'susu', 'barang barang']	Anak yatim & sosial	muamalah (sosial)
26	['kiamat', 'hari kiamat', 'hari', 'datang', 'kiamat datang', 'jadi kiamat', 'hari jadi', 'putus hari', 'tiba', 'selisih']	Hari kiamat	Eskatologi
27	['jalan', 'jauh', 'jalan lurus', 'lurus', 'sesat', 'lubang', 'sanggup', 'ejek', 'tempat', 'sesat jauh']	kebenaran , dan kesesatan	Aqidah
28	['sekutu', 'sekutu sekutu', 'tentara', 'musuh', 'bala tentara', 'bala', 'perang', 'bimbing', 'sama', 'tenggelam']	Perang & konflik	Syariah
29	['rusak', 'buat rusak', 'sapi', 'buruk', 'ternak', 'buat', 'hewan', 'hewan ternak', 'tujuh', 'ekor']	Alam dan hewan	Alam (Kauniyah)

30	['saksi', 'saksi atas', 'atas', 'saksi saksi', 'dua saksi', 'dua', 'maha saksi', 'beri saksi', 'cukup saksi', 'sumpah']	Saksi & hukum	Syariah
31	['langit', 'awan', 'angin', 'hujan', 'tumpuk', 'terus', 'langit belah', 'terbang', 'barat', 'turun']	Langit, hujan & angin	Science dan Ilmu Pengetahuan
32	['ikan', 'kapal', 'laut', 'ikan kepada', 'tanda', 'kepada', 'masing', 'layar', 'tanda tanda', 'syukur']	Laut & kapal	Alam (Kauniyah)
33	['salat', 'doa', 'laksana salat', 'laksana', 'doa tuhan', 'zakat', 'tuhan', 'iman', 'rezeki anugerah', 'infak bagi']	Ibadah (salat, zakat)	Syariah
34	['lihat', 'lihat lihat', 'kelak lihat', 'lihat kelak', 'jahim', 'tengah', 'perhati', 'kelak', 'tengok', 'tengah jahim']	Visualisasi akhirat	Eskatologi
35	['nikmat tuhan', 'tuhan mana', 'mana dusta', 'dusta nikmat', 'mana', 'nikmat', 'dusta', 'tuhan', 'tawakal', 'gila nikmat']	Nikmat didustakan	Akhlaq
36	['janji', 'janji benar', 'kapan janji', 'kapan', 'benar janji', 'penuh janji', 'benar', 'ingkar janji', 'tepat janji', 'tepat']	Janji Allah	Aqidah
37	['sihir', 'mukjizat', 'kena sihir', 'fir aun', 'aun', 'fir', 'kena',	sihir & mukjizat	History

	'sihir pandai', 'kepada sihir', 'musa']		
38	['burung', 'mukmin', 'burung burung', 'masing', 'sarang', 'semut', 'bagi mukmin', 'gembira mukmin', 'kubur', 'tanda']	Hewan & tanda	Alam (Kauniyah)
39	['kerja', 'usaha', 'bagi usaha', 'pertanggungjawaban', 'minta pertanggungjawaban', 'tahu kerja', 'atas kerja', 'baik kerja', 'kerja lut', 'pertanggungjawaban atas']	Usaha & tanggung jawab	Akhlak
40	['gunung', 'gunung gunung', 'pancang', 'bumi gunung', 'rumah', 'bumi', 'amanat', 'jalan', 'hancur', 'jalan jalan']	Gunung & bumi	Science dan Ilmu Pengetahuan
41	['sungai', 'sungai sungai', 'surga', 'alir bawah', 'alir', 'bawah', 'bawah sungai', 'surga alir', 'sungai kekal', 'kekal dalam']	Sungai surga	Eskatologi
42	['amal', 'amal saleh', 'iman amal', 'saleh', 'iman', 'surga', 'adapun iman', 'adapun', 'tobat', 'saleh ampun']	Amal saleh	Akhlak
43	['azab', 'timpa', 'timpa azab', 'tiba', 'hari pedih', 'hak urus', 'pedih', 'tambah kepada', 'benar', 'azab selalu']	Azab (umum)	Eskatologi

44	['balas', 'sempurna', 'beri balas', 'baik', 'baik demikian', 'balas buat', 'demikian beri', 'cipta sempurna', 'sempurna sesuai', 'buat baik']	Balasan amal	Eskatologi
45	['anugerah', 'tuhan', 'karunia', 'rahmat', 'anugerah kepada', 'dapat bukti', 'dapat', 'tuhan anugerah', 'nyata tuhan', 'tuhan beri']	Anugerah & rahmat Allah	Aqidah
46	['surga', 'huni', 'ada surga', 'penuh nikmat', 'surga penuh', 'huni surga', 'nikmat', 'surga dekat', 'surga nikmat', 'masuk surga']	Surga	Eskatologi
47	['dengar', 'tuli', 'dapat dengar', 'suara', 'buta', 'telinga', 'bisik', 'tuli dengar', 'dapat', 'tutup']	Pendengaran & penolakan	Akhlaq
48	['azab', 'azab pedih', 'pedih', 'umat', 'kufur', 'nabi', 'anugerah kepada', 'akhirat', 'bagi', 'qub']	Azab umat terdahulu	History
49	['sembah', 'kaum sembah', 'sembah sembah', 'kaum', 'ayah kaum', 'bapak kaum', 'hud wahai', 'sembah pernah', 'tekun sembah', 'tekun']	sejarah dan ibadah	Aqidah

Berdasarkan tabel 4.16 diperoleh struktur tema besar yang terdiri dari sembilan kategori utama, yaitu :


1. aqidah (keimanan), dengan topik 1, 4, 5, 6, 7, 17, 19, 24, 27, 36, 45, 49)

2. akhlak (perilaku, moral, dan sikap manusia), dengan topik 3, 13, 21, 35, 39, 42, 47,
3. Eskatologi (akhirat) dengan topik 2, 9, 15, 16, 22, 26, 34, 41, 43, 44, 46,
4. Syariah (hukum, ibadah, dan aturan kehidupan manusia), dengan topik 8, 14, 28, 30, 33
5. Muamalah (Interaksi sosial dan aturan kehidupan bermasyarakat.), dengan topik 10, 18, 25
6. Alam Fenomena alam sebagai tanda kebesaran Tuhan, seperti kosmos, tumbuhan, hewan, laut, ekosistem. Dengan topik 11, 20, 29, 32, 38
7. Ilmu Pengetahuan (Ilmu Pengetahuan) seperti penciptaan langit & bumi, hujan & angin, gunung dan bumi. Dengan topik 0, 31, 40
8. *History* (Kisah umat terdahulu dan peristiwa masa lalu) pada topik 12, 37, 48
9. Psikologi (Aspek emosional dan kondisi batin manusia) seperti rasa takut (khauf), kondisi psikologis manusia. Dengan topik 23

Distribusi topik menunjukkan bahwa kategori Aqidah dan Eskatologi mendominasi, diikuti oleh Akhlak dan Syariah, sementara kategori lain seperti Alam, History, dan Psikologi berperan sebagai pelengkap yang memperkaya konteks makna. Hal ini menegaskan bahwa struktur tematik Al-Qur'an berpusat pada keimanan dan akhirat, namun tetap terintegrasi dengan aspek sosial, moral, dan fenomena alam.

4.5.2 Distribusi Topik terhadap Dokumen

Pada tahap ini, dilakukan analisis distribusi topik terhadap dokumen untuk memahami bagaimana setiap topik yang dihasilkan oleh model *topic modeling* tersebar pada surat dan ayat tertentu. Analisis ini bertujuan untuk mengidentifikasi pola kemunculan topik, baik yang bersifat dominan pada bagian tertentu maupun yang tersebar secara merata.



Gambar 4. 12 Distribusi topik pada Surat Al-Fatihah, Al-Baqarah dan Ali Imran

Grafik pada gambar 4.12 menunjukkan contoh distribusi topik terhadap ayat pada tiga surat, yaitu Surat Al-Fatihah (Surat 1), Al-Baqarah (Surat 2), dan Ali Imran (Surat 3). Pada Surat Al-Fatihah, terlihat bahwa jumlah ayat yang terbatas menghasilkan distribusi topik yang sangat sederhana, dengan hanya beberapa titik yang tersebar dan cenderung mengelompok pada topik tertentu. Hal ini menunjukkan bahwa kandungan tematik dalam surat ini relatif singkat dan terfokus.

Pada surat Al-Baqarah memperlihatkan penyebaran titik yang jauh lebih padat dan beragam disepanjang sumbu ayat maupun topik, yang mengindikasikan kompleksitas tema yang tinggi serta variasi topik yang luas. Sementara itu, Surat Ali Imran menunjukkan pola distribusi yang juga beragam namun tidak sepadat Al-Baqarah, mencerminkan tingkat kompleksitas tematik yang berada di antara kedua surat sebelumnya. Secara keseluruhan, visualisasi ini menunjukkan bahwa panjang dokumen (jumlah ayat) berpengaruh terhadap keragaman topik yang dihasilkan, di mana surat yang lebih panjang cenderung memiliki distribusi topik yang lebih kompleks dan variatif.


4.6 Implementasi Aplikasi

Implementasi aplikasi pada penelitian ini bertujuan untuk merealisasikan hasil analisis pemodelan topik yang telah dilakukan ke dalam suatu sistem

berbasis web. Sistem ini dirancang untuk memungkinkan pengguna melakukan eksplorasi terhadap topik-topik yang dihasilkan dari teks terjemahan Al-Qur'an, baik dalam bentuk distribusi topik, hubungan antar topik, maupun representasi kata kunci.

4.6.1 Arsitektur Sistem

Aplikasi dikembangkan menggunakan arsitektur berbasis *client-server*, di mana proses utama dilakukan pada sisi backend menggunakan Flask, sementara pengguna berinteraksi melalui antarmuka web. Gambaran Arsitektur sistem seperti pada gambar 4.13 berikut ini.




Gambar 4. 13 Arsitektur Sistem

Pada gambar 4.13 diatas komponen sistem *frontend* yang digunakan HTML, CSS, Bootstrap Backend Flask (Python), Database dengan MySQL Model NLP yang dimunculkan hanya BERTopic dan CTM dan Library pendukung seperti Sastrawi (*preprocessing*), SentenceTransformer (*embedding*), UMAP & HDBSCAN (*clustering*)

4.6.2 Implementasi dashboard

Gambar 4.14 berikut adalah *layout* pertama yaitu *page login* dan dashboard akan tampil dashboard ketika berhasil login.




Gambar 4. 14 Page login dan *Dashboard* system

Pada gambar 4.14 untuk page dashboard menampilkan beberapa informasi seperti total dokumen, jumlah ayat yang dianalisis, beberapa nilai metrik pemodelan juga grafik menampilkan distribusi topik pada setiap surat.

4.6.3 Implementasi Preprocessing Teks

Fitur *preprocessing* dilakukan pada aplikasi sesuai dengan tahap preprocessing menjadi 3 jenis yaitu *basic* (minimal), *no stemming*, *advanced*.



Gambar 4. 15 *Fitur Preprocessing*

Pada gambar 4.15 selain 3 jenis *preprocessing*, ada fitur template agar dataset sesuai dengan format aplikasi yang digunakan. Fasilitas tombol tanpa *preprocessing* digunakan untuk dataset yang sudah siap dilakukan pemodelan secara langsung.

4.6.4 Implementasi pemodelan CTM

Implementasi sistem pemodelan CTM diberikan informasi hasil dari *preprocessing* seperti jumlah token yang terbentuk, jumlah dokumen, nilai reduksi token (%), reduksi kosakata (%), dan preservasi makna (%) seperti pada gambar 4.16 berikut.

Analisis Dokumen Keagamaan

Sistem Pemodelan Topik Keagamaan

Model CTM

Model CTMHasil Model

Hasil Preprocessing

File aktif diproses dengan metode tanpa Preprocessing dan siap digunakan untuk analisis topik.

TOTAL TOKEN

60,070

UNIQUE WORDS

2,341

DOKUMEN

5,765

REDUKSI TOKEN (%)

0.00%

REDUKSI KOSAKATA (%)

0.00%

PRESERVASI MAKNA (%)

0.00%

File Hasil Preprocessing

☒

no_preprocessed_20260403_185706_bertopic_documents_editable.csv

DownloadHapus

☐

no_preprocessed_20260401_173840_bertopic_documents_editable.csv

DownloadHapus

Optimasi & Pengaturan Model

CTM Configuration

Atur jumlah topik, lalu jalankan optimasi untuk rekomendasi K terbaik.

Jumlah Topik (K)

10

Default: 10

Range: 2 - 50

Optimasi K Value CTM

Mulai Analisis Topik

Gambar 4. 16 Implementasi Analisa Model CTM pada system

Pada tahap pemodelan CTM diberikan fitur pengujian untuk optimasi nilai K pada model CTM, dengan range nilai K yang diinginkan uotput nilai *Log-Likelihood* (LL), *Coherence Score*, *Diversity*, Quality dan rekomendasi nilai optimal setelah proses optimasi seperti pada Gambar 4.17 berikut.

CTM K Parameter Optimization

Tentukan rentang K yang akan diuji:

Sistem akan menguji setiap nilai K dan memberikan rekomendasi terbaik berdasarkan multiple metrics.

K Minimum (Start)

8

Mulai dari nilai K ini

hingga

K Maximum (End)

15

Berakhir di nilai K ini

Metrik Evaluasi:

Coherence (40%)

Log-Likelihood (30%)

Diversity (20%)

Quality (10%)

Cancel

Start Optimization

Gambar 4. 17 Implementasi Optimasi nilai K pada model CTM

Gambar 4.17 merupakan salah satu fitur implementasi pada model CTM untuk metatraining nilai optimal. Adapun hasil output berupa nilai dan grafik dari optimasi seperti pada gambar 4.18 berikut.



Gambar 4. 18 Output nilai optimasi K dan grafik nilai dari optimasi

Hasil dari pemodelan CTM diimplementasikan dengan topik yang terbentuk dan beberapa output visualisasi grafik untuk memudahkan analisis. Selain itu terdapat fitur dimana nilai rekomendasi yang bisa digunakan ditunjukkan dengan icon bintang, dan disediakan tombol *accept recommendation* untuk secara langsung mengambil nilai yang direkomendasikan oleh sistem.

Setelah proses optimasi maka dilakukan pengolahan topik menggunakan model CTM dari beberapa parameter yang dihasilkan, sehingga terbentuk hasil pemodelan topik dari model CTM, berikut gambaran implementasi pada aplikasi terkait hasil pemodelan menggunakan model CTM seperti pada gambar 4.19 berikut.



4.6.5 Implementasi Model BERTopic

UNIVERSITAS PAMULANG

Gambar 4. 20 Implementasi pemodelan BERTopic pada sistem

Setelah dilakukan pemrosesan model topik dengan model BERTopic maka output yang dihasilkan adalah beberapa topik yang terbentuk seperti gambar 4.22 berikut:

Topik BERTopic			
Topik 0 297 allah(0.020) nabi(0.016) arab(0.013) allah(0.020), nabi(0.016), arab(0.013), muslim(0.012), azab(0.011), iman(0.010), kufur(0.010), ibrahim(0.010) Tingkat relevansi: N/A	Topik 1 152 benar(0.023) dusta(0.022) jahat(0.019) benar(0.023), dusta(0.022), jahat(0.019), manusia(0.018), laku(0.017), hina(0.017), benar benar(0.016), daya(0.016) Tingkat relevansi: N/A	Topik 2 147 bumi(0.064) langit(0.062) langit bumi(0.050) bumi(0.064), langit(0.062), langit bumi(0.050), ada(0.032), maha(0.028), milik(0.028), ada langit(0.027), segala(0.026) Tingkat relevansi: N/A	Topik 3 117 iman(0.091) iman kepada(0.026) benar(0.025) iman(0.091), iman kepada(0.026), benar(0.025), banyak iman(0.024), agama(0.021), banyak(0.021), tanda banyak(0.020), kepada(0.019) Tingkat relevansi: N/A
Topik 4 102 ayat(0.133) ayat ayat(0.086) kitab(0.049) ayat(0.133), ayat ayat(0.086), kitab(0.049), baca(0.032), dusta ayat(0.031), ayat allah(0.024), dusta(0.020), hikmah(0.019) Tingkat relevansi: N/A	Topik 5 101 maha(0.044) tuhan(0.031) tahu(0.027) maha(0.044), tuhan(0.031), tahu(0.027), kuasa(0.027), bijaksana(0.025), maha bijaksana(0.025), allah(0.025), nama(0.023) Tingkat relevansi: N/A	Topik 6 101 kafir(0.109) kaum kafir(0.018) allah(0.017) kafir(0.109), kaum kafir(0.018), allah(0.017), iman(0.015), mukmin(0.013), beri(0.012), ada(0.012), jenger(0.012) Tingkat relevansi: N/A	Topik 7 99 tuhan(0.054) maha(0.026) sayang(0.025) tuhan(0.054), maha(0.026), sayang(0.025), maha sayang(0.024), tuhan maha(0.022), tuhan tuhan(0.018), ampun(0.018), mohon ampun(0.017) Tingkat relevansi: N/A
Topik 8 98 perempuan(0.063) istri(0.056) laki(0.041) perempuan(0.063), istri(0.056), laki(0.041), anak(0.033), istri istri(0.028), saudara(0.027), laki laki(0.026), perempuan perempuan(0.022) Tingkat relevansi: N/A	Topik 9 91 ingat(0.102) beri ingat(0.070) negeri(0.059) ingat(0.102), beri ingat(0.070), negeri(0.059), nenek moyang(0.046), nenek(0.046), moyang(0.046), orang beri(0.041), beri(0.034) Tingkat relevansi: N/A	Topik 10 85 karunia(0.044) anugerah(0.042) rahmat(0.034) karunia(0.044), anugerah(0.042), rahmat(0.034), karunia allah(0.036), allah(0.034), syukur(0.023), tuhan(0.022), beri(0.021) Tingkat relevansi: N/A	Topik 11 81 dosa(0.153) dosa dosa(0.061) pikul(0.027) dosa(0.153), dosa dosa(0.061), pikul(0.027), ampun(0.023), pikul dosa(0.021), dosa besar(0.021), buat dosa(0.019), siapa(0.018) Tingkat relevansi: N/A
Prev Page 1 / 5 Next			


Gambar 4. 21 hasil topik dengan model BERTopic

Gambar 4.21 merupakan hasil topik yang terbentuk dari pemodelan BERTopic, pada layout ini disediakan page topik untuk memudahkan user ketika jumlah topik yang dihasilkan begitu banyak.

4.6.6 Impelementasi Penggabungan Hasil Topik

Setelah dilakukan pemodelan topik dari model CTM atau BERTopic, maka pada aplikasi terdapat fitur metode penggabungan model topik menggunakan algoritma *Jaccard Index* pada kedua topik. Dengan menggunakan nilai Similiarity sebagai pendekatan kedua topik.


Adapun layout yang ditampilkan pada aplikasi seperti pada gambar 4.22 berikut:



Gambar 4. 22 Penggabungan Hasil topik model CTM dan BERTopic dengan *Jaccard Index*

Pada gambar 4.22 terdapat beberapa informasi fitur diantaranya informasi hasil topik pemodelan CTM dan hasil pemodelan BERTopic, kemudian hasil dari penghitungan *Jaccard Index* yang mengelompokkan hasil topik sesuai dengan perhitungan nilai similarity yang dihasilkan, dan user pun bisa melihat informasi topik secara keseluruhan setelah penggabungan topik CTM dan BERTopic dilakukan, dari informasi topik ini user bisa mengintepretasikan topik yang terbentuk.


Selain dari rangakain pengolahan pemodelan topik CTM dan BERTopic juga terdapat beberapa fitur visualisasi yang ditampilkan oleh sistem seperti, *Correlation Matrix*, Topic Word Distribution, Coherence Comparison, Intertopic Distance Map. Berikut salah satu visual gambar berikut:



Gambar 4. 23 *CTM Correlation Matrix*

Gambar 4.23 merupakan salah satu visualisasi dari hasil pemodelan *corelation matrix* pada CTM, adapapun untuk visualisai pada model BERTopic seperti *Intertopic Distance Map*, *Similiarity Heatmap*, dan *topic word score*. Berikut contoh salah satu visualisai *topic word score* pada gambar 4.24 berikut:

Visualisasi BERTopic



Gambar 4. 24 *Topic Word Score*

BAB V

KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan hasil penelitian yang telah dilakukan terhadap pemodelan topik pada teks terjemahan Al-Qur'an berbahasa Indonesia menggunakan metode CTM dan BERTopic, diperoleh kesimpulan sebagai berikut:

1. Pembangunan model diawali dengan pemilihan skema *preprocessing* terbaik, yaitu *preprocessed advanced*, yang memberikan keseimbangan optimal antara reduksi token (44,49%), reduksi kosakata (83,75%), dan preservasi makna (73,20%). Pada model CTM, optimasi jumlah topik dilakukan melalui kombinasi metrik *log-likelihood*, *topic diversity*, *topic quality*, dan *composite score*, menghasilkan nilai K optimal = 14 topik. Proses pelatihan dilakukan secara iteratif sebanyak 400 iterasi, dengan model mencapai konvergensi pada iterasi ke-100 (*log-likelihood* -6.8747). Pada model BERTopic, optimasi dilakukan terhadap parameter *min_topic_size*, dengan nilai optimal diperoleh pada 25, yang memberikan keseimbangan terbaik antara jumlah topik dan kualitas koherensi.
2. Pengukuran kualitas dan akurasi dilakukan menggunakan metrik koherensi topik pada kedua model. Model CTM menghasilkan nilai $C_v = 0,517$, $NPMI = -0,226$, $UMass = -5,0661$, $UCI = -2,1370$, dan $perplexity = 1720,28$, dengan korelasi antar topik yang relatif rendah (-0,15 hingga 0,12) menunjukkan model mampu membedakan tema secara baik meski koherensi internalnya masih pada tingkat sedang. Model BERTopic menghasilkan koherensi $C_v = 0,5735$ ($>0,5$, tergolong cukup baik), $NPMI = 0,0530$ (positif, menandakan asosiasi statistik antar kata yang bermakna), dan $UMass = -5,3257$ (nilai terbaik/paling mendekati nol dibanding konfigurasi lain), yang menunjukkan konsistensi probabilistik model terhadap distribusi dokumen.
3. Penentuan tema utama tidak hanya bersandar pada metrik statistik (*Jaccard similarity*), tetapi juga divalidasi secara kualitatif melalui Human

Interpretability Analysis, dengan Model CTM menghasilkan 14 topik yang diinterpretasikan ke dalam beberapa kelompok tema, yaitu Ketauhidan dan Keimanan/Aqidah (Topik 2, 5, 10, 12), Hari Pembalasan dan Azab/Eskatologi (Topik 7, 8, 9), Sejarah dan Umat (Topik 1, 3), Hukum dan Sosial/Muamalah (Topik 11), serta Wahyu dan Peringatan (Topik 0, 6). Model BERTopic menghasilkan 50 topik dengan kata-kata dominan yang mencerminkan tema ketuhanan, kenabian, keimanan, akhlak, eskatologi (hari kiamat, surga, neraka), ilmu pengetahuan, sosial, dan hukum — menunjukkan koherensi semantik yang jelas pada tiap topik.

4. Melalui penggabungan topik CTM dan BERTopic menggunakan pendekatan Jaccard similarity, ditemukan keterkaitan antar topik dengan tingkat kemiripan relatif rendah hingga sedang (0,08–0,25). Dari hasil ini diperoleh struktur tematik utama yang mencakup sembilan kategori besar: aqidah, akhlak, eskatologi, syariah, muamalah, fenomena alam, sejarah, ilmu pengetahuan, dan aspek psikologis. Distribusi topik menunjukkan bahwa kategori aqidah dan eskatologi menjadi tema paling dominan, didukung oleh tema-tema lain sebagai pelengkap. Analisis lanjutan juga menunjukkan bahwa panjang dan kompleksitas surat memengaruhi keragaman topik, surat pendek cenderung memiliki distribusi topik yang sederhana dan terfokus, sedangkan surat panjang memiliki distribusi topik yang lebih kompleks dan variatif.
5. Analisis distribusi topik terhadap dokumen menunjukkan bahwa panjang dan kompleksitas surat mempengaruhi keragaman topik yang dihasilkan. Surat dengan jumlah ayat yang sedikit cenderung memiliki distribusi topik yang sederhana dan terfokus, sedangkan surat yang lebih panjang memiliki distribusi topik yang lebih kompleks dan variatif. Hal ini menunjukkan bahwa model topic modeling mampu menangkap dinamika tematik berdasarkan struktur dokumen.

Secara keseluruhan, penelitian ini menunjukkan bahwa kombinasi preprocessing yang tepat, optimasi parameter model, serta penggunaan dua pendekatan topic modeling (CTM dan BERTopic) dapat memberikan

pemahaman yang komprehensif terhadap struktur tematik dalam teks terjemahan Al-Qur'an.

5.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, terdapat beberapa saran yang dapat diberikan untuk pengembangan penelitian selanjutnya.

1. untuk meningkatkan kualitas hasil *topic modeling*, disarankan untuk mengkombinasikan metode lain seperti *Neural Topic Modeling* atau pendekatan berbasis transformer yang lebih sensitif terhadap konteks semantik seperti model *Contextual Topic Model*. Hal ini diharapkan dapat meningkatkan nilai coherence dan mengurangi keterbatasan pada model CTM maupun BERTopic.
2. permasalahan outlier yang cukup tinggi pada BERTopic dapat ditangani dengan eksplorasi parameter clustering yang lebih lanjut atau dengan pendekatan *hybrid clustering*. Selain itu, penggunaan dokumen dengan konteks yang lebih panjang (misalnya per ayat digabung menjadi per tema atau per surat) dapat membantu meningkatkan stabilitas *clustering*.
3. Penelitian ini masih terbatas pada teks terjemahan Al-Qur'an, sehingga penelitian selanjutnya dapat mengembangkan analisis pada teks tafsir atau hadis untuk memperoleh pemahaman tematik yang lebih dalam dan kontekstual.

DAFTAR PUSTAKA

- Aftari, D. P., Safaat, N., Agustian, S., Yusra, Y., & Afrianty, I. (2024). Perbandingan Performa Klasifikasi Terjemahan Al-Qur'an Menggunakan Metode Random Forest dan Long Short Term Memory. *Journal of Computer System and Informatics (JoSYC)*, 5(3), 567–577. <https://doi.org/10.47065/josyc.v5i3.5156>
- Alghamdi, R., & Alfalqi, K. (2015). A Survey of Topic Modeling in Text Mining Topic Over Time (TOT), Dynamic Topic Models (DTM), Multiscale Topic Tomography, Dynamic Topic Correlation Detection, Detecting Topic Evolution in scientific literatures, etc. Keywords-Topic Modeling; Methods of Topic Modeling; Latent Semantic Analysis (LSA); Probabilistic Latent Semantic Analysis (PLSA); Latent Dirichlet Allocation (LDA); Correlated Topic Model (CTM); Topic Evolution Model. In *IJACSA) International Journal of Advanced Computer Science and Applications* (Vol. 6, Issue 1). www.ijacsa.thesai.org
- Awaludin, A. (2025). Documenting the Half-Century Evolution of Islamic Education Research: A Correlated Topic Modeling (CTM) Study of the Literature from 1970 to 2023. *Proceedings of the 2025 AERA Annual Meeting*. <https://doi.org/10.3102/2178518>
- Bartolomeo, G. (2024). *Exploring the Power of Topic Modeling Techniques in Analyzing Customer Reviews: A Comparative Analysis*. <http://arxiv.org/abs/2308.06797>
- Blei, D. M., & Lafferty, J. D. (n.d.). *Correlated Topic Models*. www.jstor.org
- Blei, D. M., & Lafferty, J. D. (2007a). A correlated topic model of Science. *The Annals of Applied Statistics*, 1(1). <https://doi.org/10.1214/07-aos114>
- Blei, D. M., & Lafferty, J. D. (2007b). A correlated topic model of Science. *The Annals of Applied Statistics*, 1(1). <https://doi.org/10.1214/07-aos114>

- Blei, D. M., & Lafferty, J. D. (2007c). A correlated topic model of Science. *The Annals of Applied Statistics*, 1(1). <https://doi.org/10.1214/07-aos114>
- Blei, D. M., Ng, A. Y., & Edu, J. B. (2003). Latent Dirichlet Allocation Michael I. Jordan. In *Journal of Machine Learning Research* (Vol. 3).
- Brawijaya, U., Raditya, B., Listyawan, N., Setiawan, N. Y., & Saputra, M. C. (2017). *Fakultas Ilmu Komputer Topic Modelling Pada Aktivitas Pengembangan Perangkat Lunak Menggunakan BERTopic* (Vol. 1, Issue 1). <http://j-ptiik.ub.ac.id>
- Campello, R. J. G. B., Moulavi, D., & Sander, J. (n.d.). *Density-Based Clustering Based on Hierarchical Density Estimates*.
- Dwiyoga Widianoro Mustafid Ridwan Sanjaya, A. (2024). *PENGANTAR NLP DAN TOPIK MODEL LDA SAMPUL DALAM*.
- Geva, M., Schuster, R., Berant, J., & Levy, O. (n.d.). *Transformer Feed-Forward Layers Are Key-Value Memories*. <https://github.com/mega002/ff-layers/>.
- Habash, N. (2006). *Arabic Preprocessing Schemes for Statistical Machine Translation*.
- Havid Albar Purnomo, M., & Abdurrachman Bachtiar, F. (2021). *Pengelompokan Terjemah Al-Quran Departemen Agama menggunakan Metode Fuzzy C-Means* (Vol. 5, Issue 2). <http://j-ptiik.ub.ac.id>
- Herwinsyah. (2023). PEMODELAN TOPIK DALAM AL-QUR'AN MENGGUNAKAN LIBRARY BERTOPIC PADA MODEL BAHASA BERT. *Jurnal SIMETRIS*, 14(2), 1–327.
- Hutama, L. B., & Suhartono, D. (2022). Indonesian Hoax News Classification with Multilingual Transformer Model and BERTopic. *Informatica (Slovenia)*, 46(8), 81–90. <https://doi.org/10.31449/inf.v46i8.4336>
- Introduction to Information Retrieval IIR 19*. (n.d.).

- Joachims, T. (n.d.). *A Probabilistic Analysis of the Rocchio Algorithm with TFIDF for Text Categorization*.
- Khine Oo, M., & Aye Khine, M. (2018). *2018 IEEE 7th Global Conference on Consumer Electronics (GCCE) : 9-12 Oct. 2018*. IEEE.
- Khine Oo, M., & Aye Khine, M. (2019). Topic Extraction of Crawled Documents Collection using Correlated Topic Model in Mapreduce Framework. *International Journal on Natural Language Computing*, 8(6), 11–23. <https://doi.org/10.5121/ijnlc.2019.8602>
- Kiwasi Wororomi, J., Felix Reba, Ms., Aleksander Mandowen, S., Alvian Sroyer, M. M., Halomoan Edy Manurung, Ms., Mayko Edison Koibur, Mc., Erna Hudianti Pujiarini, Me., Marwan Ramdhany Edy, Ms., Hajjar Yuliana, Mk., Mukarramah Yusuf, M., & Marta Dinata, R. (2024). *DATA MINING (MEMAHAMI POLA DI BALIK ANGKA) PENERBIT CV.EUREKA MEDIA AKSARA*.
- McInnes, L., Healy, J., & Melville, J. (2020). *UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction*. <http://arxiv.org/abs/1802.03426>
- Mimno, D., Wallach, H. M., Talley, E., Leenders, M., & Mccallum, A. (n.d.-a). *Optimizing Semantic Coherence in Topic Models*.
- Mimno, D., Wallach, H. M., Talley, E., Leenders, M., & Mccallum, A. (n.d.-b). *Optimizing Semantic Coherence in Topic Models*.
- Murugaraj, K., Lamsiyah, S., During, M., & Theobald, M. (2025). *Mining the Past: A Comparative Study of Classical and Neural Topic Models on Historical Newspaper Archives*.
- Prof, O. :, & Tarumingkeng, R. C. (2024). *Natural Language Processing (NLP)*.
- Raihan, M. (n.d.). *DYNAMIC TOPIC MODELLING MENGGUNAKAN BERTOPIC DALAM PEMILIHAN PRESIDEN TAHUN 2019 Disusun Oleh*.

- Reimers, N., & Gurevych, I. (2019). *Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks*. <http://arxiv.org/abs/1908.10084>
- Röder, M., Both, A., & Hinneburg, A. (2015a). Exploring the space of topic coherence measures. *WSDM 2015 - Proceedings of the 8th ACM International Conference on Web Search and Data Mining*, 399–408. <https://doi.org/10.1145/2684822.2685324>
- Röder, M., Both, A., & Hinneburg, A. (2015b). Exploring the space of topic coherence measures. *WSDM 2015 - Proceedings of the 8th ACM International Conference on Web Search and Data Mining*, 399–408. <https://doi.org/10.1145/2684822.2685324>
- Rolliawati, D. (2024). *Text Mining Approach for Topic Modeling of Corpus Al Qur'an in Indonesian Translation*.
- Snyder, R. M., & Com, R. (2015). An Introduction to Topic Modeling as an Unsupervised Machine Learning Way to Organize Text Information. In *ASCUE Proceedings* (Vol. 86). <http://www.robinsnyder.com>
- Syahrial, S., & Afidh, R. P. F. (2024). Fine-Tuning Topic Modelling: A Coherence-Focused Analysis of Correlated Topic Models. *Infolitika Journal of Data Science*, 2(2), 82–87. <https://doi.org/10.60084/ijds.v2i2.236>
- Van Der Maaten, L. J. P., Postma, E. O., & Van Den Herik, H. J. (n.d.). *Dimensionality Reduction: A Comparative Review*.
- Wallach, H. M., Murray, I., Salakhutdinov, R., & Mimno, D. (n.d.). *Evaluation Methods for Topic Models*.

DAFTAR RIWAYAT HIDUP

1. Nama	: Asep Ridwan Hidayat	NIM	: 231012050036
2. Tempat/tgl. Lahir	: Sukabumi, 19 Agustus 1989	☒ / ☐	Pria Wanita
3. Agama	: Islam		
Jenjang Prodi/Jurusan Perguruan Tinggi Tahun Lulus	: Pascasarjana : Teknik Informatika S2 : Universitas Pamulang :		
5. Alamat rumah	: Jl Alhidayah Kp Basmol	No HP	
	Kec. Kembangan	085891668847	
	Kel. Kembangan Utara	e-mail	
	Jakarta Barat	asep.rid.hidayat@gmail.com	
6. Web pribadi	:	No. Telp	
7. Pekerjaan	: Wiraswasta		
8. Alamat Kantor	: Gd Palma one jl Rasuna Sa'id, Kuningan Timur, Jakarta	e-mail	
9. Web kantor	:		

LAMPIRAN

1. Contoh Dataset Terjemah Al-Qur'an Bahasa Indonesia Surat Alfatihah dan Al-Baqarah ayat 1-30:

Surat	Ayat	Teks
1	1	Segala puji bagi Allah, Tuhan semesta alam
1	2	Yang Maha Pengasih lagi Maha Penyayang,
1	3	Pemilik hari Pembalasan
1	4	Hanya kepada Engkaulah kami menyembah dan hanya kepada Engkaulah kami memohon pertolongan.
1	5	Bimbinglah kami ke jalan yang lurus
1	6	(yaitu) jalan orang-orang yang telah Engkau beri nikmat, bukan (jalan) mereka yang dimurkai dan bukan (pula jalan) orang-orang yang sesat.
2	1	Alif Laam Miim
2	2	Kitab (Al-Qur'an) ini tidak ada keraguan di dalamnya; (ia merupakan) petunjuk bagi orang-orang yang bertakwa,
2	3	(yaitu) orang-orang yang beriman pada yang gaib, menegakkan salat, dan menginfakkan sebagian rezeki yang Kami anugerahkan kepada mereka,
2	4	dan mereka yang beriman pada (Al-Qur'an) yang diturunkan kepadamu (Nabi Muhammad) dan (kitab-kitab suci) yang telah diturunkan sebelum engkau dan mereka yakin akan adanya akhirat.
2	5	Mereka lah yang mendapat petunjuk dari Tuhannya dan mereka itulah orang-orang yang beruntung.
2	6	Sesungguhnya orang-orang yang kufur itu sama saja bagi mereka, apakah engkau (Nabi Muhammad) beri peringatan atau tidak engkau beri peringatan, mereka tidak akan beriman.
2	7	Allah telah mengunci hati dan pendengaran mereka.) Pada penglihatan mereka ada penutup, dan bagi mereka azab yang sangat berat.
2	8	Di antara manusia ada yang berkata, Kami beriman kepada Allah dan hari Akhir," padahal sesungguhnya mereka itu bukanlah orang-orang mukmin.
2	9	Mereka menipu Allah dan orang-orang yang beriman, padahal mereka hanyalah menipu diri sendiri tanpa mereka sadari.
2	10	Dalam hati mereka ada penyakit,) lalu Allah menambah penyakitnya dan mereka mendapat azab yang sangat pedih karena mereka selalu berdusta.
2	11	Apabila dikatakan kepada mereka, Janganlah berbuat kerusakan di bumi,") mereka menjawab, Sesungguhnya kami hanyalah orang-orang yang melakukan perbaikan."

2	12	Ingatlah, sesungguhnya merekalah yang berbuat kerusakan, tetapi mereka tidak menyadari.
2	13	Apabila dikatakan kepada mereka, Berimanlah kamu sebagaimana orang lain telah beriman,” mereka menjawab, Apakah kami akan beriman seperti orang-orang yang picik akalnya itu beriman?” Ingatlah, sesungguhnya mereka itulah orang-orang yang picik akalnya, tetapi mereka tidak tahu.
2	14	Apabila mereka berjumpa dengan orang yang beriman, mereka berkata, Kami telah beriman.” Akan tetapi apabila mereka menyendiri dengan setan-setan (para pemimpin) mereka, mereka berkata, Sesungguhnya kami bersama kamu, kami hanya pengolok-olok.”
2	15	Allah akan memperolok-olokkan dan membiarkan mereka terombang-ambing dalam kesesatan.
2	16	Mereka itulah orang-orang yang membeli kesesatan dengan petunjuk. Maka, tidaklah beruntung perniagaannya dan mereka bukanlah orang-orang yang mendapatkan petunjuk.
2	17	Perumpamaan mereka seperti orang yang menyalakan api. Setelah (api itu) menerangi sekelilingnya, Allah melenyapkan cahaya (yang menyinari) mereka dan membiarkan mereka dalam kegelapan, tidak dapat melihat.
2	18	(Mereka) tuli, bisu, lagi buta, sehingga mereka tidak dapat kembali.
2	19	Atau, seperti (orang yang ditimpa) hujan lebat dari langit yang disertai berbagai kegelapan, petir, dan kilat. Mereka menyumbat telinga dengan jari-jarinya (untuk menghindari) suara petir itu karena takut mati. Allah meliputi orang-orang yang kafir.)
2	20	Hampir saja kilat itu menyambar penglihatan mereka. Setiap kali (kilat itu) menyinari, mereka berjalan di bawah (sinar) itu. Apabila gelap menerpa mereka, mereka berdiri (tidak bergerak). Sekiranya Allah menghendaki, niscaya Dia menghilangkan pendengaran dan penglihatan mereka. Sesungguhnya Allah Maha Kuasa atas segala sesuatu.
2	21	Wahai manusia, sembahlah Tuhanmu yang telah menciptakan kamu dan orang-orang yang sebelum kamu agar kamu bertakwa.
2	22	(Dialah) yang menjadikan bagimu bumi (sebagai) hamparan dan langit sebagai atap, dan Dialah yang menurunkan air (hujan) dari langit, lalu Dia menghasilkan dengan (hujan) itu buah-buahan sebagai rezeki untuk kamu. Oleh karena itu, janganlah kamu mengadakan tandingan-tandingan bagi Allah, padahal kamu mengetahui.
2	23	Jika kamu (tetap) dalam keraguan tentang apa (Al-Qur'an) yang Kami turunkan kepada hamba Kami (Nabi Muhammad), buatlah satu surah yang semisal dengannya dan ajaklah penolong-penolongmu selain Allah, jika kamu orang-orang yang benar.
2	24	Jika kamu tidak (mampu) membuat(-nya) dan (pasti) kamu tidak akan (mampu) membuat(-nya), takutlah pada api neraka yang

		bahan bakarnya adalah manusia dan batu yang disediakan bagi orang-orang kafir.
2	25	Sampaikanlah kabar gembira kepada orang-orang yang beriman dan beramal saleh bahwa untuk mereka (disediakan) surga-surga yang di bawahnya mengalir sungai-sungai. Setiap kali diberi rezeki buah-buahan darinya, mereka berkata, Inilah rezeki yang diberikan kepada kami sebelumnya.” Mereka telah diberi (buah-buahan) yang serupa dan di sana mereka (memperoleh) pasangan-pasangan yang disucikan. Mereka kekal di dalamnya.
2	26	Sesungguhnya Allah tidak segan membuat perumpamaan seekor nyamuk atau yang lebih kecil daripada itu.) Adapun orang-orang yang beriman mengetahui bahwa itu kebenaran dari Tuhannya. Akan tetapi, orang-orang kafir berkata, Apa maksud Allah dengan perumpamaan ini?” Dengan (perumpamaan) itu banyak orang yang disesatkan-Nya.) Dengan itu pula banyak orang yang diberi-Nya petunjuk. Namun, tidak ada yang Dia sesatkan dengan (perumpamaan) itu, selain orang-orang fasik.)
2	27	(yaitu) orang-orang yang melanggar perjanjian Allah setelah (perjanjian) itu diteguhkan, memutuskan apa yang diperintahkan Allah untuk disambungkan (silaturahmi), dan berbuat kerusakan di bumi. Mereka itulah orang-orang yang rugi.
2	28	Bagaimana kamu ingkar kepada Allah, padahal kamu (tadinya) mati, lalu Dia menghidupkan kamu, kemudian Dia akan mematikan kamu, Dia akan menghidupkan kamu kembali, dan kepada-Nyalah kamu dikembalikan?
2	29	Dialah (Allah) yang menciptakan segala yang ada di bumi untukmu, kemudian Dia menuju ke langit, lalu Dia menyempurnakannya menjadi tujuh langit.) Dia Maha Mengetahui segala sesuatu.
2	30	(Ingatlah) ketika Tuhanmu berfirman kepada para malaikat, Aku hendak menjadikan khalifah di bumi.” Mereka berkata, Apakah Engkau hendak menjadikan orang yang merusak dan menumpahkan darah di sana, sedangkan kami bertasbih memuji-Mu dan menyucikan nama-Mu?” Dia berfirman, Sesungguhnya Aku mengetahui apa yang tidak kamu ketahui.”

2. Contoh Dataset Terjemah Al-Qur'an Bahasa Indonesia Surat Alfatihah dan Al-Baqarah ayat 1-30 yang sudah dilakukan preprocessing

Surat	Ayat	Preprocessed
1	1	segala puji semesta alam
1	2	maha asih maha sayang
1	3	milik hari balas
1	4	engkau sembah hanya engkau mohon tolong
1	5	bimbing jalan lurus

1	6	jalan beri nikmat murka sesat
2	2	kitab ragu dalam tunjuk takwa
2	3	iman gaib tegak salat infak bagi rezeki anugerah
2	4	iman turun kepada turun yakin ada akhirat
2	5	mereka dapat tunjuk tuhan untung
2	6	kufur sama bagi apakah beri ingat beri ingat iman
2	7	kunci hati dengar lihat ada tutup bagi azab berat
2	8	manusia iman hari akhir padahal bukan mukmin
2	9	tipu iman padahal hanya tipu diri sendiri sadar
2	10	hati ada sakit tambah sakit dapat azab pedih selalu dusta
2	11	apabila kata jangan buat rusa bumi jawab hanya laku baik
2	12	ingat mereka buat rusa sadar
2	13	apabila kata rim bagaimana iman jawab iman picik akal iman ingat itu picik akal tahu
2	14	apabila jumpa iman iman apabila sendiri setan setan sama hanya olok olok
2	15	olok olok biar terombang ambing sesat
2	16	itu beli sesat tunjuk tidak untung niaga bukan dapat tunjuk
2	17	umpama seperti nyala api rang keliling lenyap cahaya biar gelap dapat lihat
2	18	tuli bisu buta dapat
2	19	seperti hujan lebat langit serta bagai gelap petir kilat sumbat telinga jari jari suara petir takut mati liput kafir
2	20	hampir kilat sambar lihat kali sari jalan bawah apabila gelap terpa diri sekira hendak niscaya hilang dengar lihat maha kuasa atas segala
2	21	wahai manusia sembah tuhan cipta takwa
2	22	jadi bagi bumi hampar langit atap dia turun air langit hasil buah buah rezeki jangan ada tanding tanding padahal tahu
2	23	ragu turun hamba buat satu surah misal dengan ajak tolong tolong benar
2	24	buat buat takut api neraka bahan bakar manusia batu sedia kafir
2	25	sampai kabar gembira iman amal saleh surga surga bawah alir sungai sungai kali beri rezeki buah buah dari ini rezeki beri belum beri rupa sana pasang pasang suci kekal dalam
2	26	segan buat umpama ekor nyamuk kecil adapun iman tahu benar tuhan kafir maksud umpama sesat beri tunjuk sesat fasik
2	27	langgar janji teguh putus perintah sambung buat rusa bumi itu rugi
2	28	ingkar padahal mati hidup mati hidup nyalah kembali
2	29	dia cipta segala ada bumi untuk tuju langit sempurna tujuh langit maha tahu segala
2	30	tuhan malaikat hendak jadi khalifah bumi hendak jadi rusak tumpah darah sana tasbih puji suci nama tahu tahu

3. Contoh Distribusi Topik Terjemah Al-Qur'an Bahasa Indonesia Surat Al-Fatihah dan Al-Baqarah ayat 1-30 pada model CTM:

sura	ayat	TOPIK									
		0	1	2	3	4	5	6	7	8	9
1	1	0.020	0.020	0.420	0.420	0.020	0.020	0.020	0.020	0.020	0.020
1	2	0.020	0.020	0.020	0.020	0.020	0.020	0.820	0.020	0.020	0.020
1	3	0.025	0.025	0.275	0.525	0.025	0.025	0.025	0.025	0.025	0.025
1	4	0.157	0.014	0.014	0.014	0.014	0.014	0.443	0.014	0.014	0.300
1	5	0.525	0.025	0.025	0.025	0.025	0.025	0.275	0.025	0.025	0.025
1	6	0.517	0.017	0.017	0.017	0.183	0.017	0.017	0.017	0.017	0.183
2	2	0.183	0.017	0.017	0.183	0.183	0.017	0.017	0.017	0.350	0.017
2	3	0.122	0.011	0.011	0.011	0.233	0.011	0.122	0.233	0.011	0.233
2	4	0.013	0.013	0.013	0.013	0.388	0.013	0.013	0.138	0.013	0.388
2	5	0.183	0.017	0.017	0.017	0.183	0.017	0.017	0.183	0.017	0.350
2	6	0.210	0.010	0.010	0.010	0.110	0.010	0.010	0.010	0.310	0.310
2	7	0.010	0.010	0.010	0.110	0.010	0.410	0.010	0.110	0.110	0.210
2	8	0.013	0.013	0.013	0.138	0.013	0.013	0.013	0.013	0.388	0.388
2	9	0.011	0.011	0.011	0.011	0.233	0.011	0.011	0.233	0.011	0.456
2	10	0.009	0.009	0.009	0.191	0.009	0.100	0.009	0.100	0.100	0.464
2	11	0.009	0.009	0.100	0.009	0.009	0.009	0.009	0.282	0.100	0.464
2	12	0.017	0.017	0.017	0.017	0.183	0.017	0.017	0.017	0.183	0.517
2	13	0.006	0.006	0.006	0.006	0.069	0.006	0.006	0.006	0.256	0.631
2	14	0.238	0.392	0.008	0.008	0.085	0.008	0.008	0.008	0.008	0.238
2	15	0.443	0.300	0.014	0.014	0.014	0.014	0.014	0.014	0.014	0.157
2	16	0.555	0.009	0.009	0.009	0.009	0.009	0.009	0.191	0.100	0.100
2	17	0.085	0.008	0.008	0.238	0.008	0.315	0.008	0.008	0.085	0.238
2	18	0.620	0.020	0.020	0.020	0.020	0.020	0.020	0.020	0.020	0.220
2	19	0.005	0.005	0.105	0.005	0.005	0.305	0.005	0.055	0.105	0.405
2	20	0.091	0.004	0.135	0.048	0.004	0.526	0.048	0.004	0.091	0.048
2	21	0.014	0.014	0.157	0.014	0.014	0.014	0.014	0.014	0.157	0.586
2	22	0.005	0.005	0.386	0.005	0.005	0.195	0.005	0.052	0.148	0.195
2	23	0.392	0.008	0.162	0.008	0.085	0.008	0.085	0.008	0.085	0.162
2	24	0.008	0.008	0.092	0.342	0.008	0.008	0.008	0.008	0.092	0.425
2	25	0.003	0.068	0.068	0.294	0.358	0.035	0.003	0.003	0.100	0.068
2	26	0.205	0.005	0.005	0.005	0.005	0.055	0.205	0.055	0.105	0.355
2	27	0.008	0.008	0.092	0.258	0.008	0.092	0.008	0.008	0.175	0.342
2	28	0.011	0.011	0.678	0.011	0.011	0.011	0.011	0.011	0.011	0.233
2	29	0.007	0.007	0.540	0.007	0.007	0.073	0.140	0.007	0.140	0.073
2	30	0.005	0.005	0.374	0.005	0.005	0.058	0.216	0.058	0.163	0.111

4. Contoh Distribusi Topik Terjemah Al-Qur'an Bahasa Indonesia Surat Al-Fatihah dan Al-Baqarah ayat 1-30 pada model BERTopic:

sura	ayat	topic	confidence	text
1	1	0	0.02	Segala puji bagi Allah, Tuhan semesta alam
1	2	3	0.07	Yang Maha Pengasih lagi Maha Penyayang,
1	3	-1	0.00	Pemilik hari Pembalasan
1	4	-1	0.00	Hanya kepada Engkaulah kami menyembah dan hanya kepada Engkaulah kami memohon pertolongan.
1	5	27	0.27	Bimbinglah kami ke jalan yang lurus
1	6	-1	0.00	(yaitu) jalan orang-orang yang telah Engkau beri nikmat, bukan (jalan) mereka yang dimurkai...
2	2	5	1.00	Kitab (Al-Qur'an) ini tidak ada keraguan di dalamnya; (ia merupakan) petunjuk bagi orang-orang yang ...
2	3	33	1.00	(yaitu) orang-orang yang beriman pada yang gaib, menegakkan salat...
2	4	-1	0.00	dan mereka yang beriman pada (Al-Qur'an) yang diturunkan kepadamu (Nabi Muhammad) ...
2	5	45	1.00	Merekalah yang mendapat petunjuk dari Tuhannya dan mereka itulah orang-orang yang beruntung.
2	6	1	0.24	Sesungguhnya orang-orang yang kufur itu sama saja bagi mereka, apakah engkau (Nabi Muhammad) ...
2	7	47	1.00	Allah telah mengunci hati dan pendengaran mereka.) Pada penglihatan mereka ada penutup, dan bagi mer...
2	8	1	0.04	Di antara manusia ada yang berkata, Kami beriman kepada Allah dan hari Akhir, padahal sesungguhnya...
2	9	1	0.12	Mereka menipu Allah dan orang-orang yang beriman, padahal mereka hanyalah menipu diri sendiri tanpa ...
2	10	-1	0.00	Dalam hati mereka ada penyakit,) lalu Allah menambah penyakitnya dan mereka mendapat azab yang sanga...
2	11	29	1.00	Apabila dikatakan kepada mereka, Janganlah berbuat kerusakan di bumi) mereka menjawab, Sesungguhnya...
2	12	29	1.00	Ingatlah, sesungguhnya merekalah yang berbuat kerusakan, tetapi mereka tidak menyadari.
2	13	1	0.30	Apabila dikatakan kepada mereka, Berimanlah kamu sebagaimana orang lain telah beriman, mereka ...
2	14	24	0.75	Apabila mereka berjumpa dengan orang yang beriman, mereka berkata, Kami telah beriman. Akan tetapi...
2	15	-1	0.00	Allah akan memperolok-olokkan dan membiarkan mereka terombang-ambing dalam kesesatan.
2	16	-1	0.00	Mereka itulah orang-orang yang membeli kesesatan dengan petunjuk. Maka, tidaklah beruntung ...
2	17	-1	0.00	Perumpamaan mereka seperti orang yang menyalakan api. Setelah (api itu) menerangi sekelilingnya, All...
2	18	47	1.00	(Mereka) tuli, bisu, lagi buta, sehingga mereka tidak dapat kembali...

2	19	-1	0.00	Atau, seperti (orang yang ditimpa) hujan lebat dari langit yang disertai berbagai kegelapan, petir, ...
2	20	-1	0.00	Hampir saja kilat itu menyambar penglihatan mereka. Setiap kali (kilat itu) menyinari, mereka berjal...
2	21	-1	0.00	Wahai manusia, sembahlah Tuhanmu yang telah menciptakan kamu dan orang-orang yang sebelum kamu agar ...
2	22	0	0.15	(Dialah) yang menjadikan bagimu bumi (sebagai) hamparan dan langit sebagai atap....
2	23	19	1.00	Jika kamu (tetap) dalam keraguan tentang apa (Al-Qur'an) yang Kami turunkan kepada hamba Kami
2	24	22	0.24	Jika kamu tidak (mampu) membuat(-nya) dan (pasti) kamu tidak akan (mampu) membuat(-nya)...
2	25	41	1.00	Sampaikanlah kabar gembira kepada orang-orang yang beriman dan beramal saleh bahwa untuk mereka (dis...
2	26	9	0.07	Sesungguhnya Allah tidak segan membuat perumpamaan seekor nyamuk atau yang lebih kecil....
2	27	-1	0.00	(yaitu) orang-orang yang melanggar perjanjian Allah setelah (perjanjian) itu diteguhkan, memutuskan ...
2	28	2	1.00	Bagaimana kamu ingkar kepada Allah, padahal kamu (tadinya) mati, lalu Dia menghidupkan kamu...
2	29	0	0.29	Dialah (Allah) yang menciptakan segala yang ada di bumi untukmu, kemudian Dia menuju ke langit, lalu...
2	30	17	0.75	(Ingatlah) ketika Tuhanmu berfirman kepada para malaikat, Aku hendak menjadikan khalifah di bumi...

5. Contoh Script Aplikasi app.py

5.1 Gambar script Library pada Aplikasi

```

1 import traceback
2 import threading
3 import uuid
4 from flask import jsonify
5 from flask import Flask, render_template, request, redirect, url_for, flash, send_from_directory, session, jsonify, send_file, Response
6 from werkzeug.utils import secure_filename
7 from werkzeug.security import generate_password_hash, check_password_hash
8 import pandas as pd
9 import re
10 import string
11 import mysql.connector
12 from mysql.connector import Error
13 from Sastrawi.StopwordRemover.StopwordRemoverFactory import StopwordRemoverFactory
14 from Sastrawi.Stemmer.StemmerFactory import StemmerFactory
15 from pyPdf import PdfFileReader
16 from datetime import datetime # Import yang missing
17 import numpy as np
18 from collections import Counter
19 from langdetect import detect, DetectorFactory
20 import matplotlib
21 matplotlib.use('Agg') # Non-interactive backend untuk Flask
22 import matplotlib.pyplot as plt
23 import seaborn as sns
24 from wordcloud import WordCloud
25 import io
26 import base64
27 import zipfile
28 import toml
29 from sklearn.feature_extraction.text import CountVectorizer
30 from bertopic import BERTopic
31 import umap
32 import hdbscan
33 from sentence_transformers import SentenceTransformer
34 import plotly
35 import plotly.graph_objects as go
36 import plotly.express as px

```

5.2 Gambar Contoh fungsi *Advance Preprocessing*

```
1181
1182 # ===== Advanced Preprocessor Class =====
1183 class AdvancedIndonesianPreprocessor:
1184     def __init__(self):
1185         # Initialize Sastrawi components for Indonesian
1186         self.stemmer_factory = StemmerFactory()
1187         self.stemmer = self.stemmer_factory.create_stemmer()
1188
1189         self.stopword_factory = StopWordRemoverFactory()
1190         self.stopword_remover = self.stopword_factory.create_stop_word_remover()
1191
1192         # Extended custom stopwords for Quranic context
1193         self.quran_specific_stopwords = {
1194
1195             # Common Indonesian stopwords
1196             'yang', 'di', 'ke', 'dari', 'pada', 'dan', 'atau', 'untuk', 'dengan',
1197             'adalah', 'itu', 'ini', 'sebagai', 'dalam', 'tidak', 'akan', 'jika',
1198             'karena', 'supaya', 'agar', 'maka', 'sungguh', 'sesungguhnya',
1199
1200             'adakah', 'akan', 'akankah', 'aku', 'anda', 'bagaimana', 'bahwa',
1201             'banyak', 'beberapa', 'belum', 'boleh', 'bisa', 'bukan', 'dalam', 'dahulu', 'dulu',
1202             'dimana', 'hingga', 'jadi', 'juga', 'kembali', 'ketika',
1203             'lagi', 'lalu', 'lebih', 'melalui', 'meskipun', 'harus', 'misalnya', 'mungkin',
1204             'walaupun', 'telah', 'udah', 'bila', 'setiap',
1205             'sangat', 'saat', 'tanpa', 'sesudah', 'sebelum', 'tentang',
1206             'engkau', 'nya', 'apa', 'orang', 'kemudian',
1207
1208             # Religious terms that might be too common but carry meaning
1209             # We'll keep some of these for now, remove only if they dominate
1210             'allah', 'tuhan',
1211             # 'tuhan', 'rasul', 'nabi', 'kitab',
1212
1213             # Pronouns and demonstratives
1214
1215             # 'ia', 'mereka', 'kami', 'kita', 'nya', 'mu', 'ku',
1216             'kamu', 'mereka', 'kami', 'kita', 'nya', 'mu', 'ku', 'dia',
1217
```

5.3 Gambar Contoh Script class Quran Bertopicmodel

```
1957 def get_cached_hdbscan_model():
1958     print("[cache] HDBSCAN model created")
1959     return _cached_hdbscan_model
1960
1961
1962 class QuranBERTopicModel:
1963     def __init__(self, num_topics='auto', topic_params=None):
1964         self.num_topics = num_topics
1965         self.topic_params = topic_params or {}
1966         self.model = None
1967         self.docs = None
1968         self.sentence_model = None
1969
1970     def prepare_documents(self, documents):
1971         """Prepare documents for BERTopic"""
1972         return documents
1973
1974     def build_topic_params(self):
1975         """Build BERTopic parameters from defaults + user input."""
1976         params = {
1977             "n_gram_range": (1, 2),
1978             "min_topic_size": 5,
1979             "language": "multilingual",
1980             "calculate_probabilities": True,
1981             "verbose": True,
1982         }
1983
1984         raw = self.topic_params or {}
1985
1986         ngram_value = raw.get("n_gram_range")
1987         if isinstance(ngram_value, (list, tuple)) and len(ngram_value) == 2:
1988             try:
1989                 n_min = max(1, int(ngram_value[0]))
1990                 n_max = max(1, int(ngram_value[1]))
1991                 if n_min > n_max:
1992                     n_min, n_max = n_max, n_min
1993                 params["n_gram_range"] = (n_min, n_max)
1994             except (TypeError, ValueError):
1995
```

5.4 Gambar Contoh script Class CTM model

```
2080
2081 class QuranCTMModel:
2082     def __init__(self, num_topics=10):
2083         self.num_topics = num_topics
2084         self.model = None
2085         self.vectorizer = None
2086
2087     def prepare_data(self, documents):
2088         """Prepare data for CTM"""
2089         # Create vocabulary and document-term matrix
2090         self.vectorizer = CountVecorizer(
2091             max_features=1000,
2092             min_df=2,
2093             max_df=0.8,
2094             token_pattern=r'\b\w+\b'
2095         )
2096         dtm = self.vectorizer.fit_transform(documents)
2097         vocabulary = self.vectorizer.get_feature_names_out()
2098
2099         return dtm, vocabulary
2100
2101     def train_ctm(self, documents):
2102         """Train the CTM model"""
2103         print("Training Correlated Topic Model...")
2104
2105         # Prepare data
2106         dtm, vocabulary = self.prepare_data(documents)
2107
2108         # Convert to tomatopy format
2109         corpus = tp.utils.Corporus()
2110         for doc_vec in dtm:
2111             doc_tokens = []
2112             indices = doc_vec.nonzero()[1]
2113             data = doc_vec.data
2114             for idx, count in zip(indices, data):
2115                 word = vocabulary[idx]
2116                 doc_tokens.extend([word] * int(count))
```