



Analisis Pemodelan Topik Pada Teks Terjemahan Al-Qur'an Berbahasa Indonesia Dengan Metode *Correlated Topic Modeling* (CTM) Dan BERTopic

Asep Ridwan Hidayat¹, Sajarwo Anggai², Arya Adhyaksa Waskita³

^{1,2,3}) Teknik Informatika S-2, Program Pasca Sarjana, Universitas Pamulang, Kota Tangerang Selatan, Banten

Email: ¹asep.rid.hidayat@gmail.com, ²sajarwo@mail.com, ³dosen022334@mail.com

ABSTRACT

This study aims to analyze the thematic structure of the Indonesian translation of the Quran using the Correlated Topic Model (CTM) and BERTopic methods. The research stages include text preprocessing, evaluation of preprocessing variations, model parameter optimization, topic modeling, and analysis of the results. The preprocessing process is carried out through case folding, tokenization, stopword removal, and stemming. The evaluation results show that the advanced preprocessed method provides the best balance with a vocabulary reduction of 83.75% and meaning preservation of 73.20%. In CTM modeling, optimization of the number of topics shows that the optimal value is at $K = 14$ based on a combination of log-likelihood, topic diversity, and composite score metrics. The CTM model is able to produce representative topics with low inter-topic correlation, although the internal coherence value is still at a moderate level. Meanwhile, in BERTopic, the optimal parameter is obtained at $\text{min_topic_size} = 25$ with a coherence value of 0.5735 ($C_v > 0.5$), which is quite good. The positive NPMI value = 0.0530 indicates that there is a statistically significant association between words in the topic. The UMass value = -5.3257, which is the best value (closest to zero) compared to other configurations, indicates that the model has good probabilistic consistency towards document distribution. The results of combining topics between CTM and BERTopic using the Jaccard similarity approach show that there is a relationship between topics even with a relatively low to moderate level of similarity (0.08–0.25) so that the main thematic structure is obtained which includes several large categories such as faith, morals, eschatology, sharia, muamalah, natural phenomena, history, science, and psychological aspects. The topic distribution shows that the categories of faith and eschatology are dominant themes in the Qur'an.

Keyword: Topic Modeling, Correlated Topic Model (CTM), BERTopic, Natural Language Processing, Indonesian Translation of the Quran

ABSTRAK

Penelitian ini bertujuan untuk menganalisis struktur tematik pada teks terjemahan Al-Qur'an berbahasa Indonesia menggunakan metode Correlated Topic Model (CTM) dan BERTopic. Tahapan penelitian meliputi preprocessing teks, evaluasi variasi preprocessing, optimasi parameter model, pemodelan topik, serta analisis hasil. Proses preprocessing dilakukan melalui case folding, tokenization, stopword removal, dan stemming. Hasil evaluasi menunjukkan bahwa metode preprocessed advanced memberikan keseimbangan terbaik dengan reduksi kosakata sebesar 83,75% dan preservasi makna sebesar 73,20%. Pada pemodelan CTM, optimasi jumlah topik menunjukkan bahwa nilai optimal berada pada $K=14$ berdasarkan kombinasi metrik log-likelihood, topic diversity, dan composite score. Model CTM mampu menghasilkan topik yang representatif dengan korelasi antar topik yang rendah, meskipun nilai koherensi internal masih berada pada tingkat sedang. Sementara itu, pada BERTopic, parameter optimal diperoleh pada $\text{min_topic_size} = 25$ dengan nilai koherensi 0.5735 ($C_v > 0,5$) yang cukup baik. Nilai NPMI = 0.0530 yang bernilai positif menunjukkan bahwa terdapat asosiasi statistik yang bermakna antar kata dalam topik. Nilai UMass = -5.3257, yang merupakan nilai terbaik (paling mendekati nol) dibandingkan konfigurasi lainnya, menunjukkan bahwa model memiliki konsistensi probabilistik yang baik terhadap distribusi dokumen. Hasil penggabungan topik antara CTM dan BERTopic

menggunakan pendekatan Jaccard similarity menunjukkan adanya keterkaitan antar topik meskipun dengan tingkat kemiripan yang relatif rendah hingga sedang (0,08–0,25) sehingga diperoleh struktur tematik utama yang mencakup beberapa kategori besar seperti aqidah, akhlak, eskatologi, syariah, muamalah, fenomena alam, sejarah, ilmu pengetahuan, dan aspek psikologis. Distribusi topik menunjukkan bahwa kategori aqidah dan eskatologi menjadi tema dominan dalam Al-Qur'an.

Kata kunci: *Topic Modeling, Correlated Topic Model (CTM), BERTopic, Natural Language Processing, Terjemah Al-Qur'an Berbahasa Indonesia.*

1. PENDAHULUAN

Pemodelan topik (*topic modeling*) merupakan pendekatan penting dalam analisis teks untuk menemukan tema tersembunyi dalam kumpulan dokumen besar secara otomatis [1]. Dalam konteks teks-teks keagamaan, seperti terjemahan Al-Qur'an, analisis ini menjadi tantangan tersendiri karena sifat bahasanya yang padat makna, kontekstual, dan mengandung makna teologis yang dalam [2]. Terjemahan Al-Qur'an dalam bahasa Indonesia memiliki kekhasan struktur linguistik yang tidak hanya literal, tetapi juga interpretatif, sehingga pemodelan topik pada korpus ini membutuhkan pendekatan yang lebih kontekstual dan adaptif terhadap makna dalam teks.

Seiring perkembangan teknologi pemrosesan bahasa alami (NLP), model berbasis *transformer* seperti BERT (*Bidirectional Encoder Representations from Transformers*) membawa kemajuan signifikan dalam memahami konteks kata dalam kalimat. Model ini dilatih secara besar-besaran menggunakan miliaran kata, sehingga mampu menangkap nuansa makna dan hubungan antar-kata dalam berbagai konteks. *Correlated Topic Modeling* (CTM) dan BERTopic merupakan metode pemodelan topik modern yang memanfaatkan kekuatan representasi kontekstual dari BERT untuk menghasilkan topik yang lebih koheren dan bermakna. CTM sendiri mengembangkan pendekatan klasik dengan memodelkan korelasi antar topik menggunakan distribusi logistic normal, sehingga mampu mengidentifikasi hubungan kompleks antar tema yang muncul dalam dokumen [3].

Beberapa penelitian awal telah menerapkan BERTopic dan CTM pada berbagai jenis korpus, seperti ulasan produk, berita, dan dokumen akademik, dengan hasil yang menjanjikan. Misalnya, menunjukkan bahwa CTM mampu menghasilkan nilai koherensi topik yang lebih tinggi dibanding metode lainnya seperti LDA [3]. Di sisi lain, BERTopic mendapatkan perhatian karena kemampuannya mengidentifikasi topik secara dinamis dan mendalam, serta menyajikannya dalam bentuk visual interaktif. Namun, penerapan kedua

metode ini pada korpus teks religius terutama teks terjemahan Al-Qur'an dalam bahasa Indonesia belum banyak digunakan.

Salah satu penelitian pada terjemah Al-Qur'an yaitu diantaranya "Pengelompokan Terjemah Al-Quran Departemen Agama menggunakan Metode Fuzzy C-Means", penelitian ini menggunakan algoritma *fuzzy c-means* (FCM) dan *vector space model* (VSM) untuk mengelompokkan terjemahan ayat berdasarkan kemiripan dan fokus pada *clustering* dengan *preprocessing* teks, pembobotan *tf-idf*, dan evaluasi kualitas kluster dengan *silhouette coefficient*. Hasil algoritma FCM menghasilkan nilai *clustering* terbaik dengan parameter tertentu dan algoritma ini secara umum mampu menemukan kelompok ayat yang serupa makna. Namun, karakteristik dimensi fitur tinggi dan kemiripan antar terjemah yang sedikit membuat kinerja FCM kurang optimal [4].

Adapun penelitian ini selain dari metode yang lebih kontekstual dengan metode CTM dan Bertopic juga terletak pada kebutuhan untuk memahami kandungan makna dalam teks Al-Qur'an secara lebih terstruktur dan otomatis, sehingga dapat dimanfaatkan dalam berbagai keperluan seperti pembelajaran tematik, pengembangan sistem pencarian ayat berbasis tema, atau analisis linguistik keislaman. Pemodelan topik yang baik pada teks terjemahan Al-Qur'an dapat membantu masyarakat maupun akademisi dalam memahami dan mengeksplorasi tema-tema utama dalam Al-Qur'an secara efisien dan sistematis.

2. METODE


Objek penelitian ini adalah salah teks terjemahan Al-Qur'an dalam Bahasa Indonesia.

2.1. Jenis dan Sumber data

Data penelitian ini adalah teks terjemahan Al-Qur'an dalam Bahasa Indonesia, bersumber dari kementerian Agama Republik Indonesia (Kemenag RI) di <https://quran.kemenag.go.id/> dengan referensi terjemahanya diarahkan ke <https://pustakalajnah.kemenag.go.id/> dengan versi Terjemahan Al-Quran_v161122 sebanyak 114 file.

2.2. Perancangan Penelitian

Perancangan penelitian ini dengan dua pendekatan model topik berbasis representasi semantik, yakni *Correlated Topic Model* (CTM) dan BERTopic, terhadap dataset terjemahan Al-Qur'an dalam Bahasa Indonesia. Berikut daigram alur peneletian.



Gambar 1 Diagram Perancangan Penelitian

Gambar 1 diagram perancangan penelitian diawali dengan pengumpulan dan praproses dataset terjemahan Al-Qur'an Bahasa Indonesia, kemudian *Preprocessing*, dilanjutkan training dan evaluasi model CTM dan BERTopic. setelah terbentuk topik dilakukan penggabungan topik dengan metode *Jaccard Similarity* dilakukan analisa dan intepretasi topik.

2.3. Teknik Analisis

Teknis analisis dilakukan secara bertahap dengan pendekatan berbasis bahasa Python dan pustaka NLP modern.

2.3.1 Metode Analisis

Metode analisis yang digunakan adalah dua algoritma pemodelan topik utama yaitu:

2.3.1.1 *Correlated Topic Model (CTM)*

Secara matematis CTM memodelkan distribusi topik dalam dokumen menggunakan model *Gaussian logit-normal* sebagai pengganti distribusi *Dirichlet* pada LDA.

$$\theta_d \sim \text{LogisticNormal}(\mu, \Sigma) \quad (1)$$

Dimana θ_d adalah distribusi topik dokumen d , μ adalah mean dan Σ adalah matriks kovarians untuk korelasi topik.

2.3.1.2 BERTopic

BERTopic menggunakan representasi *embedding* kata/konteks berdasarkan model *transformer* (seperti BERT) dan klasterisasi berbasis densitas (misalnya HDBSCAN) untuk menghasilkan topik.

2.3.2 Tools dan Library yang Digunakan

Bahasa pemrograman yang digunakan Python 3.10 dengan menggunakan *Framework* Jupyter Notebook dan Google Colab. Library utama yang digunakan *transformers*, *sentence-transformers*, *ctm*, *bertopic nltk*, *spacy*, *gensim*, *pandas*, *scikit-learn*.

2.4. Metode Evaluasi

Evaluasi dalam penelitian ini dilakukan untuk mengukur kualitas dan efektivitas model topik yang dihasilkan oleh CTM dan BERTopic dalam menggambarkan struktur tematik dari teks terjemahan Al-Qur'an.

2.4.1 Evaluasi Kuantitatif

Beberapa evaluasi kualitatif yang bisa dijadikan parameter penilaian dari output data yang diperoleh yaitu :

2.4.1.1 Metode Evaluasi Preprocessing

Pada tahap preprocessing, dilakukan evaluasi untuk mengukur efektivitas pembersihan data teks melalui tiga metrik utama, yaitu:

1. Token Reduction

$$\text{Token Reduction}(\%) = \frac{T_{\text{before}} - T_{\text{after}}}{T_{\text{before}}} \times 100 \quad (2)$$

Dengan T_{before} = Jumlah Token sebelum preprocessing, T_{after} = Jumlah Token setelah preprocessing.

2. Vocabulary Reduction

$$\text{Vocabulary Reduction}(\%) = \frac{V_{\text{before}} - V_{\text{after}}}{V_{\text{before}}} \times 100 \quad (8)$$

Dengan V_{before} = Jumlah kata unik sebelum preprocessing, V_{after} = Jumlah kata unik setelah preprocessing.

3. *Preservation Rate*

$$Preservation Rate (\%) = \frac{T_{after}}{T_{before}} \times 100 \quad (9)$$

2.4.1.2 Evaluasi Optimasi Jumlah Topik CTM

Pada tahap optimasi jumlah topik K pada model CTM dilakukan untuk mengukur nilai K dengan beberapa nilai sebagai berikut:

1. *Log-Likelihood (LL)*

$$LL = \sum_{d=1}^D \log P(w_d | \theta_d) \quad (10)$$

Dengan D = total seluruh dokumen, d = indeks dokumen, w_d = kata dalam dokumen ke -d, θ_d = distribusi topik dokumen

2. *Perplexity*

$$Perplexity = \exp \left(- \frac{\sum_d \log P(w_d)}{\sum_d N_d} \right) \quad (11)$$

Dengan w_d = kumpulan kata dalam dokumen, d = dokumen, N_d = jumlah kata dalam dokumen d

3. *Topic Coherence Score*

Beberapa vatrian yang digunakan:

a. *Umass*

$$UMass (w_i, w_j) = \log \frac{D(w_i, w_j) + \epsilon}{D(w_j)} \quad (12)$$

Dengan (w_i, w_j) = Jumlah total dokumen yang mengandung kata w_i dan w_j , $D(w_j)$ = Jumlah total dokumen yang mengandung kata w_j , ϵ = adalah konstanta kecil untuk menghindari pembagian dengan nol.

b. *Positive Pointwise Mutual Information (PPMI)*

$$PPMI(w_i, w_j) = \max(0, \log \frac{P(w_i, w_j)}{P(w_i)P(w_j)}) \quad (13)$$

Dengan $P(w_i, w_j)$ adalah probabilitas kemunculan bersama kata w_i dan w_j dalam korpus. $P(w_i)$ dan $P(w_j)$ adalah probabilitas kemunculan masing-masing kata.

c. *NPMI*

$$NPMI(w_i, w_j) = \frac{\log \frac{P(w_i, w_j)}{P(w_i)P(w_j)}}{-\log P(w_i, w_j)} \quad (14)$$

Dengan $P(w_i, w_j)$ adalah probabilitas kemunculan bersama kata w_i dan w_j dalam korpus. $P(w_i)$ dan $P(w_j)$

3. HASIL DAN PEMBAHASAN

3.1. Variasi dan Hasil Preprocessing Teks

Tahap preprocessing teks dilakukan melalui tahapan *Case Folding*, *Stopword removal*, *Tokenization*, *Punctuation removal*, *Stemming*, dan *Lemmatization*.

3.1.1 Variasi Metode *Preprocessing*

Pada penelitian ini diterapkan beberapa variasi metode preprocessing untuk mengevaluasi pengaruh masing-masing tahapan terhadap kualitas representasi teks sebelum dilakukan pemodelan topik, dan didapatkan beberapa nilai dari variasi preprocessing sebagai berikut:

Tabel 1 Nilai Hasil Variasi Preprocessing

Variasi Preprocessing	Reduksi Token (%)	Reduksi Kosakata (%)	Preservasi Makna (%)
<i>Preprocessed basic</i>	6,81	58.43	68,61
<i>Preprocessed no steam</i>	55.7	59.31	74.45
<i>Preprocessed advanced</i>	55.6	83.75	73.20

Tabel 1 adalah tiga metrik evaluasi, *pereprocessed advanced* dipilih sebagai preprocessing utama dalam penelitian dengan variasi keseimbangan terbaik antara

reduksi token tinggi (44,49%) untuk menekan noise, reduksi kosakata sangat signifikan (83,75%) untuk meningkatkan stabilitas topik, Preservasi makna memadai (73,20%) untuk menjaga interpretabilitas tema.

3.2. Analisa Topik model CTM


3.3.1 Optimasi Jumlah Topik

Proses optimasi dilakukan dengan menguji rentang jumlah topik $K = 8$ hingga $K = 19$, menggunakan 114 dokumen tingkat surat dengan total 75.490 token.

Tabel 2 Hasil uji optimasi nilai K

Jumlah Topik (K)	<i>Log- Likelihood</i> (LL)	<i>Coherence Score</i>	<i>Diversity</i>	<i>Quality</i>
8	-6.556	1	0.925	0.95
9	-7.0233	1	0.9111	0.9444
10	-6.7489	1	0.96	0.94
11	-6.9106	1	0.9455	0.9545
12	-7.0999	1	0.9167	0.9417
13	-7.1274	1	0.9385	0.9385
14	-6.8294	1	0.9714	0.9429
15	-7.1615	1	0.9933	0.9267
16	-7.0843	1	0.975	0.9375
17	-7.1856	1	0.9529	0.9529
18	-7.8642	1	0.9333	0.9556
19	-7.7731	1	0.9526	0.9421

Pada tabel 2 merupakan nilai hasil pengujian rentang topik 8-19 jika digambarkan dalam bentuk grafik seperti berikut:



Gambar 1. 1 Grafik Normalized Score vs Number of topics

Grafik normalisasi menunjukkan perbandingan semua metrik dalam satu skala. Terlihat bahwa pada $K=14$, hampir seluruh metrik berada pada posisi yang relatif tinggi dan seimbang dibandingkan jumlah topik lainnya. Tidak ada metrik yang terlalu dominan maupun terlalu rendah, yang menunjukkan bahwa model berada pada kondisi optimal.

3.3. Training dan Analisa Hasil Pemodelan CTM

3.3.1 Training model CTM

Tabel 3 Iterasi Training Model

Iterasi	Log-Likelihood
0	-7.7665
100	-6.7815
200	-6.8747
300	-7.2442
400	-7.3224

Tabel 3 terlihat bahwa nilai *log-likelihood* mengalami perubahan sepanjang proses iterasi pelatihan model CTM. Pada iterasi awal (iterasi ke-0), nilai berada pada angka -7.7665, yang menunjukkan bahwa model masih dalam kondisi awal dan belum mampu memodelkan distribusi data dengan baik. Selanjutnya, pada iterasi ke-100 terjadi peningkatan signifikan menjadi -6.7815, Namun, setelah iterasi ke-100, nilai *log-*

likelihood mengalami sedikit penurunan pada iterasi ke-200 menjadi -6.8747, dan terus menurun hingga iterasi ke-300 (-7.2442) dan iterasi ke-400 (-7.3224) iterasi dirasa sudah cukup.

3.3.2 Analisis Hasil Topik CTM


Tabel 4 Hasil Topik CTM

Topik ke-	Kata-kata Utama	Topik Ke-	Kata-kata Utama
0	ayat, ingat, dosa, baca, dengar	7	azab, bawa, timpa, datang, gembira
1	benar, janji, setan, ajar, ambil	8	hari, jalan, sendiri, kiamat, malam
2	rasul, sembah, dusta, datang, bukti	9	masuk, dua, dalam, surga, neraka
3	kaum, tanda, hidup, mati, waktu	10	kepada, beri, tunjuk, anugerah, rezeki
4	kufur, hati, takut, balas, rasa	11	buat, jangan, anak, laki, perempuan
5	maha, bumi, langit, tahu, segala	12	tuhan, dapat, siapa, kata, tahu
6	turun, tempat, kitab, buruk, malaikat	13	ada, bagi, baik, iman, jadi

Analisis terhadap kata-kata utama pada tabel 1 bahwa topik-topik yang dihasilkan memiliki koherensi semantik yang jelas dan mencerminkan tema-tema utama Al-Qur'an, diantaranya, Ketauhidan dan keimanan (Aqidah) pada Topik 2, 5, 10, dan 12. Hari pembalasan dan azab (Eskatologi) pada Topik 7, 8, dan 9. Keimanan dan Aklak pada Topik 4 dan 13. Sejarah dan Umat pada topik 1 dan 3. Hukum dan Sosial (Muamalah) pada topik 11. Wahyu dan peringatan pada topik 0 dan 6.

3.3.3 Analisa Korelasi antar topik model CTM

Nilai korelasi pada *Gambar 2* berada pada rentang yang relatif rendah, yaitu sekitar -0,15 hingga 0,12. Hal ini menunjukkan bahwa nilai korelaasi yang tidak begitu kuat satu sama lain. Tetapi terdapat beberapa pasangan topik yang memiliki korelasi positif, meskipun dalam skala kecil, seperti antara topik 1 dan topik 2 dengan nilai sekitar 0,12, serta topik 7 dan topik 10 dengan nilai sekitar 0,08. Korelasi positif ini menunjukkan adanya kedekatan konteks atau kemiripan semantik antar topik



Gambar 3 Grafik CTM Topic Correlation Heatmap

3.3.4 Analisa Metriks Koherensi CTM

Tabel 5 .Nilai Metrik Koherensi

C_v	NPMI	UMass	UCI	Perplexity
0.517	-0.022	-5.066	-2.137	1720.28

Nilai C_v sebesar 0,5170 pada tabel 5 mengindikasikan bahwa koherensi topik berada pada kategori sedang, artinya kata-kata dalam setiap topik sudah cukup saling berkaitan. nilai NPMI sebesar -0,0226 yang mendekati nol tetapi masih negatif menunjukkan bahwa keterkaitan antar kata dalam topik relatif lemah, nilai UMass sebesar -5,0661 dan UCI sebesar -2,1370, yang keduanya bernilai negatif, artinya hubungan antar kata dalam topik masih kurang kuat, dan Nilai Perplexity sebesar 1720,28 menunjukkan bahwa model CTM yang digunakan masih belum optimal dalam menangkap struktur distribusi kata pada dataset.

3.4 Analisis Topik Model BERTopic

3.4.1 Uji Parameter Jumlah Minimal Dokumen


Tabel 6 Nilai CV, NPMI dan Umass pada pengujian Min Topic Size

min topic size	number topics	C_v	NPMI	UMass	NPMI norm	UMass norm	Final Score
5	203	0.6048	0.0619	-7.5949	1	0	0.6
10	104	0.5908	0.0576	-6.6529	0.8983	0.4142	0.7047
15	75	0.5769	0.0367	-6.4287	0.4043	0.5128	0.4477
20	60	0.555	0.0196	-6.5236	0	0.471	0.1884
25	39	0.5735	0.053	-5.3257	0.7896	0.9977	0.8728
30	36	0.5687	0.0476	-5.3205	0.6619	1	0.7972

Pada tabel 1.6 terlihat bahwa perubahan nilai parameter ini memberikan pengaruh signifikan terhadap jumlah topik yang dihasilkan. pada topic size 5 yang menghasilkan 203 topik. Namun, meskipun nilai C_v dan NPMI relatif tinggi pada konfigurasi ini, nilai UMass yang sangat rendah (-7.5949) menunjukkan bahwa topik yang dihasilkan kurang koheren secara statistik dalam konteks probabilistik dokumen, ketika nilai *min_topic_size* ditingkatkan, jumlah topik menjadi lebih sedikit dan lebih general. Pada nilai 25, model menghasilkan 39 topik dengan keseimbangan terbaik antara metrik evaluasi. Hal ini ditunjukkan oleh nilai C_v (0.5735) dan NPMI (0.0530) yang cukup tinggi, serta nilai UMass yang paling mendekati nol (-5.3257) mengindikasikan peningkatan kualitas koherensi topik. Selain itu, normalisasi metrik menghasilkan nilai NPMI_norm (0.7896) dan UMass_norm (0.9977) yang tinggi, sehingga menghasilkan *FinalScore* tertinggi yaitu 0.8728. Dengan demikian, dapat disimpulkan bahwa nilai *min_topic_size* = 25 merupakan parameter optimal dalam eksperimen ini.

3.4.2 Hasil Pemodelan BERTopic


Setelah dilakukan pengolahan dokumen dengan pengujian parameter topic size 25 diperoleh 50 topik , dan berikut diperoleh grafik distribusi topik sebagai berikut:



Gambar 4 Grafik Distribusi Topik pada dokumen

Grafik gambar 4 merupakan grafik distribusi terlihat bahwa Topik -1 (maha, benar, kepada, beri) memiliki jumlah dokumen terbesar (2039), Hal ini menunjukkan bahwa sekitar sepertiga dokumen tidak tergabung dalam topik tertentu dan diklasifikasikan sebagai outlier disebabkan; karakteristik teks dokumen yang multitematik, panjang dokumen yang pendek, sensitifitas Algoritma clustering (HDBSCAN).

Jika dilihat frekuensi kemunculan topik pada setiap dokumen bisa dilihat dari grafik berikut :



Gambar 1. 2 Grafik Topic Word Scores

Grafik *Topic Word Scores* menunjukkan distribusi kata-kata representatif pada masing-masing topik yang dihasilkan oleh model BERTopic. Hasil visualisasi

menunjukkan bahwa setiap topik memiliki konsistensi semantik yang baik, ditandai dengan keterkaitan yang kuat antar kata dalam satu kluster.


Contoh 5 hasil topik 1 dari 50 topik dan seterusnya pada tabel diatas dapat dirincikan sebagai berikut:

Tabel 1. 1 Contoh Hasil topik pada BERTopic

Topik	
0	['bumi', 'langit', 'langit bumi', 'cipta', 'ada', 'maha', 'milik', 'cipta langit', 'segala', 'ada langit']
1	['iman', 'wahai iman', 'wahai', 'agama', 'benar', 'iman kepada', 'kufur', 'kepada', 'iman jangan', 'ada']
2	['hidup', 'mati', 'akhirat', 'dunia', 'hidup dunia', 'hidup mati', 'mati hidup', 'dunia akhirat', 'nyawa', 'bumi']
3	['jahat', 'laku', 'manusia', 'cipta', 'hina', 'durhaka', 'benar', 'jahanam', 'duga', 'siapa']
4	['nabi', 'jihad', 'muslim', 'arab', 'islam', 'agama', 'ibrahim', 'iman', 'masjid', 'bahasa']
5	['ayat', 'ayat ayat', 'kitab', 'baca', 'dusta ayat', 'turun', 'jelas', 'olok', 'dusta', 'hikmah']

Dari tabel 1.7 pada hasil pemodelan, diperoleh struktur tema besar yang terdiri dari sembilan kategori utama, seperti aqidah (keimanan), denga topik 1, 4, 5. Eskatologi (akhirat) dengan topik 2 dan akhlak (perilaku, moral, dan sikap manusia), dengan topik.

3.4. Distribusi Topik terhadap Dokumen



Gambar 1. 3 Contoh distribusi topik Surat Al-Fatihah, Al-baqarah dan Ali Imran

Pada Surat Al-Fatihah, terlihat bahwa jumlah ayat yang terbatas menghasilkan distribusi topik yang sangat sederhana. Pada surat Al-Baqarah memperlihatkan penyebaran titik yang jauh lebih padat dan beragam disepanjang sumbu ayat maupun topik, yang mengindikasikan kompleksitas tema yang tinggi serta variasi topik yang luas. Sementara itu, Surat Ali Imran menunjukkan pola distribusi yang juga beragam namun tidak sepadat Al-Baqarah, mencerminkan tingkat kompleksitas tematik yang berada di antara kedua surat sebelumnya.

4. KESIMPULAN

Berdasarkan hasil penelitian yang telah dilakukan pada model menunjukkan CTM sudah mampu menangkap hubungan antar topik, tetapi kualitas koherensi internal topik masih berada pada tingkat sedang hingga rendah. Dengan kata lain, model cenderung baik dalam memodelkan relasi antar topik, namun belum optimal dalam menghasilkan topik yang benar-benar solid secara semantik.

Hasil topik pada model BERTopic sebanyak 50 topik dan kata-kata dominan pada tabel menunjukkan bahwa topik-topik yang dihasilkan memiliki koherensi semantik yang jelas dan mencerminkan tema-tema seperti ketuhanan, kenabian, keimanan, akhlak, eskatologi (hari kiamat, surga, dan neraka), ilmu pengetahuan (science), sosial, dan hukum.

5. DAFTAR PUSTAKA

- [1] Blei, D. M., Ng, A. Y., & Edu, J. B. (2003). Latent Dirichlet Allocation Michael I. Jordan. In *Journal of Machine Learning Research* (Vol. 3).

- [2] Habash, N. (2006). *Arabic Preprocessing Schemes for Statistical Machine Translation*
- [3] Blei, D. M., & Lafferty, J. D. (2007a). A correlated topic model of Science. *The Annals of Applied Statistics*, 1(1). <https://doi.org/10.1214/07-aos114>.
- [4] Havid Albar Purnomo, M., & Abdurrachman Bachtiar, F. (2021). *Pengelompokan Terjemah Al-Quran Departemen Agama menggunakan Metode Fuzzy C-Means* (Vol. 5, Issue 2). <http://j-ptiik.ub.ac.id>
- [5] Aftari, D. P., Safaat, N., Agustian, S., Yusra, Y., & Afrianty, I. (2024). Perbandingan Performa Klasifikasi Terjemahan Al-Qur'an Menggunakan Metode Random Forest dan Long Short Term Memory. *Journal of Computer System and Informatics (JoSYC)*, 5(3), 567–577. <https://doi.org/10.47065/josyc.v5i3.5156>
- [6] Awaludin, A. (2025). Documenting the Half-Century Evolution of Islamic Education Research: A Correlated Topic Modeling (CTM) Study of the Literature from 1970 to 2023. *Proceedings of the 2025 AERA Annual Meeting*. <https://doi.org/10.3102/2178518>
- [7] Bartolomeo, G. (2024). *Exploring the Power of Topic Modeling Techniques in Analyzing Customer Reviews: A Comparative Analysis*. <http://arxiv.org/abs/2308.06797>
- [8] Blei, D. M., & Lafferty, J. D. (n.d.). *Correlated Topic Models*. www.jstor.org
- [9] Blei, D. M., & Lafferty, J. D. (2007b). A correlated topic model of Science. *The Annals of Applied Statistics*, 1(1). <https://doi.org/10.1214/07-aos114>
- [10] Blei, D. M., & Lafferty, J. D. (2007c). A correlated topic model of Science. *The Annals of Applied Statistics*, 1(1). <https://doi.org/10.1214/07-aos114>
- [11] Brawijaya, U., Raditya, B., Listyawan, N., Setiawan, N. Y., & Saputra, M. C. (2017). *Fakultas Ilmu Komputer Topic Modelling Pada Aktivitas Pengembangan Perangkat Lunak Menggunakan BERTopic* (Vol. 1, Issue 1). <http://j-ptiik.ub.ac.id>
- [12] Campello, R. J. G. B., Moulavi, D., & Sander, J. (n.d.). *Density-Based Clustering Based on Hierarchical Density Estimates*.
- [12] Havid Albar Purnomo, M., & Abdurrachman Bachtiar, F. (2021). *Pengelompokan Terjemah Al-Quran Departemen Agama menggunakan Metode Fuzzy C-Means* (Vol. 5, Issue 2). <http://j-ptiik.ub.ac.id>

